

回归分析


Regression Analysis



回归 (regression) ?

Francis Galton (1822-1911)

- 一般说来高个子的父代会有高个子的子代
- 子代的身高比父代更加趋向一致(“向平庸的回归”)



$$\bar{x} \approx 68, \bar{y} \approx 69$$

儿子比父亲平均高1英寸

对于身高72英寸的父亲，
儿子身高多数不到73英寸；

对于身高64英寸的父亲，
儿子身高多数超过65英寸；

回归直线 $y=0.516x+33.73$

Pearson: 1078个父亲和儿子身高的散点图

回归分析是数学建模的有力工具

- 由于客观事物内部规律的复杂及人们认识程度的限制, 无法分析实际对象内在的因果关系;
- 人们关心的变量(因变量)受另外几个变量(自变量)的关联性(非因果性)的影响, 并且存在众多随机因素, 难以用机理分析方法找出它们之间的关系;
- 需要建立这些变量的数学模型, 使得能够根据自变量的数值预测因变量的大小, 或者解释因变量的变化。

血压与年龄

刹车距离与车速

薪金与资历、教育程度、工作岗位

回归分析的主要步骤

- 收集一组包含因变量和自变量的数据；
- 选定因变量与自变量之间的模型，利用数据按照最小二乘准则计算模型中的系数；
- 利用统计分析方法对不同的模型进行比较，找出与数据拟合得最好的模型；
- 判断得到的模型是否适合于这组数据，诊断有无不适合回归模型的异常数据；
- 利用模型对因变量作出预测或解释。

回归分析(Regression Analysis)

- 从应用角度介绍回归分析的基本原理、方法和软件实现

1. 简化的实际问题及其数学模型
2. 一元线性回归
3. 多元线性回归
4. 非线性回归

实例及其数学模型 例1 血压与年龄

为了解血压随年龄增长而升高的关系，调查了30个成年人的血压（收缩压，mmHg）与年龄：


序号	血压	年龄	序号	血压	年龄	序号	血压	年龄
1	144	39	11	162	64	21	136	36
2	215	47	12	150	56	22	142	50
3	138	45	13	140	59	23	120	39
4	145	47	14	110	34	24	120	21
5	162	65	15	128	42	25	160	44
...	...	...	...	...	...	...	...	...

- 用这组数据确定血压与年龄的关系；
- 从年龄预测血压可能的变化范围；
- 回答 “平均说来60岁比50岁的人血压高多少”。

例1 血压与年龄

模型 记血压(因变量) y , 年龄(自变量) x ,

作数据 $(x_i, y_i)(i=1, 2, \dots, 30)$ 的散点图



y 与 x 大致呈线性关系

$$y = \beta_0 + \beta_1 x$$

由数据确定系数 β_0, β_1

的估计值 $\hat{\beta}_0, \hat{\beta}_1$

- 曲线拟合(求超定线性方程组的最小二乘解);
- 从统计推断角度讨论 β_0, β_1 的置信区间和假设检验;
- 对任意的年龄 x 给出血压 y 的预测区间。

例2 血压与年龄、体重指数、吸烟习惯

又调查了例1中30个成年人的体重指数、吸烟习惯:

序号	血压	年龄	体重指数	吸烟	序号	血压	年龄	体重指数	吸烟	序号	血压	年龄	体重指数	吸烟
1	144	39	24.2	0	11	162	64	28.0	1	21	136	36	25.0	0
2	215	47	31.1	1	12	150	56	25.8	0	22	142	50	26.2	1
3	138	45	22.6	0	13	140	59	27.3	0	23	120	39	23.5	0
4	145	47	24.0	1	14	110	34	20.1	0	24	120	21	20.3	0
5	162	65	25.9	1	15	128	42	21.7	0	25	160	44	27.1	1
...	...	...	...	...	...	...	...	...	...	...	...	...	...	...

体重指数: $\text{体重(kg)} / [\text{身高(m)}]^2$

吸烟习惯: 0~不吸烟, 1~吸烟



例2 血压与年龄、体重指数、吸烟习惯

模型 记血压 y , 年龄 x_1 、体重指数 x_2 、吸烟习惯 x_3

作数据 y 对 x_2 的散点图 y 与 x_2 大致呈线性关系

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_3$$

由数据确定系数 $\beta_0, \beta_1, \beta_2, \beta_3$

的估计值 $\hat{\beta}_0, \hat{\beta}_1, \hat{\beta}_2, \hat{\beta}_3$

例3 软件开发人员的薪金

建立模型研究薪金与资历、管理责任、教育程度的关系，分析人事策略的合理性，作为新聘用人员薪金的参考。

46名软件开发人员的档案资料

编号	薪金	资历	管理	教育	编号	薪金	资历	管理	教育
01	13876	1	1	1	42	27837	16	1	2
02	11608	1	0	3	43	18838	16	0	2
03	18701	1	1	3	44	17483	16	0	1
04	11283	1	0	2	45	19207	17	0	2
05	11767	1	0	3	46	19346	20	0	1

资历~ 从事专业工作的年数；管理~ 1=管理人员，0=非管理人员；教育~ 1=中学，2=大学，3=研究生



模型

 $y \sim$ 薪金, $x_1 \sim$ 资历 (年) $x_2 = 1 \sim$ 管理人员, $x_2 = 0 \sim$ 非管理人员

教育

1=中学

2=大学

3=研究生

$$x_3 = \begin{cases} 1, & \text{中学} \\ 0, & \text{其它} \end{cases}$$

$$x_4 = \begin{cases} 1, & \text{大学} \\ 0, & \text{其它} \end{cases}$$

中学: $x_3=1, x_4=0$;大学: $x_3=0, x_4=1$;研究生: $x_3=0, x_4=0$

假设

- 资历每加一年薪金的增长是常数(资历对薪金的作用是线性的);
- 管理、教育、资历之间无交互作用.


线性回归模型 $y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_3 + \beta_4 x_4$ 由数据确定 $\hat{\beta}_0, \hat{\beta}_1, \hat{\beta}_2, \hat{\beta}_3$

例4 酶促反应

酶~高效生物催化剂; 酶促反应~经过酶催化的化学反应

酶促反应的反应速度主要取决于反应物（底物）的浓度:

- 底物浓度较小时，反应速度大致与浓度成正比;
- 底物浓度很大、渐进饱和时，反应速度趋于固定值.





例4 酶促反应

为研究酶促反应中嘌呤霉素对反应速度与底物浓度之间关系的影响, 设计了两个实验: 使用的酶经过嘌呤霉素处理; 使用的酶未经嘌呤霉素处理。


实验数据

底物浓度(ppm)		0.02		0.06		0.11		0.22		0.56		1.10	
反应速度	处理	76	47	97	107	123	139	159	152	191	201	207	200
	未处理	67	51	84	86	98	115	131	124	144	158	160	/

对未经嘌呤霉素处理的反应, 用实验数据估计参数 β_1, β_2 ; 用实验数据研究嘌呤霉素处理对参数 β_1, β_2 的影响。


模型 $y = \frac{\beta_1 x}{\beta_2 + x} \Rightarrow \frac{1}{y} = \frac{1}{\beta_1} + \frac{\beta_2}{\beta_1} \frac{1}{x} = \theta_1 + \theta_2 \frac{1}{x}$

对 β_1, β_2 非线性 对 θ_1, θ_2 线性



$1/x$ 较小时有很好的线性趋势,
 $1/x$ 较大时出现很大的分散.

$\theta_1 = 6.972 \times 10^{-3}, \theta_2 = 0.215 \times 10^{-3} \Rightarrow \beta_1 = 143.43, \beta_2 = 0.0308$




x 较大时, y 有较大偏差.
 参数估计时, x 较小 ($1/x$ 很大)
 的数据控制了参数的确定.

拟合欠佳, 直接考虑非线性模型


一元线性回归分析

问题 已知一组数据 $(x_i, y_i), i=1, 2, \dots, n$ (平面上的 n 个点), 用最小二乘准则确定一个线性函数(直线) $y = \beta_0 + \beta_1 x$

1. 血压与年龄



2. 合金强度与碳含量



系数的计算二者没有什么区别; 2的拟合效果比1好得多.

怎样衡量由最小二乘准则拟合得到的模型的可靠程度?

怎样给出模型系数的置信区间和因变量的预测区间?

一元线性回归模型

$$y = \beta_0 + \beta_1 x + \varepsilon$$

x ~自变量 β_0, β_1 ~回归系数

ε ~随机变量(影响 y 的随机因素的总和)

基本假设


独立性: 对于不同的 x , y 相互独立

线性性: y 的期望是 x 的线性函数

齐次性: 对于不同的 x , y 的方差是常数

正态性: 对于给定的 x , y 服从正态分布

ε 是相互独立的、期望为0、方差为 σ^2 、正态分布的随机变量, 即 $\varepsilon \sim N(0, \sigma^2)$, ε 称(随机)误差。



回归系数的最小二乘估计

数据 $x_i, y_i (i=1, \dots, n)$ 代入 $y = \beta_0 + \beta_1 x + \varepsilon \iff y_i = \beta_0 + \beta_1 x_i + \varepsilon_i$

误差平方和 $Q(\beta_0, \beta_1) = \sum_{i=1}^n \varepsilon_i^2 = \sum_{i=1}^n [y_i - (\beta_0 + \beta_1 x_i)]^2$

$$\frac{\partial Q}{\partial \beta_0} = 0, \frac{\partial Q}{\partial \beta_1} = 0 \iff \hat{\beta}_1 = \frac{s_{xy}}{s_{xx}}, \quad \hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$$

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i, \quad \bar{y} = \frac{1}{n} \sum_{i=1}^n y_i, \quad s_{xx} = \sum_{i=1}^n (x_i - \bar{x})^2, \quad s_{xy} = \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})$$

直线 $y = \hat{\beta}_0 + \hat{\beta}_1 x$ 通过 x_i, y_i 的均值点 $(\bar{x}, \bar{y})$

最小二乘估计

线性无偏最小方差估计

一元线性回归的统计分析

1. 误差方差 $D\varepsilon = \sigma^2$ 的估计

$$y_i = \beta_0 + \beta_1 x_i + \varepsilon_i$$

$$\hat{y}_i = \hat{\beta}_0 + \hat{\beta}_1 x_i, i = 1, 2, \dots, n \quad y_i \text{ 理论值(期望)的估计}$$

$$\hat{\varepsilon}_i = y_i - \hat{y}_i, i = 1, 2, \dots, n \quad \text{误差} \varepsilon_i \text{ 的估计, 称残差(记作 } e_i \text{)}$$

$$\text{残差平方和} \quad Q = \sum_{i=1}^n e_i^2 = \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

$$\sigma^2 \text{ 的无偏估计} \quad s^2 = \hat{\sigma}^2 = \frac{Q}{n-2}$$

$n-2 \sim Q$ 的自由度 = 数据容量 - 模型中所含参数的个数

$s^2 \sim$ 剩余方差(样本方差), $s \sim$ 剩余标准差(样本标准差)

一元线性回归的统计分析

2. 回归系数的区间估计和假设检验

统计性质: $\hat{\beta}_1 \sim N(\beta_1, \sigma^2 / s_{xx})$, $Q / \sigma^2 \sim \chi_{(n-2)}^2$, $\hat{\beta}_1$ 和 Q 相互独立

t 分布
$$t = \frac{(\hat{\beta}_1 - \beta_1) \sqrt{s_{xx}} / \sigma}{\sqrt{Q / (n-2) \sigma^2}} = \frac{(\hat{\beta}_1 - \beta_1) \sqrt{s_{xx}}}{s} \sim t_{(n-2)}$$

β_1 的置信区间
$$\left[\hat{\beta}_1 - t_{(n-2), 1-\alpha/2} \frac{s}{\sqrt{s_{xx}}}, \hat{\beta}_1 + t_{(n-2), 1-\alpha/2} \frac{s}{\sqrt{s_{xx}}} \right]$$

问: 怎样缩短 β_1 的置信区间? s 越小, s_{xx} 越大

对 β_1 的假设检验 $H_0 : \beta_1 = 0, H_1 : \beta_1 \neq 0$

$|t| = \left| \frac{\hat{\beta}_1 \sqrt{s_{xx}}}{s} \right| > t_{(n-2), 1-\alpha/2} \Rightarrow \text{拒绝 } H_0 \Rightarrow \text{回归模型有效} \Rightarrow \beta_1 \text{ 的置信区间不包含零点}$

一元线性回归的统计分析

3.模型的有效性检验 偏差的分解: $y_i - \bar{y} = (y_i - \hat{y}_i) + (\hat{y}_i - \bar{y})$

$$\sum_{i=1}^n \underbrace{(y_i - \bar{y})^2}_S = \sum_{i=1}^n \underbrace{(y_i - \hat{y}_i)^2}_Q + \sum_{i=1}^n \underbrace{(\hat{y}_i - \bar{y})^2}_U$$

总偏差平方和

残差平方和

回归平方和

决定系数 $R^2 = U/S$ 因变量的总变化中自变量引起的部分的比例

$$\hat{y}_i = \hat{\beta}_0 + \hat{\beta}_1 x_i \quad \bar{y} = \hat{\beta}_0 + \hat{\beta}_1 \bar{x} \quad U = \hat{\beta}_1^2 \sum_{i=1}^n (x_i - \bar{x})^2 = \hat{\beta}_1^2 s_{xx}$$

若 H_0 成立 $U/\sigma^2 = \hat{\beta}_1^2 s_{xx}/\sigma^2 \sim \chi_{(1)}^2$

$$Q/\sigma^2 \sim \chi_{(n-2)}^2,$$

$$F = \frac{U}{Q/(n-2)} \sim F_{(1,n-2)}$$

给定 α , 有 $F_{(1,n-2), 1-\alpha}$

$$F > F_{(1,n-2), 1-\alpha}$$

拒绝 H_0 回归模型有效

利用一元线性回归模型进行预测

x_0 给定, y_0 的预测值: $\hat{y}_0 = \hat{\beta}_0 + \hat{\beta}_1 x_0$


性质: $\hat{y}_0$ 无偏, 且 $E(\hat{y}_0 - y_0)^2$ 最小

预测
区间

$$[\hat{y}_0 - t_{(n-2), 1-\alpha/2} s \sqrt{\frac{(x_0 - \bar{x})^2}{s_{xx}} + \frac{1}{n}} + 1, \hat{y}_0 + t_{(n-2), 1-\alpha/2} s \sqrt{\frac{(x_0 - \bar{x})^2}{s_{xx}} + \frac{1}{n}} + 1]$$

$s \sim$ 剩余标准差

n 很大且 x_0 接近 $\bar{x}$



$$[\hat{y}_0 - u_{1-\alpha/2} s, \hat{y}_0 + u_{1-\alpha/2} s]$$

$$\delta(x) = t_{(n-2), 1-\alpha/2} s \sqrt{\frac{(x - \bar{x})^2}{s_{xx}} + \frac{1}{n}} + 1 \approx u_{1-\alpha/2} s$$

一元线性回归的MATLAB实现

`b=regress(y,X)`

`[b,bint,r,rint,s]=regress(y,X,alpha)`

输入： y ~因变量（列向量）， X ~1与自变量组成的矩阵， α ~显著性水平 α （缺省时设定为0.05）

输出： $b = (\hat{\beta}_0, \hat{\beta}_1)$ ， $bint$ ~ β_0, β_1 的置信区间， r ~残差（列向量）， $rint$ ~残差的置信区间，

s (4个统计量)：决定系数 R^2 ； F 值； $F_{(1,n-2)}$ 分布大于 F 值的概率 p ，当 $p < \alpha$ 时拒绝 H_0 ，回归模型有效；剩余方差 s^2 。

注意 `regress` 与 `polyfit` 用法的区别

例1 血压与年龄 模型 $y = \beta_0 + \beta_1 x$ 数据


回归系数	回归系数估计值	回归系数置信区间
β_0	98.4084	[78.7484 118.0683]
β_1	0.9732	[0.5601 1.3864]
$R^2=0.4540$ $F=23.2834$ $p<0.0001$ $s^2 = 273.7137$		

模型检验 β_1 置信区间不含零点； $p<\alpha$ ； $F_{(1,n-2), 1-\alpha} = 4.1960 < F$
 β_1 置信区间较长， R^2 较小，模型精度不高。



xueya1.m

残差及其置信区间




(x_2, y_2) 残差的置信区间不包含零点，因为残差应服从均值为0的正态分布，它偏离数据整体的变化趋势，称为**异常点**或**离群点**，应予以剔除。

由残差图剔除异常数据后

回归系数	回归系数估计值	回归系数置信区间
β_0	96.8665	[85.4771 108.2559]
β_1	0.9533	[0.7140 1.1925]
$R^2=0.7123$ $F=66.8358$ $p<0.0001$ $s^2=91.4305$		

残差及其置信区间

剔除 (x_2, y_2) 的残差及其置信区间

将回归系数代入，对50岁人的血压进行预测：

$$\hat{y}_0 = \hat{\beta}_0 + \hat{\beta}_1 x_0 = 144.5298$$

预测区间 ($\alpha=0.05$) :

$$[124.5406 \quad 164.5190]$$

简化 ($t \rightarrow u$) :

$$[125.7887 \quad 163.2708]$$

例2:

合金的强度 y 与其中的碳含量 x

$y/(\text{kg}/\text{mm}^2)$	41.0	42.5	45.0	45.5	45.0	47.5
$x/\%$	0.10	0.11	0.12	0.13	0.14	0.15
$y/(\text{kg}/\text{mm}^2)$	49.0	51.0	50.0	55.0	57.5	59.5
$x/\%$	0.16	0.17	0.18	0.20	0.22	0.24



hejin.m

计算结果如下:

回归系数	回归系数估计值	回归系数置信区间
β_0	27.9473	[25.7205 30.1741]
β_1	131.8396	[118.3788 145.3005]
$R^2=0.9794 \quad F=476.2462 \quad p<0.0001 \quad s^2=0.7737$		

显然这个结果不仅能通过模型有效性检验，而且可以知道模型的精度比例1高。

MATLAB实现:

```
y=[144 215 138 145 162 142 170 124 158 154 162 150 140 110 128 130  
135 114 116 124 136 142 120 120 160 158 144 130 125 175];  
x=[39 47 45 47 65 46 67 42 67 56 64 56 59 34 42 48 45 18 20 19 36 50 39  
21 44 53 63 29 25 69];  
n=length(y);  
X=[ones(n,1), x']; % 1与自变量组成的输入矩阵  
[b,bint,r,rint,s]=regress(y',X); %回归分析程序  
b,bint,s,s2=sum(r.^2)/(n-2)  
rcoplot(r,rint) %绘制带置信区间的残差误差棒图  
pause  
y=[y(1) y(3:30)];  
x=[x(1) x(3:30)];  
n=length(y);  
X=[ones(n,1) x'];  
[b,bint,r,rint,s]=regress(y',X);  
b,bint,s,s2=sum(r.^2)/(n-2)  
rcoplot(r,rint)  
pause
```

```
y0=b(1)+b(2)*50; % 预测y(x=50)
xb=mean(x);
sxx=sum((x-xb).^2);
a=sqrt((50-xb)^2/sxx+1/n+1);
t=tinvt(0.975,n-2);
d=t*a*sqrt(s2);
y1=y0-d;y2=y0+d; % 预测y(x=50)区间 (t分布)
[y0 y1 y2]
d1=norminv(0.975)*sqrt(s2);
y3=y0-d1;y4=y0+d1;
[y0 y3 y4] % 预测y(x=50)区间 (N分布)
```

多元线性回归分析

模型

$$y = \beta_0 + \beta_1 x_1 + \cdots + \beta_m x_m + \varepsilon, \quad \varepsilon \sim N(0, \sigma^2)$$

估计回归系数

$$\Downarrow (y_i, x_{i1}, \cdots x_{im}), \quad i = 1, \cdots n, \quad n > m$$

$$y_i = \beta_0 + \beta_1 x_{i1} + \cdots + \beta_m x_{im} + \varepsilon_i, \quad \varepsilon_i \sim N(0, \sigma^2), \quad i = 1, \cdots n$$

$$X = \begin{bmatrix} 1 & x_{11} & \cdots & x_{1m} \\ \cdots & \cdots & \cdots & \cdots \\ 1 & x_{n1} & \cdots & x_{nm} \end{bmatrix}, \quad Y = \begin{bmatrix} y_1 \\ \cdots \\ y_n \end{bmatrix}, \quad \varepsilon = \begin{bmatrix} \varepsilon_1 \\ \cdots \\ \varepsilon_n \end{bmatrix}, \quad \beta = [\beta_0, \beta_1, \cdots \beta_m]^T$$

$$\Downarrow \begin{cases} Y = X\beta + \varepsilon \\ \varepsilon \sim N(0, \sigma^2) \end{cases}$$

$$Q(\beta) = \sum_{i=1}^n \varepsilon_i^2 = (Y - X\beta)^T (Y - X\beta)$$

$$\frac{\partial Q}{\partial \beta_i} = 0, \quad i = 0, 1, \cdots m$$

$$\square X^T (Y - X\beta) = 0 \quad \square \hat{\beta} = (X^T X)^{-1} X^T Y \quad \text{最小二乘估计}$$

思考

怎样保证 $X^T X$ 可逆为什么要求 $n > m$

多元线性回归的统计分析

1. 误差方差 σ^2 的估计

一元回归

多元回归

模型

$$y = \beta_0 + \beta_1 x_1 + \varepsilon$$

$$y = \beta_0 + \beta_1 x_1 + \cdots + \beta_m x_m + \varepsilon$$

估计值

$$\hat{y}_i = \hat{\beta}_0 + \hat{\beta}_1 x_i$$

$$\hat{y}_i = \hat{\beta}_0 + \hat{\beta}_1 x_{1i} + \cdots + \hat{\beta}_m x_{mi}$$

残差

$$e_i = \hat{\varepsilon}_i = y_i - \hat{y}_i$$

$$e_i = \hat{\varepsilon}_i = y_i - \hat{y}_i$$

残差平方和

$$Q = \sum_{i=1}^n e_i^2 = \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

$$Q = \sum_{i=1}^n e_i^2 = \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

剩余方差

$$s^2 = \hat{\sigma}^2 = \frac{Q}{n-2}$$

$$s^2 = \hat{\sigma}^2 = \frac{Q}{n-m-1}$$

Q的自由度

n-2 (2个参数)

n-(m+1) (m+1个参数)

2. 回归系数的区间估计和假设检验

一元回归

$$\hat{\beta}_1 \sim N(\beta_1, \sigma^2 / s_{xx}), \quad s_{xx} = \sum_{i=1}^n (x_i - \bar{x})^2$$

$$Q / \sigma^2 \sim \chi_{(n-2)}^2,$$

$$t = \frac{(\hat{\beta}_1 - \beta_1) \sqrt{s_{xx}} / \sigma}{\sqrt{Q / (n-2) \sigma^2}} = \frac{(\hat{\beta}_1 - \beta_1) \sqrt{s_{xx}}}{s} \sim t_{(n-2)}$$

$$[\hat{\beta}_1 - t_{(n-2), 1-\alpha/2} \frac{s}{\sqrt{s_{xx}}}, \hat{\beta}_1 + t_{(n-2), 1-\alpha/2} \frac{s}{\sqrt{s_{xx}}}]$$

$$H_0 : \beta_1 = 0, \quad H_1 : \beta_1 \neq 0$$

$$|t| = \left| \frac{\hat{\beta}_1 \sqrt{s_{xx}}}{s} \right| > t_{(n-2), 1-\alpha/2}$$

拒绝 H_0 , 模型有效

多元回归

$$\hat{\beta}_j \sim N(\beta_j, \sigma^2 c_{jj}), \quad c_{jj} \sim (\tilde{X}^T \tilde{X})^{-1}$$

的 j 对角元

$$Q / \sigma^2 \sim \chi_{(n-m-1)}^2$$

$$t_j = \frac{(\hat{\beta}_j - \beta_j) / \sigma \sqrt{c_{jj}}}{\sqrt{Q / (n-m-1) \sigma^2}} = \frac{\hat{\beta}_j - \beta_j}{s \sqrt{c_{jj}}} \sim t_{(n-2)}$$

$$[\hat{\beta}_j - t_{(n-2), 1-\alpha/2} s \sqrt{c_{jj}}, \hat{\beta}_j + t_{(n-2), 1-\alpha/2} s \sqrt{c_{jj}}]$$

$$H_0^{(j)} : \beta_j = 0, \quad H_1^{(j)} : \beta_j \neq 0$$

$$|t_j| = \left| \frac{\hat{\beta}_j}{s \sqrt{c_{jj}}} \right| > t_{(n-2), 1-\alpha/2}$$

3. 模型的有效性检验

一元回归

多元回归

偏差分解

$$S = U + Q$$

$$S = U + Q$$

决定系数

$$R^2 = U / S$$

$$R^2 = U / S$$

$$H_0 : \beta_1 = 0, \quad H_1 : \beta_1 \neq 0$$

$$H_0^{(j)} : \beta_j = 0, \quad H_1^{(j)} : \beta_j \neq 0$$

$$H_0 \text{ 成立} \quad U / \sigma^2 \sim \chi_{(1)}^2, \quad Q / \sigma^2 \sim \chi_{(n-2)}^2,$$

$$U / \sigma^2 \sim \chi_{(m)}^2, \quad Q / \sigma^2 \sim \chi_{(n-m-1)}^2$$

$$F = \frac{U}{Q/(n-2)} \sim F_{(1, n-2)}$$

$$F = \frac{U/m}{Q/(n-m-1)} \sim F_{(m, n-m-1)}$$

检验

$$F > F_{(1, n-2), 1-\alpha}$$

$$F_{(m, n-m-1), 1-\alpha}$$



拒绝 H_0 , 模型有效

利用多元线性回归模型进行预测

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x_1 + \cdots + \hat{\beta}_m x_m$$

性质: $\hat{y}_0$ 无偏, 且 $E(\hat{y}_0 - y_0)^2$ 最小

预测区间 $[\hat{y} - \delta(x), \hat{y} + \delta(x)]$

$$\delta(x) = t_{(n-2), 1-\alpha/2} s \sqrt{(x - \bar{x})^T (\tilde{X}^T \tilde{X})^{-1} (x - \bar{x}) + \frac{1}{n} + 1} \approx u_{1-\alpha/2} s$$

与一元回归对比

$$\delta(x) = t_{(n-2), 1-\alpha/2} s \sqrt{\frac{(x - \bar{x})^2}{s_{xx}} + \frac{1}{n} + 1} \approx u_{1-\alpha/2} s$$

多元线性回归的MATLAB实现

与一元回归相同 `b=regress(y,X)` % 注意 X 的构造

`[b,bint,r,rint,s]=regress(y,X,alpha)`

例2 血压与年龄、体重指数、吸烟习惯




$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_3$$


计算结果如下：

xueya2.m

回归系数	回归系数估计值	回归系数置信区间
β_0	45.3636	[3.5537 87.1736]
β_1	0.3604	[-0.0758 0.7965]
β_2	3.0906	[1.0530 5.1281]
β_3	11.8246	[-0.1482 23.7973]
$R^2 = 0.6855$ $F = 18.8906$ $p < 0.0001$ $s^2 = 169.7917$		



剔除两个
异常点



回归系数	回归系数估计值	回归系数置信区间
β_0	58.5101	[29.9064 87.1138]
β_1	0.4303	[0.1273 0.7332]
β_2	2.3449	[0.8509 3.8389]
β_3	10.3065	[3.3878 17.2253]
$R^2= 0.8462 \quad F= 44.0087 \quad p<0.0001 \quad s^2=53.6604$		

预测模型为:

$$\hat{y} = 58.5101 + 0.4303x_1 + 2.3449x_2 + 10.3065x_3$$

- 年龄和体重指数相同，吸烟者比不吸烟者的血压高10.3.
- 与例1“血压与年龄”的结果 $\hat{y} = 96.8665 + 0.9533x_1$ 相比，年龄增加1岁血压的升高值(即 β_1)为何有这么大的差别.
- 对50岁、体重指数25的吸烟者的血压作预测：将 $x_1=50$ ， $x_2=25$ ， $x_3=1$ 代入上面的预测模型得 $\hat{y}=148.9525$ ，在 $\alpha=0.05$ 下计算的预测区间为 $[133.1716, 164.7334]$ ，按照简化式计算的预测区间为 $[134.5951, 163.3099]$.

MATLAB实现:

```
y=[144 215 138 145 162 142 170 124 158 154 162 150 140 110 128  
130 135 114 116 124 136 142 120 120 160 158 144 130 125 175];  
x1=[39 47 45 47 65 46 67 42 67 56 64 56 59 34 42 48 45 18 20 19  
36 50 39 21 44 53 63 29 25 69];  
x2=[24.2 31.1 22.6 24.0 25.9 25.1 29.5 19.7 27.2 19.3 28.0 25.8  
27.3 20.1 21.7 22.2 27.4 18.8 22.6 21.5 25.0 26.2 23.5 20.3 27.1  
28.6 28.3 22.0 25.3 27.4];  
x3=[0 1 0 1 1 0 1 0 1 0 1 0 0 0 0 1 0 0 0 0 0 1 0 0 1 1 0 1 0 1];  
n=length(y);  
X=[ones(n,1), x1',x2',x3']; %注意X的构造  
[b,bint,r,rint,s]=regress(y',X);  
s2=sum(r.^2)/(n-4);  
b,bint,s,s2  
rcoplot(r,rint)  
pause
```

```
y=[y(1) y(3:9) y(11:30)]; % 剔除两个异常数据
x1=[x1(1) x1(3:9) x1(11:30)];
x2=[x2(1) x2(3:9) x2(11:30)];
x3=[x3(1) x3(3:9) x3(11:30)];
n=length(y);
X=[ones(n,1), x1',x2',x3'];
[b,bint,r,rint,s]=regress(y',X);
s2=sum(r.^2)/(n-4);
b,bint,s,s2
rcoplot(r,rint)
pause
```

```
y0=[1,50,25,1]*b; % 预测值
x11=x1-mean(x1);x22=x2-mean(x2);x33=x3-
mean(x3);
XX=[x11',x22',x33'];L=inv(XX'*XX);
x=[50,25,1];xb=[mean(x1),mean(x2),mean(x3)];
a=sqrt((x-xb)*L*(x-xb)'+1/n+1);
t=tinv(0.975,n-2);
d=t*a*sqrt(s2);
y1=y0-d;y2=y0+d;
yt=[y1,y0,y2] % 预测区间 (t分布)
dd=norminv(0.975)*sqrt(s2);
y3=y0-dd;y4=y0+dd;
yn=[y3,y0,y4] % 预测区间 (N分布)
```

线性最小二乘拟合与多元线性回归的一般形式

线性回归模型 $y = \beta_0 + \beta_1 x_1 + \cdots + \beta_m x_m + \varepsilon, \varepsilon \sim N(0, \sigma^2)$ (1)

“线性”是指 y 是系数 β 的关系(非指 y 与 x 的关系)

$$y = \beta_0 + \beta_1 x^2, \quad y = \beta_0 + \beta_1 e^{x_1} + \beta_2 / x_2 \quad \sim \text{线性回归}$$

线性回归
一般形式

$$y = \beta_0 + \beta_1 r_1(x) + \cdots + \beta_m r_m(x) + \varepsilon, \varepsilon \sim N(0, \sigma^2) \quad (2)$$

$x = (x_1, \cdots, x_k)$, $r_j(x) (j = 1, \cdots, m)$ 是已知函数

令 $r_j(x) = u_j$, 则(2) $\rightarrow$ (1)

实验作业：

1、用切削机床加工时，为实时地调整机床需测定刀具的磨损速度，每隔一小时测量刀具的厚度得到以下数据，建立刀具厚度对于切削时间的回归模型，对模型和回归系数进行检验，并预测7.5h和15h后的刀具厚度，同时计算预测区间，解释计算结果。

时间/h	0	1	2	3	4	5	6	7	8	9	10
刀具厚度/cm	30.6	29.1	28.4	28.1	28.0	27.7	27.5	27.2	27.0	26.8	26.5

2、电影院调查电视广告费用和报纸广告费用对每周收入的影响，得到下面的数据，建立回归模型并进行检验，诊断异常点的存在并进行处理。

每周收入	96	90	95	92	95	95	94	94
电视广告费用	1.5	2.0	1.5	2.5	3.3	2.3	4.2	2.5
报纸广告费用	5.0	2.0	4.0	2.5	3.0	3.5	2.5	3.0

例3 软件开发人员的薪金

建立模型研究薪金与资历、管理责任、教育程度的关系，分析人事策略的合理性，作为新聘用人员薪金的参考。

46名软件开发人员的档案资料

编号	薪金	资历	管理	教育	编号	薪金	资历	管理	教育
01	13876	1	1	1	42	27837	16	1	2
02	11608	1	0	3	43	18838	16	0	2
03	18701	1	1	3	44	17483	16	0	1
04	11283	1	0	2	45	19207	17	0	2
05	11767	1	0	3	46	19346	20	0	1

资历~ 从事专业工作的年数；管理~ 1=管理人员，0=非管理人员；教育~ 1=中学，2=大学，3=研究生

多元线性回归中的交互作用

例3 软件开发人员的薪金 $y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_3 + \beta_4 x_4$

$y \sim$ 薪金, $x_1 \sim$ 资历, $x_2 = 1 \sim$ 管理人员, $x_2 = 0 \sim$ 非管理人员

$x_3 = 1, x_4 = 0 \sim$ 中学; $x_3 = 0, x_4 = 1 \sim$ 大学; $x_3 = 0, x_4 = 0 \sim$ 研究生

```
M=dlmread('xinjindata.m');
n=46; x1=M(:,3); x2=M(:,4); x3=M(:,6); x4=M(:,7);
y=M(:,2);
x=[ones(n,1) x1 x2 x3 x4 ];
[b,bi,r,ri,s]=regress(y,x);
s2=sum(r.^2)/(n-5);
b,bi,s,s2
pause
plot(x1,r,'+') %%残差e与x1(资历)的散点图
pause
xx=M(:,8);
plot(xx,r,'+') %%残差e与组合x2~x4(管理-教育水平)的散点图
```



xinjindata.m



xinjin1.m

46x8 double

	1	2	3	4	5	6	7	8
1	1	13876	1	1	1	1	0	2
2	2	11608	1	0	3	0	0	5
3	3	18701	1	1	3	0	0	6
4	4	11283	1	0	2	0	1	3
5	5	11767	1	0	3	0	0	5
6	6	20872	2	1	2	0	1	4
7	7	11772	2	0	2	0	1	3
8	8	10535	2	0	1	1	0	1
9	9	12195	2	0	3	0	0	5
10	10	12313	3	0	2	0	1	3
11	11	14975	3	1	1	1	0	2
12	12	21371	3	1	2	0	1	4
13	13	19800	3	1	3	0	0	6
14	14	11417	4	0	1	1	0	1
15	15	20263	4	1	3	0	0	6
16	16	13231	4	0	3	0	0	5
17	17	12884	4	0	2	0	1	3
18	18	13245	5	0	2	0	1	3
19	19	13677	5	0	3	0	0	5
20	20	15965	5	1	1	1	0	2
21	21	12366	6	0	1	1	0	1
22	22	21352	6	1	3	0	0	6
23	23	13839	6	0	2	0	1	3
24	24	22884	6	1	2	0	1	4
25	25	16978	7	1	1	1	0	2



xinjindata.m

46x8 double

	1	2	3	4	5	6	7	8
26	26	14803	8	0	2	0	1	3
27	27	17404	8	1	1	1	0	2
28	28	22184	8	1	3	0	0	6
29	29	13548	8	0	1	1	0	1
30	30	14467	10	0	1	1	0	1
31	31	15942	10	0	2	0	1	3
32	32	23174	10	1	3	0	0	6
33	33	23780	10	1	2	0	1	4
34	34	25410	11	1	2	0	1	4
35	35	14861	11	0	1	1	0	1
36	36	16882	12	0	2	0	1	3
37	37	24170	12	1	3	0	0	6
38	38	15990	13	0	1	1	0	1
39	39	26330	13	1	2	0	1	4
40	40	17949	14	0	2	0	1	3
41	41	25685	15	1	3	0	0	6
42	42	27837	16	1	2	0	1	4
43	43	18838	16	0	2	0	1	3
44	44	17483	16	0	1	1	0	1
45	45	19207	17	0	2	0	1	3
46	46	19346	20	0	1	1	0	1

多元线性回归中的交互作用

例3 软件开发人员的薪金 $y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_3 + \beta_4 x_4$

y ~薪金, x_1 ~资历, $x_2=1$ ~ 管理人员, $x_2=0$ ~ 非管理人员

$x_3=1, x_4=0$ ~中学; $x_3=0, x_4=1$ ~大学; $x_3=0, x_4=0$ ~研究生

系数	系数估计	置信区间
β_0	11032	[10258 11807]
β_1	546	[484 608]
β_2	6883	[6248 7517]
β_3	-2994	[-3826 -2162]
β_4	148	[-636 931]
$R^2=0.957 \quad F=226 \quad p=0.000$		

$R^2, F, p \rightarrow$ 模型整体上可用

资历增加1年

薪金增长546

管理人员多6883

中学程度比更高的少2994

大学程度比更高的多148

β_4 置信区间包含零点,
解释不可靠!

用残差分析发现交互作用


$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x_1 + \hat{\beta}_2 x_2 + \hat{\beta}_3 x_3 + \hat{\beta}_4 x_4$$

考察残差 $e = y - \hat{y}$ 是否为 $N(0, \sigma^2)$

管理与教育的组合


组合	1	2	3	4	5	6
管理	0	1	0	1	0	1
教育	1	1	2	2	3	3

e 与资历 x_1 的关系



残差大概分成3个水平，
6种管理—教育组合混在一起，未正确反映

e 与管理—教育组合的关系



残差全为正，或全为负，
管理—教育组合处理不当
应增加 x_2 与 x_3, x_4 的交互项

增加管理 x_2 与教育 x_3, x_4 的交互项

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_3 + \beta_4 x_4 + \beta_5 x_2 x_3 + \beta_6 x_2 x_4 + \varepsilon$$





xinjin2.m

```
M=dlmread('xinjindata.m');  
y=M(:,2); x1=M(:,3); x2=M(:,4); x3=M(:,6);  
x4=M(:,7);  
x5=x2.*x3;  
x6=x2.*x4;  
n=length(y);  
x=[ones(n,1) x1 x2 x3 x4 x5 x6];  
[b,bi,r,ri,s]=regress(y,x);  
s2=sum(r.^2)/(n-7);  
b,bi,s,s2  
pause  
plot(x1,r,'+'),  
pause  
xx=M(:,8);  
plot(xx,r,'+')
```


增加管理 x_2 与教育 x_3, x_4 的交互项

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_3 + \beta_4 x_4 + \beta_5 x_2 x_3 + \beta_6 x_2 x_4 + \varepsilon$$

系数	系数估计值	置信区间
β_0	11204	[11044 11363]
β_1	497	[486 508]
β_2	7048	[6841 7255]
β_3	-1727	[-1939 -1514]
β_4	-348	[-545 -152]
β_5	-3071	[-3372 -2769]
β_6	1836	[1571 2101]
$R^2=0.999 \quad F=554 \quad p=0.000$		



R^2, F 有改进，所有回归系数置信区间都不含零点，模型完全可用

消除了不正常现象

异常数据(33号)应去掉

去掉异常数据后的结果



xinjin3.m

```
M=dlmread('xinjindata.m');  
M=[M(1:32,:);M(34:46,:)]; %%剔除了33号数据  
y=M(:,2);  
x1=M(:,3);  
x2=M(:,4);  
x3=M(:,6);  
x4=M(:,7);  
x5=x2.*x3;  
x6=x2.*x4;  
n=length(y);  
x=[ones(n,1) x1 x2 x3 x4 x5 x6];  
[b,bi,r,ri,s]=regress(y,x);  
s2=sum(r.^2)/(n-7);  
b,bi,s,s2  
pause  
plot(x1,r,'+'),  
pause  
xx=M(:,8);  
plot(xx,r,'+')
```




去掉异常数据后的结果

系数	系数估计值	置信区间
β_0	11200	[11139 11261]
β_1	498	[494 503]
β_2	7041	[6962 7120]
β_3	-1737	[-1818 -1656]
β_4	-356	[-431 -281]
β_5	-3056	[-3171 -2942]
β_6	1997	[1894 2100]
$R^2= 0.9998 \quad F=36701 \quad p=0.0000$		

$R^2: 0.957 \rightarrow 0.999 \rightarrow 0.9998$

$F: 226 \rightarrow 554 \rightarrow 36701$

置信区间长度更短



残差图十分正常

最终模型的结果可以应用

模型应用 $\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x_1 + \hat{\beta}_2 x_2 + \hat{\beta}_3 x_3 + \hat{\beta}_4 x_4 + \hat{\beta}_5 x_2 x_3 + \hat{\beta}_6 x_2 x_4$

制订6种管理—教育组合人员的“基础”薪金(资历 $x_1=0$)

组合	管理 x_2	教育 (x_3, x_4)	系数	“基础”薪金
1	0	(1,0)	$\beta_0 + \beta_3$	9463
2	1	(1,0)	$\beta_0 + \beta_2 + \beta_3 + \beta_5$	13448
3	0	(0,1)	$\beta_0 + \beta_4$	10844
4	1	(0,1)	$\beta_0 + \beta_2 + \beta_4 + \beta_6$	19882
5	0	(0,0)	β_0	11200
6	1	(0,0)	$\beta_0 + \beta_2$	18241


大学程度管理人员比更高程度管理人员的薪金高

大学程度非管理人员比更高程度非管理人员的薪金略低

线性回归的特殊情形----多项式回归

例1 西红柿的施肥量与产量 14块同样大小土地的数据

序号	产量(升)	施肥(千克)	序号	产量(升)	施肥(千克)
1	1035	6.0	...	...	...
2	624	2.5	12	1030	9.0
3	1084	7.5	13	985	11.0
...	...	...	14	855	12.5



模型 $y = \beta_0 + \beta_1 x + \beta_2 x^2 + \varepsilon$

b=regress(y,X)求解

$$\hat{y} = 175.62 + 217.87x - 13.15x^2$$

一元多项式回归模型的一般形式

$$y = \beta_0 + \beta_1 x + \cdots + \beta_m x^m + \varepsilon$$




xihongshi.m

MATLAB求解

- regress(y,X)
- polyfit(x,y,m)
- polytool(x,y,m,alpha)

注意3个程序的用法与所得结果的相同点和不同点

例1的交互式画面



MATLAB实现:

```
y=[1035 624 1084 1052 1015 1066 704 960 990 1050 839 1030 985 855];
x=[6.0000 2.5000 7.5000 8.5000 10.0000 7.0000 3.0000 11.5000 5.5000 6.5000
4.0000 9.0000 11.0000 12.5000];
```

```
plot(x,y,'+'),
```

```
pause
```

```
x2=x.^2;
```

```
X=[ones(14,1) x' x2'];
```

```
[b,bi,r,ri,s]=regress(y',X);
```

```
b,bi,s,
```

```
pause
```

```
xx=2:.1:13;
```

```
yy=b(1)+b(2)*xx+b(3)*xx.^2;
```


```
plot(x,y,'+',xx,yy),grid,
```

```
pause
```

```
a=polyfit(x,y,2)
```

% 注意与 regress 的区别

```
polytool(x,y,2)
```



例2 商品销售量与价格

某厂生产的一种电器的销售量 y 与竞争对手的价格 x_1 和本厂的价格 x_2 有关。



下表是该商品在10个城市的销售记录。

x_1 (元)	120	140	190	130	155	175	125	145	180	150
x_2 (元)	100	110	90	150	210	150	250	270	300	250
y (个)	102	100	120	77	46	93	26	69	65	85

(1) 根据这些数据建立 y 与 x_1 和 x_2 的关系式，对得到的模型和系数进行检验。

(2) 若某市本厂产品售价160元，竞争对手售价170元，预测该市的销售量。

例2 商品销售量与价格



y 与 x_2 有较明显的线性关系， y 与 x_1 的关系难以确定。
需要试验不同的回归模型，用统计分析决定优劣。

线性模型 $y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \varepsilon$

$n=10$;

$x1=[120 \ 140 \ 190 \ 130 \ 155 \ 175 \ 125 \ 145 \ 180 \ 150]$;

$x2=[100 \ 110 \ 90 \ 150 \ 210 \ 150 \ 250 \ 270 \ 300 \ 250]$;

$y=[102 \ 100 \ 120 \ 77 \ 46 \ 93 \ 26 \ 69 \ 65 \ 85]$;



$x=[\text{ones}(n,1) \ x1' \ x2']$;

$[b,bi,r,ri,s]=\text{regress}(y',x)$;



shangpin.m

例2 商品销售量与价格



y 与 x_2 有较明显的线性关系， y 与 x_1 的关系难以确定。
需要试验不同的回归模型，用统计分析决定优劣。

线性模型 $y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \varepsilon$

系数	系数估计	置信区间
β_0	66.5176	[-32.5060 165.5411]
β_1	0.4139	[-0.2018 1.0296]
β_2	-0.2698	[-0.4611 -0.0785]
$R^2 = 0.6527, F = 6.5786, p = 0.0247, s^2 = 351.0445$		

置信区间包含零点
整体检验效果不好

二次函数

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_1^2 + \beta_4 x_2^2 + \varepsilon$$

回归模型

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_1 x_2 + \beta_4 x_1^2 + \beta_5 x_2^2 + \varepsilon$$

多元二项式回
归的一般形式

$$y = \beta_0 + \beta_1 x_1 + \cdots + \beta_m x_m + \sum_{1 \leq j, k \leq m} \beta_{jk} x_j x_k + \varepsilon$$

MATLAB命令: `rstool(x,y,'model',alpha)`

$x \sim n \times m$ 自变量矩阵, $y \sim$ 因变量向量, **model** 选择:

linear (只包含线性项) (默认选项);

purequadratic (包含线性项和纯二次项);

interaction (包含线性项和纯交互项);

quadratic (包含线性项和完全二次项)。

输出一个交互式画面

MATLAB实现:


```
n=10;  
x1=[120 140 190 130 155 175 125 145 180 150];  
x2=[100 110 90 150 210 150 250 270 300 250];  
y=[102 100 120 77 46 93 26 69 65 85];  
x=[ones(n,1) x1' x2'];  
[b,bi,r,ri,s]=regress(y',x); %第一次的线性回归  
s2=sum(r.^2)/(n-2);  
b,bi,s,s2  
x=[x1 ; x2]';  
pause  
rstool(x,y','purequadratic')
```



shangpin.m

例2 商品销售量与价格

model = purequadratic



4个模型的输出比较

	β_0	β_1	β_2	β_3	β_4	β_5	s
Purequadratic	-312.5871	7.2701	-1.7337	-0.0228	0.0037		16.6436
quadratic	-307.3600	7.2032	-1.7374	0.0001	-0.0226	0.0037	18.6064
interaction	137.5317	-0.0372	-0.7131	0.0028			19.1626
linear	66.5176	0.4139	-0.2698				18.7362

变量选择与逐步回归

变量选择

影响因变量的因素:

自变量 $x_1, x_2, \dots, x_m$ 及其简单函数, 如 $x_i^2, 1/x_i, e^{x_i}$ ($i \in \{1, 2, \dots, m\}$)

- 将所有影响显著的因素都纳入回归模型;
- 最终的模型尽量简单, 即包含尽量少的因素。

变量选择的标准

$$s^2 = Q/(n-p-1), s^2 \text{ 最小}$$

- 从候选集合 $S=\{x_1, \dots, x_k\}$ 中选出一子集 S_1 (含 $p \leq k$ 个自变量)与因变量 y 构造回归模型, 其优劣由 s^2 度量.
- 影响显著的自变量进入模型时, Q 明显下降, s 减小;
- 影响很小的自变量进入模型时, Q 下降不大, p 的增加会使 s 变大.

逐步回归

- 从候选集合中确定一初始子集;
- 从子集外（候选集合内）中引入一个对 y 影响显著的;
- 对集合中的变量进行检验，剔除影响变得不显著的;
- 迭代式地进行引入和剔除，直到不能进行为止。
- 选择衡量影响显著程度的统计量，通常用偏 F 统计量;
- 适当选取引入变量的显著性水平 α_{in} 和剔除变量的 α_{out} 。
- 引入新的变量后原来模型内影响显著的变量变得不显著，从而被剔除 ~ 自变量之间存在较强相关性的结果。

多重共线性

某些自变量之间的相关性很强

□ 矩阵 $X^T X$ 病态 □ 回归系数的置信区间较大

MATLAB中的逐步回归

stepwise (x,y,inmodel,penter,premove)

x~ $n \times k$ 自变量数据矩阵(k ~全部变量数), **y**~因变量向量,

inmodel~初始模型中候选变量的指标 (**x**的列序号, 缺省时为全部候选变量),



penter ~ 引入变量的显著性水平 α_{in} (缺省时为0.05)

premove ~ 剔除变量的显著性水平 α_{out} (缺省时为0.10)

输出交互式画面

例 儿童的体重与身高和年龄

序号	体重(kg)	身高(m)	年龄	序号	体重(kg)	身高(m)	年龄
1	27.1	1.34	8	7	30.9	1.39	10
2	30.2	1.49	10	8	27.8	1.21	9
3	24.0	1.14	6	9	29.4	1.26	10
4	33.4	1.57	11	10	24.8	1.06	6
5	24.9	1.19	8	11	36.5	1.64	12
6	24.3	1.17	7	12	29.1	1.44	9



可能存在二次函数关系

MATLAB实现:


```
y=[27.1 30.2 24.0 33.4 24.9 24.3 30.9 27.8 29.4 24.8 36.5 29.1];  
x1=[1.34 1.49 1.14 1.57 1.19 1.17 1.39 1.21 1.26 1.06 1.64 1.44];  
x2=[ 8 10 6 11 8 7 10 9 10 6 12 9];  
xx=[x1' x2' (x1.^2)' (x2.^2)' (x1.*x2)']; %候选变量集合  
stepwise(xx,y',[1,2]) %初始纳入模型的自变量列序号, 即 $x_1, x_2$   
pause  
n=12;  
x=[ones(n,1) x1' x2' (x2.^2)'];  
[b,bi,r,ri,s]=regress(y',x);  
s2=sum(r.^2)/(n-4);  
b,bi,s,s2
```




ertong.m

例 儿童的体重与身高和年龄

初始结果



最终结果



$$\hat{y} = 25.8287 + 5.3289x_1 - 2.6849x_2 + 0.2380x_2^2$$



%%%%%%%%%

图左上部的窗口用圆点和线段显示 x 中各个候选变量的回归系数估计值及其置信区间，蓝色和红色分别相应于在和不在模型中的变量，粗线段和细线段分别表示90%和95%的置信区间。

图右上部的窗口中列出一个统计表，包括各个候选变量的回归系数估计值、 t 统计量和一个概率值(其含义与ttest中的sig相同)。当用鼠标单击左上部的圆点或右上部的字段时，可使之由红变蓝，于是该变量被引入；或者由蓝变红，于是该变量被剔除。

图右上部也有提示：“Nextstep:”告诉你下一步应该引入或剔除哪个变量，按照这个提示只需单击这个按钮即可。

%%

图的中间是相应于当前模型的一些输出，有模型常数项 β 的估计值(intercept)，决定系数 R^2 ，F统计量，剩余标准差s(RMSE)，P值等.可以用使；达到最小作为确定最终模型的标准，不一定遵照“Nextstep: Move noterms”的提示。

图下部的窗口用圆点记录每次选取模型的剩余标准差s，供比较用，当鼠标指向某个圆点时，就显示那个模型包含的变量；若单击圆点，则重现那个模型的结果，通过图形右方的Export下拉式菜单可以向MATLAB工作区传送数据（用法与rstool相同）。

非线性回归分析

非线性最小二乘拟合

已知模型 $y = f(x, \beta)$, $x = (x_1, \dots, x_m)$, $\beta = (\beta_1, \dots, \beta_k)$ f 对 β 非线性

观测数据 (x_i, y_i) , $x_i = (x_{i1}, \dots, x_{im})$, $i = 1, \dots, n$, $n > m$

误差平方和 $Q(\beta) = \sum_{i=1}^n \varepsilon_i^2(\beta) = \sum_{i=1}^n [y_i - f(x_i, \beta)]^2$

非线性回归
$$\begin{cases} y = f(x, \beta) + \varepsilon, & x = (x_1, \dots, x_m), \quad \beta = (\beta_1, \dots, \beta_k) \\ \varepsilon \sim N(0, \sigma^2) \end{cases}$$

回归系数 β 的最小二乘估计 $\hat{\beta}$

非线性回归可以对非线性最小二乘拟合结果作统计分析

MATLAB中的非线性回归

[b,R,J]=nlinfit(x,y,'model',b0)

x ~自变量数据矩阵（每列一个变量）， y ~因变量向量，
 $model$ ~模型的函数名（m文件），形式为 $y=f(b,x)$ ，
 b 为待估系数 β ， $b0$ ~回归系数 β 的初值。

输出： b ~ β 的估计， R ~残差， J ~估计误差的Jacobi矩阵

bi=nlparci(b,R,J) %%回归系数 β 的置信区间

nlintool(x,y,'model',b) %%一个交互式画面

（内容和用法与多项式回归的Polytool类似）



实例4 酶促反应(续)

模型 $y = \frac{\beta_1 x}{\beta_2 + x}$ $y \sim$ 酶促反应的速度, $x \sim$ 底物浓度



huaxue.m



huaxue1.m

对未经嘌呤霉素处理的数据

```
x=[0.02 0.02 0.06 0.06 0.11 0.11 0.22 0.22 0.56 0.56 1.10];
y=[67 51 84 86 98 115 131 124 144 158 160]; % 未处理
%x=[0.02 0.02 0.06 0.06 0.11 0.11 0.22 0.22 0.56 0.56 1.10 1.10];
%y=[76 47 97 107 123 139 159 152 191 201 207 200]; % 已处理
beta0=[143 0.03];
[beta,R,J]=nlinfit(x,y,'huaxue',beta0);
betaci=nlparci(beta,R,J);
beta,betaci
xx=0:0.01:1.2;
yy=beta(1)*xx./(beta(2)+xx);
plot(x,y,'+',xx,yy),axis([0 1.2 0 200]), pause
nlintool(x,y,'huaxue',beta)
```

```
function yhat=huaxue(beta,x)
yhat=beta(1)*x./(beta(2)+x);
```




实例4 酶促反应(续)


模型 $y = \frac{\beta_1 x}{\beta_2 + x}$ $y \sim$ 酶促反应的速度, $x \sim$ 底物浓度

对未经嘌呤霉素处理的数据


nlinfit $\Rightarrow \hat{\beta}_1 = 160.2781, \hat{\beta}_2 = 0.0477$, 与用**lsqnonlin**的结果相同

nlparci $\Rightarrow \hat{\beta}_1 \in [145.6191, 174.9372], \hat{\beta}_2 \in [0.0301, 0.0653]$

数据拟合结果



nlintool的交互式画面





酶促反应的混合反应模型

在同一模型中考虑嘌呤霉素处理的影响

$$y = \frac{\beta_1 x}{\beta_2 + x} \quad \Rightarrow \quad y = \frac{(\beta_1 + \gamma_1 x_2) x_1}{(\beta_2 + \gamma_2 x_2) + x_1}$$

x_1 ~底物浓度, x_2 ~0(未经处理),1(经过处理)变量,

β_1 ~未经处理的最终反应速度,

β_2 ~未经处理的反应的半速度点,

γ_1 ~经处理后最终反应速度的增长值,

γ_2 ~经处理后反应的半速度点的增长值.

这个模型的求解, 请同学们自行完成

实验作业：

1、社会学家认为犯罪与收入低、失业及人口规模有关，对20个城市的犯罪率 y (每10万人中犯罪的人数) 与年收入低于5000美元家庭的百分比 x_1 、失业率 x_2 和人口总数 x_3 (千人)进行了调查，结果如下表.

- (1) 若 x_1 - x_3 中至多只许选择2个变量，最好的模型是什么？
- (2) 包含3个自变量的模型比上面的模型好吗？确定最终模型.
- (3) 对最终模型观察残差，有无异常点？若有，剔除后如何.

序号	y	x_1	x_2	x_3	序号	y	x_1	x_2	x_3
1	11.2	16.5	6.2	587	11	14.5	18.1	6.0	7895
2	13.4	20.5	6.4	643	12	26.9	23.1	7.4	762
3	40.7	26.3	9.3	635	13	15.7	19.1	5.8	2793
4	5.3	16.5	5.3	692	14	36.2	24.7	8.6	741
5	24.8	19.2	7.3	1248	15	18.1	18.6	6.5	625
6	12.7	16.5	5.9	643	16	28.9	24.9	8.3	854
7	20.9	20.2	6.4	1964	17	14.9	17.9	6.7	716
8	35.7	21.3	7.6	1531	18	25.8	22.4	8.6	921
9	8.7	17.2	4.9	713	19	21.7	20.2	8.4	595
10	9.6	14.3	6.4	749	20	25.7	16.9	6.7	3353

2、为得到研磨机速度(转/min)与纤维制品磨损量的关系, 在6种不同转速下分别对8块同样材料的制品进行试验, 结果下表。

转速	磨 损 量							
100	23.0	23.5	24.4	25.2	25.6	26.1	24.9	25.6
120	26.7	26.1	25.8	26.3	27.2	27.9	28.3	27.4
140	28.0	28.4	27.0	28.8	29.8	29.4	28.7	29.3
160	32.7	32.1	31.9	33.0	33.5	33.7	34.0	32.5
180	43.1	41.7	42.4	42.1	43.5	43.8	44.2	43.6
200	54.2	43.7	53.1	53.8	55.6	55.9	54.7	54.5

(1) 假定磨损量与转速之间的关系是线性的, 对所给数据采用两种办法建立模型: 原始数据; 先将每种转速下的8个磨损量平均。比较得到的两个结果的异同, 并作解释。

(2) 对模型 (1) 作改进, 如建立二次函数模型 (对数据仍用两种办法)。