



三大统计量

杨文志

大数据与统计学院

wzyang@ahu.edu.cn

三大统计量——卡方分布

定义 4.4.1. 设 $X_1, X_2, \dots, X_n$ *i.i.d.* $\sim N(0, 1)$, 令 $X = \sum_{i=1}^n X_i^2$, 则称 X 是自由度为 n 的 χ^2 变量, 其分布称为自由度为 n 的 χ^2 分布, 记为 $X \sim \chi_n^2$.

设随机变量 X 是自由度为 n 的 χ^2 随机变量, 则其概率密度函数为


$$g_n(x) = \begin{cases} \frac{1}{2^{\frac{n}{2}} \Gamma(\frac{n}{2})} x^{\frac{n}{2}-1} e^{-\frac{x}{2}}, & x > 0, \\ 0, & x \leq 0. \end{cases} \quad (4.4.1)$$

注 4.4.1. 若记 $\Gamma(\alpha, \lambda)$ 表示形状参数为 α 、刻度参数为 λ 的 *Gamma* 分布, 其密度函数如下

$$p(x; \alpha, \lambda) = \begin{cases} \frac{\lambda^\alpha}{\Gamma(\alpha)} x^{\alpha-1} e^{-\lambda x}, & x > 0, \\ 0, & x \leq 0. \end{cases}$$

则自由度为 n 的 χ^2 分布与 *Gamma* 分布的关系为: $X = \sum_{i=1}^n X_i^2 \sim \Gamma(n/2, 1/2)$. 我们也可以利用这一关系给出 χ^2 分布的定义: “若随机变量 X 的概率密度函数为 $\Gamma(n/2, 1/2)$, 则称 X 为服从自由度为 n 的 χ^2 分布”.


三大统计量——卡方分布

图 4.4.1 χ_n^2 的密度函数 $g_n(x)$ 形状图

χ_n^2 的密度函数 $g_n(x)$ 形状如图 4.4.1.

χ_n^2 密度函数的支撑集(即使密度函数为正的自变量的集合)为 $(0, +\infty)$, 由图 4.4.1 可见当自由度 n 越大, χ_n^2 的密度曲线越趋于对称, n 越小, 曲线越不对称. 当 $n = 1, 2$ 时曲线是单调下降趋于 0. 当 $n \geq 3$ 时曲线有单峰, 从 0 开始先单调上升, 在一定位置达到峰值, 然后单下降趋向于 0.

三大统计量——卡方分布

图 4.4.2 χ_n^2 的上侧 α 分位数

χ^2 变量具有下列性质:

- (1) 设随机变量 $X \sim \chi_n^2$ 则有 $E(X) = n$, $Var(X) = 2n$.
- (2) 设 $Z_1 \sim \chi_{n_1}^2$, $Z_2 \sim \chi_{n_2}^2$, 且 Z_1 和 Z_2 独立, 则 $Z_1 + Z_2 \sim \chi_{n_1+n_2}^2$.

若 $X \sim \chi_n^2$, 记 $P(X > c) = \alpha$, 则 $c = \chi_n^2(\alpha)$ 称为 χ_n^2 分布的上侧 α 分位数, 如图 4.4.2 所示. 当 α 和 n 给定时可查表求出 $\chi_n^2(\alpha)$ 之值, 如 $\chi_{10}^2(0.01) = 23.209$, $\chi_5^2(0.05) = 12.592$ 等.

三大统计量——t分布

定义 4.4.2. 设随机变量 $X \sim N(0, 1)$, $Y \sim \chi_n^2$, 且 X 和 Y 独立, 则称

$$T = \frac{X}{\sqrt{Y/n}}$$

为自由为 n 的 t 变量, 其分布称为由 n 的 t 分布, 记为 $T \sim t_n$.

设随机变量 $T \sim t_n$, 则其密度函数为

$$t_n(x) = \frac{\Gamma(\frac{n+1}{2})}{\Gamma(\frac{n}{2})\sqrt{n\pi}} \left(1 + \frac{x^2}{n}\right)^{-\frac{n+1}{2}}, \quad -\infty < x < \infty$$

t_n 的密度函数与标准正态分布 $N(0, 1)$ 密度很相似, 它们都是关于原点对称, 单峰偶函数, 在 $x = 0$ 处达到极大. 但 t_n 的峰值低于 $N(0, 1)$ 的峰值, t_n 的密度函数尾部都要比 $N(0, 1)$ 的两侧尾部粗一些. 如图 4.4.3 所示. 容易证明: $\lim_{n \rightarrow \infty} t_n(x) = \varphi(x)$, 此处 $\varphi(x)$ 是 $N(0, 1)$ 变量的密度函数.

若 $T \sim t_n$, 记 $P(|T| > c) = \alpha$, 则 $c = t_n(\alpha/2)$ 为自由度为 n 的 t 分布的双侧 α 分位数 (如图 4.4.4 所示). 当给定 α 时, $t_n(\alpha)$, $t_n(\alpha/2)$ 等可通过查表求出. 例如 $t_{12}(0.05) = 1.782$, $t_9(0.025) = 2.262$ 等.




图 4.4.3 t_n 的密度函数 $t_n(x)$ 形状图

三大统计量——t分布




图 4.4.4 t_n 的双侧 α 分位数

t 分布是英国统计学家 W.S. Gosset 在 1908 年以笔名 Student 发表的论文中提出的, 故后人称为“学生氏(Student)分布”或“ t 分布”.

t 变量具有下列的性质:

- (1) 若随机变量 $T \sim t_n$, 则当 $n \geq 2$ 时, $E(T) = 0$. 当 $n \geq 3$ 时, $Var(T) = \frac{n}{n-2}$.
- (2) 当 $n \rightarrow \infty$ 时, t 变量的极限分布为 $N(0, 1)$.

三大统计量——F分布

定义 4.4.3. 设随机变量 $X \sim \chi_m^2$, $Y \sim \chi_n^2$, 且 X 和 Y 独立, 则称

$$F = \frac{X/m}{Y/n}$$

为自由度分别是 m 和 n 的 F 变量, 其分布称为自由度分别是 m 和 n 的 F 分布, 记为 $F \sim F_{m,n}$.

若随机变量 $Z \sim F_{m,n}$, 则其密度函数为

$$f_{m,n}(x) = \begin{cases} \frac{\Gamma(\frac{m+n}{2})}{\Gamma(\frac{m}{2})\Gamma(\frac{n}{2})} m^{\frac{m}{2}} n^{\frac{n}{2}} x^{\frac{m}{2}-1} (n+mx)^{-\frac{m+n}{2}}, & x > 0, \\ 0, & \text{其它.} \end{cases}$$

自由度为 m, n 的 F 分布的密度函数如图 4.4.5. 注意 F 分布的自由度 m 和 n 是有顺序的, 当 $m \neq n$ 时若将自由度 m 和 n 的顺序颠倒一下, 得到的是两个不同的 F 分布. 图 4.4.5 中给出了几个不同自由度的密度函数的曲线. 由图 4.4.5 可见对给定 $m = 10$, n 取不同值时 $f_{m,n}(x)$ 的形状, 我们看到曲线是偏态的, n 越小偏态越严重.




图 4.4.5 $F_{m,n}$ 的密度函数 $f_{m,n}(x)$ 形状图

三大统计量——F分布




图 4.4.6 $F_{m,n}$ 的上侧 α 分位数

若 $F \sim F_{m,n}$, 记 $P(F > c) = \alpha$, 则 $c = F_{m,n}(\alpha)$ 称为 F 分布的上侧 α 分位数 (见图 4.4.6). 当 m, n 和 α 给定时, 可以通过查表求出 $F_{m,n}(\alpha)$ 之值, 例如 $F_{4,10}(0.05) = 3.48$, $F_{10,15}(0.01) = 3.80$ 等. 这在区间估计和假设检验问题中常常用到.



三大统计量——F分布

F 变量具有下列的性质:

(1) 若 $Z \sim F_{m,n}$, 则 $1/Z \sim F_{n,m}$.

(2) 若 $T \sim t_n$, 则 $T^2 \sim F_{1,n}$.

(3) $F_{m,n}(1-\alpha) = 1/F_{n,m}(\alpha)$

以上性质中(1)和(2)是显然的, (3)的证明不难, 留给读者作为练习. 尤其性质(3)在求区间估计和假设检验问题时会常常用到. 因为当 α 为较小的数, 如 $\alpha = 0.05$ 或 $\alpha = 0.01$, m, n 给定时, 从已有的 F 分布表上查不到 $F_{m,n}(1-0.05)$ 和 $F_{m,n}(1-0.01)$ 之值, 但它们的值可利用性质(3)求得, 因为 $F_{n,m}(0.05)$ 和 $F_{n,m}(0.01)$ 是可以通过查 F 分布表求得的.



正态总体样本均值和样本方差分布

1. 正态变量线性函数的分布

设随机变量 $X_1, \dots, X_n$ $i.i.d. \sim N(a, \sigma^2)$, $c_1, c_2, \dots, c_n$ 为常数, 则有

$$T = \sum_{k=1}^n c_k X_k \sim N\left(a \sum_{k=1}^n c_k, \sigma^2 \sum_{k=1}^n c_k^2\right)$$

特别, 当 $c_1 = \dots = c_n = 1/n$, 即 $T = \frac{1}{n} \sum_{i=1}^n X_i = \bar{X}$ 时, 有

$$\bar{X} \sim N(a, \sigma^2/n).$$



正态总体样本均值和样本方差分布

2. 正态变量样本均值和样本方差的分布

下述定理给出了正态变量样本均值和样本方差的分布和它们的独立性.

定理 4.4.1. 设 $X_1, X_2, \dots, X_n$ $i.i.d. \sim N(a, \sigma^2)$, $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$ 和 $S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$ 分别为样本均值和样本方差, 则有

- (1) $\bar{X} \sim N(a, \frac{1}{n}\sigma^2)$;
- (2) $(n-1)S^2/\sigma^2 \sim \chi_{n-1}^2$;
- (3) $\bar{X}$ 和 S^2 独立.



正态总体样本均值和样本方差分布

下面几个推论在正态总体区间估计和假设检验问题中有着重要应用.

推论 4.4.1. 设 $X_1, X_2, \dots, X_n$ 相互独立相同分布 ($i.i.d.$) $\sim N(a, \sigma^2)$, 则

$$T = \frac{\sqrt{n}(\bar{X} - a)}{S} \sim t_{n-1}.$$

证: 由注5.4.3可知 $\bar{X} \sim N(a, \sigma^2/n)$, 将其标准化得 $\sqrt{n}(\bar{X} - a)/\sigma \sim N(0, 1)$. 又 $(n-1)S^2/\sigma^2 \sim \chi_{n-1}^2$, 即 $S^2/\sigma^2 \sim \chi_{n-1}^2/(n-1)$, 且 $\bar{X}$ 和 S^2 独立, 按定义有

$$T = \frac{\sqrt{n}(\bar{X} - a)/\sigma}{\sqrt{S^2/\sigma^2}} = \frac{\sqrt{n}(\bar{X} - a)}{S} \sim t_{n-1}.$$



正态总体样本均值和样本方差分布

推论 4.4.2. 设 $X_1, X_2, \dots, X_m$ i.i.d. $\sim N(a_1, \sigma_1^2)$, $Y_1, Y_2, \dots, Y_n$ i.i.d. $\sim N(a_2, \sigma_2^2)$, 且假定 $\sigma_1^2 = \sigma_2^2 = \sigma^2$, 样本 $X_1, X_2, \dots, X_m$ 与 $Y_1, Y_2, \dots, Y_n$ 独立, 则

$$T = \frac{(\bar{X} - \bar{Y}) - (a_1 - a_2)}{S_w} \cdot \sqrt{\frac{mn}{n+m}} \sim t_{n+m-2},$$

此处 $(n+m-2)S_w^2 = (m-1)S_1^2 + (n-1)S_2^2$, 其中

$$S_1^2 = \frac{1}{m-1} \sum_{i=1}^m (X_i - \bar{X})^2, \quad S_2^2 = \frac{1}{n-1} \sum_{j=1}^n (Y_j - \bar{Y})^2.$$



正态总体样本均值和样本方差分布

证: 由注5.4.3可知 $\bar{X} \sim N(a_1, \sigma^2/m)$, $\bar{Y} \sim N(a_2, \sigma^2/n)$, 故有 $\bar{X} - \bar{Y} \sim N(a_1 - a_2, (\frac{1}{m} + \frac{1}{n})\sigma^2) = N(a_1 - a_2, \frac{n+m}{mn}\sigma^2)$. 将其标准化得

$$\frac{\bar{X} - \bar{Y} - (a_1 - a_2)}{\sigma} \sqrt{\frac{mn}{m+n}} \sim N(0, 1). \quad (4.4.4)$$

又 $(m-1)S_1^2/\sigma^2 \sim \chi_{m-1}^2$, $(n-1)S_2^2/\sigma^2 \sim \chi_{n-1}^2$, 再利用 χ^2 分布的性质可知

$$\frac{(m-1)S_1^2 + (n-1)S_2^2}{\sigma^2} \sim \chi_{n+m-2}^2. \quad (4.4.5)$$

再由 (4.4.4) 和 (4.4.5) 中 $(\bar{X}, \bar{Y})$ 与 (S_1^2, S_2^2) 相互独立, 由定义可知

$$\begin{aligned} T &= \frac{(\bar{X} - \bar{Y}) - (a_1 - a_2)}{\sigma} \sqrt{\frac{mn}{n+m}} \bigg/ \sqrt{\frac{(m-1)S_1^2 + (n-1)S_2^2}{\sigma^2(n+m-2)}} \\ &= \frac{(\bar{X} - \bar{Y}) - (a_1 - a_2)}{S_w} \sqrt{\frac{mn}{n+m}} \sim t_{n+m-2}. \end{aligned}$$



正态总体样本均值和样本方差分布

推论 4.4.3. 设 $X_1, X_2, \dots, X_m$ *i.i.d.* $\sim N(a_1, \sigma_1^2)$, $Y_1, Y_2, \dots, Y_n$ *i.i.d.* $\sim N(a_2, \sigma_2^2)$, 且样本 $X_1, X_2, \dots, X_m$ 和 $Y_1, Y_2, \dots, Y_n$ 相互独立, 则

$$F = \frac{S_1^2}{S_2^2} \cdot \frac{\sigma_2^2}{\sigma_1^2} \sim F_{m-1, n-1},$$

此处 S_1^2 和 S_2^2 定义如推论 4.4.2 所述.

证: 由注 5.4.3 可知 $(m-1)S_X^2/\sigma_1^2 \sim \chi_{m-1}^2$, $(n-1)S_Y^2/\sigma_2^2 \sim \chi_{n-1}^2$, 且二者独立, 由 F 分布的定义可知

$$F = \frac{\frac{(m-1)S_X^2}{\sigma_1^2}/(m-1)}{\frac{(n-1)S_Y^2}{\sigma_2^2}/(n-1)} = \frac{S_X^2}{S_Y^2} \cdot \frac{\sigma_2^2}{\sigma_1^2} \sim F_{m-1, n-1}.$$

证毕.