

统计学概论

杨文志
安徽大学大数据与统计学院
wzyang@ahu.edu.cn

统计学概论

主要参考文献：

- 《数据挖掘与机器学习——基于R语言编程》，方匡南，兰伟，高等教育出版社，2024；
- 《人工智能概率与统计基础》，王卓，薛栋，王圣强，北京大学出版社，2025；
- 《人工智能的数学基础》，冯朝路，于鲲，杨金柱，栗伟，清华大学出版社，2022；
- 《人工智能导论》，金军委、高山、张自豪等编著北京大学出版社，2022；
- 《人工智能数学基础》，唐宇迪、李琳、侯惠芳、王社伟，北京大学出版社出版，2020

第1章 统计学绪论

- 1.1 统计学发展
- 1.2 人工智能发展
- 1.3 人工智能应用
- 1.4 学习AI需要哪些知识
- 1.5 为什么要学习统计学
- 1.6 本课程统计学知识点

1.1 统计学发展

人类最早的计数活动可以追溯到5000多年前的原始社会，可以说是统计学发展的源头。

17世纪中叶

- **国势学派**：国势学派主要是通过对比来分析各个国家之间的人口、领土、资源财富等与国家富强有关的显著事项的强弱，探索国家盛衰的原因。
- **政治算术学派**：诞生在英国，其主要代表人物是威廉·配第和格朗特。该学派更加关注社会经济领域的研究。与国势学派不同的是，政治算术学派更注重数量的对比分析，核心思想是计量和归纳的思想，运用分组法、平均数法和相对数法等统计方法对比各国的国情国力，为统计学的发展奠定了方法论的基础。

1.1 统计学发展

18世纪末至19世纪末

- **数理统计学派**：重统计学理论和方法的研究。19世纪中叶，数理统计学派的创始人凯特勒把古典概率论正式引入了统计学，运用大数定律来研究人类社会活动的规律，使得统计学的发展进入新的阶段。各种统计概念与统计方法，如正态分布曲线、最小二乘法和误差测定等被大量应用到经济、人口和法律等领域。
- **社会统计学派**：产生于19世纪后半叶，代表人物有恩格尔和梅尔等人。社会统计学派关注解决社会政治、经济等问题，研究社会的结构、动态和趋势以及人类活动的规律，强调对总体的研究，其研究主要围绕统计指标展开，同时也注重数据的收集和整理方法，为国家的政治经济管理服务。

1.1 统计学发展

进入到20世纪

- 推断性统计（即通过样本数据来推断总体的方法）成为了统计学的重心。
- 20世纪70年代，John Tukey提出的探索性数据分析（EDA）可以说是统计学发展的重大转折。
- 而后贝叶斯统计、非参数统计、多元统计、时间序列和计量经济学等统计学分支逐渐发展成熟，自助法（Bootstrap）和非参领域中的核光滑方法（Kernel Smoothing）等统计学领域的新技术的诞生，使统计学在应用领域的前景更加广阔，统计学在分子生物学、医学、天文学、和社会经济等多个领域都有着高度的应用。

1.1 统计学发展

大数据时代的融合：统计学习与机器学习

- 进入21世纪，数据量呈指数级增长，统计学与计算机科学深度融合，形成了**统计学习 (Statistical Learning)** 领域。
- **探索性数据分析 (EDA)**，强调在建模前先用图形（如箱线图）探索数据，发现异常和模式。
 - **大数据时代**：随着计算机算力的提升，传统的频率学派统计（如假设检验）在处理海量数据时遇到瓶颈，而**贝叶斯统计**（利用先验知识进行更新）和**机器学习**（从数据中自动学习模式）成为新的主流。
 - **从“模型驱动”到“数据驱动”**：传统统计学强调模型的假设（如正态性、线性），而当代统计学更关注模型的预测精度，允许使用“黑箱”模型（如神经网络、支持向量机）。
 - **核心思想：偏差-方差权衡 (Bias-Variance Tradeoff)**。认识到模型不是越复杂越好，需要在拟合数据（低偏差）和泛化能力（低方差）之间找到平衡。

1.2 人工智能发展

人工智能 (Artificial Intelligence, AI) 作为一门前沿交叉学科，是研究和开发用于模拟、延伸和扩展人的智能的理论、方法、技术及应用系统的一门新的技术科学。人类的智能随着人类的活动无处不在，如下棋、竞技解题游戏、规划路线和驾驶车辆，都需要人工智能，如果机器能够执行这些任务，就可以认为机器具有了某种性质的人工智能。由此我们可以看出，人工智能是个很宽泛的话题。从手机上的计算器到无人驾驶汽车，再到未来可能改变世界的重大变革，人工智能可以描述很多东西。

1.2 人工智能发展

日常生活中我们每天都能接触到人工智能。互联网中各种各样的人工智能新闻随处可见，人工智能已经从一个深藏于专业实验室的科研产品，步入我们的社会生活中。人工智能带来的变化已随处可见。当你打开新闻网页时，展示给你的那些文章是由人工智能为你定制的；当你上网购物时，打开首页看到的是你最有可能感兴趣的、最有可能购买的商品，这是推荐算法根据你最近的搜索记录自动推荐的；当你打开邮箱时，系统已经为你过滤了你不关心的广告和垃圾邮件。2017年，AlphaGo以无可争辩的能力战胜了人类围棋高手，名噪一时。人工智能在无人驾驶等领域也大显身手，显示出越来越强的能力。图像识别、语音识别、指纹识别等技术给人们的生活带来了极大的便利，人工智能改变了我们的生活方式。

1.2 人工智能发展

11年前微信“摇一摇”改变春晚传统，让互联网红包大战成为春晚标配。头部公司你方唱罢我登台，纷纷亮出肌肉试图驯服这头流量猛兽，但究其本质都是验证高并发下的I/O（输入/输出）吞吐能力。

2026年春晚舞台呈现效果和互动模式彻底变。当AI让国宝级水墨画中的骏马挣脱纸张的束缚肆意奔腾；当数个身形一致的分身与真人演员在光影中真假难辨；当人们不再只是摇晃、点击手机抢夺既定红包，而是输入一段文字或说出一句吉祥话，就能即兴创作一张独一无二的新年图景，我们发现：互联网底层正式从流量分发迈入算力分发的AI时代。

字节跳动正是这场盛宴背后的技术推手，豆包视频生成模型Seedance 2.0、豆包图像创作模型Seedream4.5，以及豆包语音模型被广泛用于春晚节目与互动中。数据显示，除夕当天豆包AI互动总数达19亿，“豆包过年”活动在除夕帮助用户生成超过5000万张新春主题头像、生成超过1亿条新春祝福。

通过春晚舞台，豆包向外界传递了一个清晰的信号：AI不再仅仅是聊天框里的玩具，它已经具备了工业级的生产能力，扛得住指数级爆发的算力洪流，并正在以一种极其务实的方式，渗透进汽车、手机、机器人乃至实体经济的毛细血管中。

1.2 人工智能发展

人工智能发展历程

- 1. 萌芽期（1950s—1960s）
 - 1950年：图灵提出“图灵测试”，奠定AI理论基石。
 - 1956年：达特茅斯会议首次提出“人工智能”术语，标志AI学科诞生。
 - 早期突破：
 - 逻辑理论家（Logic Theorist, 1956）可证明数学定理。
 - ELIZA（1966）实现简单人机对话。
- 2. 知识驱动与专家系统（1970s—1980s）
 - 1970年代：遭遇“AI寒冬”，因算力不足与预期过高。
 - 1980年代复兴：
 - 专家系统（如MYCIN医疗诊断）商业化成功。
 - 日本“第五代计算机计划”推动符号逻辑研究。

1.2 人工智能发展

人工智能发展历程

- 3. 机器学习崛起（1990s—2000s）
 - 统计学习主流化：支持向量机、贝叶斯网络广泛应用。
 - 里程碑事件：
 - 1997年：IBM深蓝击败国际象棋冠军卡斯帕罗夫。
 - 2006年：深度学习因“神经网络复兴”突破训练瓶颈。
- 4. 深度学习与大模型时代（2010s—2020s）
 - 2012年：AlexNet在ImageNet竞赛夺冠，点燃深度学习革命。
 - 2016年：AlphaGo战胜围棋冠军，彰显强化学习潜力。
 - 2018—2022年：
 - Transformer架构（2017）推动自然语言处理飞跃。
 - GPT-3、BERT等预训练模型实现少样本学习。
 - DALL·E、Stable Diffusion开启多模态生成浪潮。

1.2 人工智能发展

人工智能发展历程

5. 通用智能与融合创新（2020s中期至今）

- 技术趋势：
 - 大模型向多模态、强推理演进（如GPT-4、Gemini）。
 - 具身智能机器人（特斯拉Optimus等）步入现实场景。
 - AI与生物计算、量子计算交叉探索。
- 社会影响：
 - 全球AI伦理与安全监管体系加速构建（如欧盟《AI法案》）。
 - 开源与闭源生态并行，推动技术民主化与产业竞争。

1.3 人工智能应用

人工智能可以分为**弱人工智能**和**强人工智能**两大类。强人工智能是指具有人类的心智和意识、具有自主的选择行为，且拥有超越人类智慧水平的人工智能。强人工智能目前离我们还很遥远，是人工智能领域的长远目标。

弱人工智能是指擅长某个方面的人工智能，能够帮助人类从某些脑力劳动中解放出来。比如能战胜象棋世界冠军的人工智能、手机中的骚扰电话自动拦截、邮箱的自动过滤，都属于弱人工智能。目前对于人工智能的研究和开发主要集中在弱人工智能领域，弱人工智能已经成为我们日常生活必不可少的一部分。

1.3 人工智能应用

- (1) 图像识别。图像识别是指计算机从图像中识别出物体、场景和活动。图像识别有着广泛的应用，包括医疗领域的成像分析、人脸识别、公共安全、安防监控、无人驾驶等。
- (2) 语音识别。语音识别是把语音转化为文字，并对其进行识别、认知和处理。语音识别的主要应用包括电话客服、自动翻译、医疗领域听写、语音书写、计算机系统声控等。
- (3) 虚拟个人助理。虚拟个人助理是指智能手机上的语音助理、语音输入、家庭管家和陪护机器人等。如微软小冰、百度度秘、科大讯飞、Amazon Echo、Google Home 等。
- (4) 自然语言处理。自然语言处理帮助实现人机之间自然语言的通信，在机器翻译、语音识别中都有相应的应用。

1.3 人工智能应用

- (5) 智能机器人。智能机器人目前在生活中随处可见，如扫地机器人、陪伴机器人.....这些机器人不管是跟人语音聊天，还是自主定位导航行走、安防监控等，都离不开人工智能技术的支持。
 - (6) 电商网站的产品推荐和社交网站的好友推荐。如淘宝、京东等商城，会根据用户浏览过的商品和页面、搜索过的关键字，推送一些相关的产品或网站内容，以及媒体平台根据日常浏览记录推送用户喜欢看的信息等。
- 除此之外，军事、制造、金融、医疗等很多领域都广泛应用了各种各样的人工智能技术。

1.4 学习AI需要哪些知识

人工智能目前已经成为一个涉及很广的学科，涵盖感知、学习、推理与决策等方面的能力，有着众多的研究分支和应用方向，不同的子方向对学科知识的要求也不尽相同。当前人工智能的方法主要是通过已有数据集让机器来学习知识并获得预测和判断的能力，这样的方法称为**机器学习**。机器学习主要从数据和行动中学习，并且这种方式已经获得了长足的发展，在各行各业得到了应用，已经成为目前人工智能的主流方法。

对于学习人工智能而言，最基础的学科知识主要涉及**数学、统计学和计算机**。各种人工智能技术归根结底都建立在数学模型之上，要了解人工智能，首先要掌握必备的数学基础知识，并**通过概率论描述数据的统计规律等**。

机器学习常见算法分类与核心概要

一、监督学习 (Supervised Learning)

1. 回归算法

- 线性回归** 用线性模型拟合连续值输出，最小化均方误差。
- 扩展**: 岭回归、Lasso回归 (加入正则化防止过拟合)。
- 决策树回归** 基于树结构分割数据，输出叶节点均值。
- 支持向量回归 (SVR)** 在高维空间中寻找使间隔最大化的超平面，支持非线性核函数。

2. 分类算法

- 逻辑回归** 通过Sigmoid函数将线性输出映射为概率，用于二分类或多分类。
- 决策树分类** 基于信息增益 (ID3)、基尼系数 (CART) 递归划分特征。
- 随机森林** 通过多棵决策树集成，投票决定结果，降低过拟合风险。
- 支持向量机 (SVM)** 寻找最大间隔超平面，核函数 (如RBF) 可处理非线性分割。
- 朴素贝叶斯** 基于贝叶斯定理与特征条件独立假设，适用于文本分类。
- K近邻 (KNN)** 根据最近邻样本的多数投票进行分类。

机器学习常见算法分类与核心概要

二、无监督学习 (Unsupervised Learning)

1. 聚类算法

- **K均值聚类** 迭代将样本分配到最近的质心，并更新质心位置。
- **层次聚类** 通过树状结构（凝聚或分裂）逐步合并/分割样本簇。
- **高斯混合模型 (GMM)** 假设数据由多个高斯分布生成，用EM算法求解参数。

2. 降维与特征提取

- **主成分分析 (PCA)** 通过正交变换将数据投影到低维线性空间，保留最大方差。
- **t-SNE** 非线性降维，侧重于保持高维数据的局部结构，常用于可视化。
- **自编码器** 神经网络通过编码-解码重构输入，隐层作为低维表示。

三、半监督与弱监督学习

- **自训练** 用已标注数据训练模型，对未标注数据打伪标签并迭代扩充训练集。
- **标签传播** 基于图结构将已标注样本的标签扩散到未标注样本。

四、强化学习 (Reinforcement Learning)

- **Q学习** 基于价值迭代，通过Q表存储状态-动作值，适用于离散空间。
- **深度Q网络 (DQN)** 用神经网络近似Q值，引入经验回放与目标网络稳定训练。
- **策略梯度方法** 直接优化策略函数，如REINFORCE算法、PPO、SAC。

机器学习常见算法分类与核心概要

五、集成学习 (Ensemble Learning)

- **Bagging** 并行训练多个基模型并投票（如随机森林）。
- **Boosting** 序列化训练弱模型，调整权重聚焦错误样本（如AdaBoost、XGBoost、LightGBM）。
- **Stacking** 用多个基模型的输出作为新特征，训练元模型进行最终预测。

六、深度学习算法

1. 神经网络基础

- **前馈神经网络** 多层感知机 (MLP)，通过反向传播优化权重。
- **卷积神经网络** 用于图像、视频等网格数据，核心为卷积层、池化层。
- **循环神经网络** 处理序列数据（如文本、时间序列），含LSTM、GRU等变体解决梯度消失。
- **Transformer** 基于自注意力机制，成为NLP（如BERT、GPT）与多模态模型基础。

2. 生成模型

- **生成对抗网络** 生成器与判别器对抗训练，生成逼真数据。
- **变分自编码器** 通过隐变量建模学习数据分布，支持生成与重构。

1.5 为什么要学习统计

一、提供AI模型的理论基石

1. 概率框架支撑不确定性建模

- 现实世界数据充满噪声与缺失，统计学中的**概率论**（如贝叶斯网络、隐马尔可夫模型）赋予AI系统表达与推理不确定性的能力。
- 示例：自动驾驶感知系统通过概率分布预测行人轨迹，医疗诊断模型结合先验知识计算疾病后验概率。

2. 统计推断实现从数据到知识的转化

- AI本质是从数据中归纳规律，而**统计推断**（假设检验、置信区间）为模型结论的可靠性提供量化评估。
- 示例：A/B测试通过显著性分析判断算法策略效果，避免随机误差误导决策。

二、驱动机器学习方法论的形成

1. 监督学习的统计本质

- 线性回归、逻辑回归等基础模型源自**广义线性模型理论**；支持向量机（SVM）基于统计学习理论的结构风险最小化原则。
- 生成模型与贝叶斯学派深度绑定
- 变分自编码器（VAE）、高斯混合模型（GMM）依赖**最大似然估计**与**贝叶斯推断**

2. 因果推理的突破依赖统计革新

- 鲁宾因果模型、do-演算等因果AI工具源于统计学对“相关性≠因果性”的长期研究。

三、保障AI系统可解释性与稳健性

1. 可解释性工具依托统计指标

- SHAP值、LIME等模型解释方法通过**特征贡献度分布**量化决策依据。
- 假设检验用于判断模型是否学到虚假关联（如医疗模型误将仪器标记作为病症特征）。

2. 稳健性评估依赖统计测试

- 对抗样本检测需分析预测结果的**置信度分布**；模型偏差审计通过统计差异度量公平性（如群体间准确率差异的p值检验）。

四、优化模型训练与评估体系

1. 训练策略的统计优化

- 梯度下降的收敛性分析依赖**随机过程理论**；自适应优化器（Adam）融合矩估计思想。

2. 模型评估的统计规范

- 交叉验证防止过拟合；**Bootstrap**方法用于估计模型性能的置信区间；统计检验（如McNemar检验）比较模型优劣。

五、应对数据稀缺与噪声的底层方法

1. 小样本学习

- 贝叶斯方法通过引入先验分布提升少数数据下的泛化能力（如高斯过程）。

2. 异常检测与数据清洗

- 基于统计分布（如3 σ 原则、马氏距离）识别异常值，提升数据质量。

六、前沿AI方向的统计学内核

强化学习，涉及马尔可夫决策过程、贝尔曼方程

联邦学习，涉及分布式统计推断、隐私保护（差分隐私）

生成对抗网络，涉及分布匹配（JS散度、Wasserstein距离）

大语言模型评估，涉及困惑度（Perplexity）、对齐统计指标

1.6 本课程统计学知识点

- 概率统计基础
- 描述性数据分析
- 数据结构与基本运算
- 假设检验与方差分析
- R函数与优化
- 线性回归
- 随机数产生与抽样模拟
- 线性分类
- 数据清洗与预处理
- 模型选择与正则化