

统计学概论

杨文志
安徽大学大数据与统计学院
wzyang@ahu.edu.cn

第3章 概率统计基础2

- 随机变量数字特征
- 大数定律和中心极限定理
- 数理统计基本概念
- 最大似然估计
- 最大后验估计

3.1 随机变量数字特征

随机变量的概率分布是对随机变量的概率性质最完整的描述，但在很多实际问题中，我们需要掌握的是随机变量一个具体的指标，例如粮食的平均产量、一个地区家庭的平均年收入等。在这种情况下，希望能够用一个简单的数字量来粗线条地描述随机变量的特性，而且这个数字量要简单明了、特征鲜明、直观实用，通常称这个能够描述随机变量的某种特性的数字量为数字特征。随机变量的数字特征很多，这里我们主要介绍数学期望、方差、协方差和相关系数四种常用数字特征。

3.1.1 数学期望

定义3.1 离散型随机变量期望定义

设离散随机变量 X 的分布列为

$$P(X = x_n) = p_n, \quad n = 1, 2, \dots$$

若级数 $\sum_{i=1}^{\infty} x_i p_i$ 绝对收敛，则称该级数为 X 的数学期望，记为

$$E(X) = \sum_{i=1}^{\infty} x_i p_i$$

【例 3.1】 $X \sim B(n, p)$, 求 $E(X)$.

解:

$$\begin{aligned}
 E(X) &= \sum_{k=0}^n k C_n^k p^k (1-p)^{n-k} \\
 &= np \sum_{k=1}^n \frac{(n-1)!}{(k-1)!(n-k)!} p^{k-1} (1-p)^{(n-1)-(k-1)} \\
 &= np \sum_{k=0}^{n-1} C_{n-1}^k p^k (1-p)^{(n-1)-k} = np
 \end{aligned}$$

特例 若 $Y \sim B(1, p)$, 则 $E(Y) = p$ 另解: 令 $X_1, X_2, \dots, X_n$ i.i.d (即独立同分布), $X_1 \sim B(1, p)$

则

$$Y = \sum_{i=1}^n X_i \sim B(n, p)$$

且

$$EY = E\left(\sum_{i=1}^n X_i\right) = \sum_{i=1}^n EX_i = np$$

【例 3.2】 某城市有 10 万个家庭, 没有孩子的家庭有 1000 个, 有一个孩子的家庭有 9 万个, 有两个孩子的家庭有 6000 个, 有 3 个孩子的家庭有 3000 个, 那么一个家庭中孩子数目的数学期望是多少?

解: $EX = 0 \cdot 0.1/10 + 1 \cdot 9/10 + 2 \cdot 0.6/10 + 3 \cdot 0.3/10 = 1.11$

定义3.2 连续型随机变量期望定义

设连续随机变量 X 的密度函数为 $p(x)$, 若积分 $\int_{-\infty}^{\infty} xp(x)dx$ 绝对收敛, 则称该积分为 X 的数学期望, 记为

$$E(X) = \int_{-\infty}^{\infty} xp(x)dx$$

【例 3.2】 $X \sim N(\mu, \sigma^2)$, 求 $E(X)$.

解:

$$E(X) = \int_{-\infty}^{+\infty} x \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}} dx$$

$$\stackrel{\frac{x-\mu}{\sigma}=u}{=} \int_{-\infty}^{+\infty} (u\sigma + \mu) \frac{1}{\sqrt{2\pi}} e^{-\frac{u^2}{2}} du = \mu$$

【例 3.3】

例如: 柯西(Cauchy)分布的密度函数为

$$f(x) = \frac{1}{\pi(1+x^2)}, \quad -\infty < x < +\infty$$

但

$$\int_{-\infty}^{+\infty} |x| f(x) dx = \int_{-\infty}^{+\infty} \frac{|x|}{\pi(1+x^2)} dx$$

发散

它的数学期望不存在!

定义3.3 随机变量函数的数学期望定义

定理4.1.1: (i) 设连续型 (离散型) 随机变量 X 的分布密度为 $p(x)$ (分布列为 $p_i, i = 1, 2, \dots$), 实函数 $g(x)$ 为 Borel 可测函数, 令 $Y = g(X)$, 若 $E(g(X))$ 存在, 则

$$E(g(X)) = \begin{cases} \sum_{i=1}^{\infty} g(x_i) p_i, & X \text{ 为离散型随机变量;} \\ \int_{-\infty}^{\infty} g(x) p(x) dx, & X \text{ 为连续型随机变量。} \end{cases}$$

随机变量数学期望性质

- $E(C) = C$ 常数
- $E(aX) = aE(X)$
- $E(X + Y) = E(X) + E(Y)$

$$E\left(\sum_{i=1}^n a_i X_i + C\right) = \sum_{i=1}^n a_i E(X_i) + C$$

- 当 X, Y 独立时, $E(XY) = E(X)E(Y)$
注: 逆命题不成立, 即若 $E(XY) = E(X)E(Y)$, X, Y 不一定独立
- 若存在数 a 使 $P(X \geq a) = 1$, 则 $E(X) \geq a$;
若存在数 b 使 $P(X \leq b) = 1$, 则 $E(X) \leq b$.

【例 3.4】 市场上对某种产品每年需求量为 X 吨, $X \sim U[2000, 4000]$, 每出售一吨可赚3万元, 售不出去, 则每吨需仓库保管费1万元, 问应该生产这中商品多少吨, 才能使平均利润最大?

解:

$$f_X(x) = \begin{cases} \frac{1}{2000}, & 2000 < x < 4000 \\ 0, & \text{else} \end{cases}$$

设每年生产 y 吨的利润为 Y , 显然, $2000 < y < 4000$

$$Y = g(X) = \begin{cases} 3y, & y \leq X \\ 3X - (y - X), & y > X \end{cases}$$

$$g(x) = \begin{cases} 3y, & y \leq x \\ 4x - y, & y > x \end{cases}$$

$$E(Y) = \int_{-\infty}^{+\infty} g(x)f_X(x)dx$$

$$= \int_{2000}^y (4x - y) \frac{1}{2000} dx + \int_y^{4000} 3y \frac{1}{2000} dx$$

$$= \frac{1}{2000} (-2y^2 + 14000y - 8 \times 10^6)$$

$$\frac{dE(Y)}{dy} = \frac{1}{2000} (-4y + 14000) = 0$$

$$\text{显然, } \frac{d^2 E(Y)}{dy^2} = -\frac{4}{2000} < 0$$

故 $y = 3500$ 时, $E(Y)$ 最大, $E(Y) = 8250$ 万元

3.1.2 方差

随机变量的期望是对随机变量取值平均水平的综合评价, 而方差是衡量随机变量取值波动性的另一个重要数字特征。

定义3.4

若 $E(X - E(X))^2$ 存在, 则称 $E(X - E(X))^2$ 为 X 的方差, 记为

$$\text{Var}(X) = D(X) = E(X - E(X))^2$$

称 $\sigma_X = \sigma(X) = \sqrt{\text{Var}(X)}$ 为 X 的标准差。

标准差的量纲与随机变量的量纲相同。

概率意义:

数学期望反映了 X 取值的中心。

方差反映了 X 取值相对于其取值中心的离散程度。

命题:

$$\text{Var}(X) = 0 \iff P(X = E(X)) = 1$$

若 X 为离散型随机变量, 分布列为

$$P(X = x_k) = p_k, \quad k = 1, 2, \dots$$

$$D(X) = \sum_k^{+\infty} (x_k - E(X))^2 p_k$$

若 X 为连续型随机变量, 概率密度为 $f(x)$

$$D(X) = \int_{-\infty}^{+\infty} (x - E(X))^2 f(x) dx$$

计算方差的常用公式:

$$D(X) = E(X^2) - E^2(X)$$

方差性质

- $D(aX + b) = a^2 D(X)$
- 若 X, Y 相互独立, 则

$$D(X \pm Y) = D(X) + D(Y)$$

- $X_1, \dots, X_n$ 相互独立, $a_1, a_2, \dots, a_n, b$ 为常数

$$D\left(\sum_{i=1}^n a_i X_i + b\right) = \sum_{i=1}^n a_i^2 D(X_i)$$

- 若 X, Y 相互独立 $\Rightarrow E(XY) = E(X)E(Y)$
 $\stackrel{\neq}{\Rightarrow} D(X \pm Y) = D(X) + D(Y)$
- 对任意常数 $C, D(X) \leq E(X - C)^2$, 当且仅当 $C = E(X)$ 时等号成立.

定义3.5 标准化随机变量

设随机变量 X 的期望 $E(X)$ 、方差 $D(X)$ 都存在, 且 $D(X) \neq 0$, 则称

$$X^* = \frac{X - E(X)}{\sqrt{D(X)}}$$

为 X 的标准化随机变量. 显然,

$$E(X^*) = 0, D(X^*) = 1$$

(1) 标准化随机变量消除了各个总体之间的均值、方差和度量单位的差异;

(2) 在实际应用中, 为比较具有同分布的各种不同来源数据的概率特征, 常把数据标准化. 例如, 在比较一名同学在班级的两次不同考试中的学习成绩, 用他的标准分数更合理; 在比较在不同班级的两名同学的学习成绩时, 用各自班的标准分数来比较的合理性就要差一些, 除非两个班级有相同的学习水平。

3.1.3 协方差/相关系数

定义3.6 称

$$Cov(X, Y) = E[X - E(X)][Y - E(Y)]$$

为 X 与 Y 的协方差.

称

$$\begin{pmatrix} D(X) & cov(X, Y) \\ cov(X, Y) & D(Y) \end{pmatrix}$$

为 X, Y 的协方差矩阵

定义3.7

称

$$r_{XY} = \frac{Cov(X, Y)}{\sqrt{Var(X)}\sqrt{Var(Y)}}$$

为 X 与 Y 的相关系数.

若记

$$X^* = \frac{X - E(X)}{\sqrt{D(X)}}, \quad Y^* = \frac{Y - E(Y)}{\sqrt{D(Y)}}$$

则

$$r_{XY} = cov(X^*, Y^*)$$

协方差计算

$$cov(X, Y) = E(XY) - E(X)E(Y)$$

若 (X, Y) 为离散型,

$$cov(X, Y) = \sum_{i=1}^{+\infty} \sum_{j=1}^{+\infty} [x_i - E(X)][y_j - E(Y)]p_{ij}$$

若 (X, Y) 为连续型,

$$cov(X, Y) = \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} [x - E(X)][y - E(Y)]f(x, y)dx dy$$

协方差具有如下的性质：

(1) 对称性： $\text{Cov}(X, Y) = \text{Cov}(Y, X)$;

(2) 若 X 与 Y 相互独立，则 $\text{Cov}(X, Y) = 0$;

(3) 对于任何实数 c ， $\text{Cov}(cX, Y) = \text{Cov}(X, cY) = c\text{Cov}(X, Y)$

(4) $D(\xi_i) = \text{Cov}(\xi_i, \xi_i)$ 。

(5)

$$\text{cov}\left(\sum_{i=1}^n a_i X_i, \sum_{j=1}^n b_j Y_j\right) = \sum_{i=1}^n \sum_{j=1}^n a_i b_j \text{cov}(X_i, Y_j)$$

(6)

$$D\left(\sum_{i=1}^n X_i\right) = \sum_{i=1}^n D(X_i) + 2 \sum_{1 \leq i < j \leq n} \text{cov}(X_i, X_j)$$

若 $X_1, X_2, \dots, X_n$ 相互独立，

$$D\left(\sum_{i=1}^n X_i\right) = \sum_{i=1}^n D(X_i)$$

思考题： 设随机变量 $\xi \sim N(0, 1)$ ，试证明 ξ 与 ξ^2 不相关，但是不独立。

提示：协方差或者相关系数为0，但显然 ξ 与 ξ^2 具有相依关系，非独立。

3.2 大数定律和中心极限定理

当大量重复某一相同试验的时候，其最后的试验结果可能会稳定在某一数值附近。就像抛硬币一样，当不断地抛上千次，甚至上万次，我们会发现，正面或者反面向上的次数都会接近一半；大量的重复试验最终的结果都会趋于稳定，但是这个稳定性到底是什么？怎样去用数学语言把它表达出来？这其中会不会有某种规律性？是必然的还是偶然的？为了回答这些问题，我们在概率论中利用极限理论对随机变量进行了研究。极限理论是概率论的基本理论，其中大数定律和中心极限定理都是研究随机变量序列的极限定理。

大数定律与中心极限定理是现代概率论、统计学、理论科学和社会科学的基石。

3.2.1 大数定律

定义3.8

设 $\{\xi_n, n \geq 1\}$ 为一随机变量序列, ξ 为一随机变量. 如果对任意 $\varepsilon > 0$, 有

$$P(|\xi_n - \xi| > \varepsilon) \rightarrow 0, n \rightarrow \infty,$$

$$\Leftrightarrow P(|\xi_n - \xi| \leq \varepsilon) \rightarrow 1, n \rightarrow \infty,$$

则称 $\{\xi_n, n \geq 1\}$ 依概率收敛到随机变量 ξ , 并记为

$$\xi_n \xrightarrow{P} \xi.$$

3.2.1 大数定律

大数定律有若干个表现形式，这里主要介绍伯努利大数定律、辛钦大数定律和 Chebyshev 大数定理。

伯努利大数定律：设 n_A 是 n 次独立重复试验中事件 A 发生的次数， p 是事件 A 在每次试验中发生的概率，则对任意正数 ε ，有

$$\lim_{n \rightarrow \infty} P \left\{ \left| \frac{n_A}{n} - p \right| < \varepsilon \right\} = 1 \quad \text{或} \quad \lim_{n \rightarrow \infty} P \left\{ \left| \frac{n_A}{n} - p \right| \geq \varepsilon \right\} = 0。$$

辛钦大数定律：设随机变量 $X_1, X_2, \dots, X_n, \dots$ 相互独立，服从同一分布，且具有数学期望 $E(X_i) = \mu, i = 1, 2, \dots$ 则对任意给定的正数，有

$$\lim_{n \rightarrow \infty} P \left\{ \left| \frac{1}{n} \sum_{i=1}^n X_i - \mu \right| < \varepsilon \right\} = 1$$

辛钦大数定律告诉我们：随着样本数量 n 增大，样本均值几乎必然等于总体真实的均值，从而为统计推断中依据样本平均数估计总体平均数提供了理论依据。例如，要估计某地区的平均亩产量，可收割有代表性的地块 n 块，计算其平均亩产量，则当 n 较大时，可用它作为整个地区平均亩产量的一个估计，此类做法在实际应用中具有重要意义。

Chebyshev大数定律

设随机变量序列 $X_1, X_2, \dots, X_n, \dots$ 相互独立, 且具有相同的数学期望和方差.

$$E(X_k) = \mu, \quad D(X_k) = \sigma^2, \quad k = 1, 2, \dots$$

则 $\forall \varepsilon > 0$ 有

$$\lim_{n \rightarrow \infty} P\left(\left|\frac{1}{n} \sum_{i=1}^n X_i - \mu\right| \geq \varepsilon\right) = 0$$

或

$$\lim_{n \rightarrow \infty} P\left(\left|\frac{1}{n} \sum_{i=1}^n X_i - \mu\right| < \varepsilon\right) = 1$$

Chebyshev大数定律

更一般:

设 $X_1, X_2, \dots, X_n, \dots$ 两两不相关, 不一定有相同的数学期望与方差, 可设

$$E(X_k) = \mu_k, \quad D(X_k) = \sigma_k^2 \leq \sigma^2, \quad k = 1, 2, \dots$$

则有

$$\lim_{n \rightarrow \infty} P\left(\left|\frac{1}{n} \sum_{k=1}^n X_k - \frac{1}{n} \sum_{k=1}^n \mu_k\right| \geq \varepsilon\right) = 0$$

3.2.2 中心极限定理

林德贝格-勒维(Lindeberg-Levy)中心极限定理

设随机变量序列 $X_1, X_2, \dots, X_n, \dots$ 独立同一分布, 且有期望和方差:

$$E(X_k) = \mu, D(X_k) = \sigma^2 > 0, k = 1, 2, \dots$$

则对于任意实数 x ,

$$\lim_{n \rightarrow \infty} P\left(\frac{\sum_{k=1}^n X_k - n\mu}{\sqrt{n}\sigma} \leq x\right) = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^x e^{-\frac{t^2}{2}} dt = \Phi(x)$$

3.2.2 中心极限定理

棣莫弗—拉普拉斯(DeMoivre-Laplace)中心极限定理

设 μ_n 为服从二项分布 $b(n, p)$ 的随机变量, 则当 n 充分大时, 有

$$\lim_{n \rightarrow \infty} P\left\{\frac{\mu_n - np}{\sqrt{npq}} \leq y\right\} = \Phi(y)$$

注: 这是林德贝格—勒维中心极限定理的特例.

3.2.2 中心极限定理

林德贝格(Lindeberg)中心极限定理

设 $\{X_n\}$ 是一系列相互独立的连续随机变量, 它们具有有限的期望 $\mathbb{E}X_i = \mu_i$ 和方差 $\mathbb{D}X_i = \sigma_i^2$, 记 $Y_n = \sum_{i=1}^n X_i$, $\mathbb{D}Y_n = \sum_{i=1}^n \sigma_i^2 = B_n^2$, 记 X_i 的密度函数是 $p_i(x)$, 若

$$\forall \tau > 0 : \lim_{n \rightarrow \infty} \frac{1}{\tau^2 B_n^2} \sum_{i=1}^n \int_{|x - \mu_i| > \tau B_n} (x - \mu_i)^2 p_i(x) dx = 0$$

则

$$\lim_{n \rightarrow \infty} P \left(\frac{1}{B_n} \sum_{i=1}^n (X_i - \mu_i) < a \right) = \Phi(a)$$

3.2.2 中心极限定理

李雅普诺夫中心极限定理

设 $\{X_n\}$ 为独立随机变量序列, 若存在 $\delta > 0$, 满足:

$$\lim_{n \rightarrow \infty} \frac{1}{B_n^{2+\delta}} \sum_{i=1}^n E \left(|X_i - \mu_i|^{2+\delta} \right) = 0$$

则

$$\lim_{n \rightarrow \infty} P \left\{ \frac{1}{B_n} \sum_{i=1}^n (X_i - \mu_i) \leq y \right\} = \Phi(y)$$

注: 李雅普诺夫中心极限定理是林德贝格中心极限定理的推论

【例3.5】

设 $X_1, X_2, \dots, X_{99}$ 相互独立, 且服从不同的0-1分布 $P(X_i = 1) = p_i = 1 - \frac{i}{100}$, 试求 $P\left(\sum_{i=1}^{99} X_i \geq 60\right)$

解: 设 $X_{100}, X_{101}, \dots$ 相互独立, 且与 X_{99} 同分布, 则可以验证 $\{X_n\}$ 满足 $\delta = 1$ 的李雅普诺夫条件,

且 $E\left(\sum_{i=1}^{99} X_i\right) = 49.5$, $Var\left(\sum_{i=1}^{99} X_i\right) = 16.665$ 由此得

$$P\left(\sum_{i=1}^{99} X_i \geq 60\right) = P\left\{\frac{\sum_{i=1}^{99} X_i - 49.5}{\sqrt{16.665}} \geq \frac{60 - 49.5}{\sqrt{16.665}}\right\}$$

$$\approx 1 - \Phi(2.5735) = 0.005$$

提示
 $X_1, \dots, X_{99}$
只是独立,
不同分布。

【例 3.6】

二项分布的近似计算:

例: 设有一批种子, 其中良种占 $1/6$. 试估计在任选的6000粒种子中, 良种比例与 $1/6$ 比较上下不超过1%的概率。

解: 设 X 表示6000粒种子中的良种数, 则

$$X \sim B(6000, 1/6)$$

由德莫佛—拉普拉斯中心极限定理, 近似有

$$X \sim N\left(1000, \frac{5000}{6}\right)$$

$$P\left(\left|\frac{X}{6000} - \frac{1}{6}\right| < 0.01\right) = P(|X - 1000| < 60)$$

$$\approx \Phi\left(\frac{1060 - 1000}{\sqrt{5000/6}}\right) - \Phi\left(\frac{940 - 1000}{\sqrt{5000/6}}\right)$$

$$= \Phi\left(\frac{60}{\sqrt{5000/6}}\right) - \Phi\left(\frac{-60}{\sqrt{5000/6}}\right)$$

$$= 2\Phi\left(\frac{60}{\sqrt{5000/6}}\right) - 1 \approx 0.9624$$

二项分布是离散型分布, 而正态分布是连续型分布, 所以用正态分布作为二项分布近似时, 可做如下修正: 设 $\mu_n \sim B(n, p)$,

$0 < p < 1$. 则 $E\mu_n = np$, $Var(\mu_n) = npq$, 其中 $q = 1 - p$.

$$P(\mu_n = k) = P(k - 0.5 < \mu_n < k + 0.5)$$

(上式因为 μ_n 是取整数的, 左右放 0.5 不影响其概率)

$$\begin{aligned} &= P\left(\frac{k - 0.5 - E\mu_n}{\sqrt{Var(\mu_n)}} < \frac{\mu_n - E\mu_n}{\sqrt{Var(\mu_n)}} < \frac{k + 0.5 - E\mu_n}{\sqrt{Var(\mu_n)}}\right) \\ &\approx \Phi\left(\frac{k + 0.5 - np}{\sqrt{npq}}\right) - \Phi\left(\frac{k - 0.5 - np}{\sqrt{npq}}\right) \quad (\text{应用中心极限定理}). \end{aligned}$$

如果 $P(\mu_n = k) = P\left(\frac{\mu_n - E\mu_n}{\sqrt{Var(\mu_n)}} = \frac{k - E\mu_n}{\sqrt{Var(\mu_n)}}\right)$, 但是连续型取点的概率为 0, 二项分布取点的概率非 0. 所以需要上述 μ_n 取值左右加减 0.5 变换再用正态分布近似计算.

◀ ▶ ◀ ▶ ◀ ▶ ◀ ▶ ◀ ▶ ◀ ▶ ◀ ▶

棣莫弗—拉普拉斯定理三个应用

设 μ_n 为服从二项分布 $b(n, p)$ 的随机变量, 则当 n 充分大时, 有

$$\lim_{n \rightarrow \infty} P\left\{\frac{\mu_n - np}{\sqrt{npq}} \leq y\right\} = \Phi(y)$$

- i) 已知 n 和 y , 求概率;
- ii) 已知 n 和概率, 求 y ;
- iii) 已知 y 和概率, 求 n .

给定n和y, 求概率

例:100个独立工作(工作的概率为0.9)的部件组成一个系统, 求系统中至少有85个部件工作的概率.

解: 用 $X_i = 1$ 表示第 i 个部件正常工作, 反之记为 $X_i = 0$ 又记 $Y = X_1 + X_2 + \cdots + X_{100}$, 则 $E(Y) = 90$, $Var(Y) = 9$. 由此得:

$$P\{Y \geq 85\} \approx 1 - \Phi\left(\frac{85 - 0.5 - 90}{\sqrt{9}}\right) = 0.966$$

给定n和概率, 求y

例:有200台独立工作(工作的概率为0.7)的机床, 每台机床工作时需15kw电力. 问共需多少电力, 才可有95%的可能性保证正常生产?

解: 用 $X_i = 1$ 表示第 i 台机床正常工作, 反之记为 $X_i = 0$ 又记 $Y = X_1 + X_2 + \cdots + X_{200}$, 则 $E(Y) = 140$, $Var(Y) = 42$. 设供电量为 y , 则从

$$P\{15Y \geq y\} \approx 1 - \Phi\left(\frac{y/15 + 0.5 - 140}{\sqrt{42}}\right) \geq 0.95$$

中解得

$$y \geq 2252$$

给定 y 和概率，求 n

例:用调查对象中的收看比例 k/n 作为某电视节目的收视率 p 的估计。要有90%的把握，使 k/n 与 p 的差异不大于0.05，问至少要调查多少对象？

解：用 Y_n 表示 n 个调查对象中收看此节目的人数，则 Y_n 服从 $b(n, p)$ 分布， k 为 Y_n 的实际取值。根据题意

$$P(|Y_n/n - p| < 0.05) \approx 2\Phi\left(0.05\sqrt{n/p(1-p)}\right) - 1 \geq 0.90$$


从中解得

$$0.05\sqrt{n/p(1-p)} \geq 1.645$$

又由 $p(1-p) \leq 0.25$ 可解得

$$n \geq 270.6, n = 271$$

【例 3.7】 高尔顿钉板实验是中心极限定理重要案例，请编程实现这个实验。



3.3 数理统计基本概念

在概率论中，我们是在假设随机变量的分布已知的前提下去研究它的规律性，但在数理统计中，研究的随机变量的分布是未知的，或者只知道它具有某种形式，其中包含着未知参数。只能通过对所研究的随机变量进行重复独立的观察，得到大量观察数据后进行统计分析，从而对所研究的随机变量的分布作出种种推断。

3.3.1 简单随机抽样

从总体中抽取的样本如果满足下述两个条件，则这种随机的、独立的抽样方法称为简单随机抽样。

- (1) 代表性：因抽取样本要反映总体，自然要求每个个体和总体具有相同分布。
- (2) 独立性：各次抽取必须是相互独立的，即每次抽样的结果既不影响其他各次抽样的结果，也不受其他各次抽样结果的影响。满足这两个条件的样本称为简单随机样本，也是我们常说的独立同分布样本。

从总体中抽取容量为 n 的样本，也就是对代表总体的随机变量 X 随机独立地进行了 n 次试验，每次试验结果可以看作一个随机变量 X_i ， n 次试验得到随机变量序列 $X_1, X_2, \dots, X_n$ ，它们相互独立，且与总体服从相同的分布。将得到的样本实际观测值设为 $x_1, x_2, \dots, x_n$ ，也可以认为发生了相互独立的事件 $X_1=x_1, X_2=x_2, \dots, X_n=x_n$ 。

3.3.2 常用的统计量

在实际应用中，对总体进行统计推断时，往往不是直接使用样本本身，而是针对问题构造一些样本的函数 $g(X_1, X_2, \dots, X_n)$ ，然后利用这些样本函数对总体进行统计推断。若样本函数 $g(X_1, X_2, \dots, X_n)$ 中不含有任何未知量，则称这类样本函数为统计量。

(1) 样本均值 $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$ 。

(2) 样本方差 $S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2 = \frac{1}{n-1} \left(\sum_{i=1}^n X_i^2 - n\bar{X}^2 \right)$ 。

(3) 样本标准差 (均方差) $S = \sqrt{S^2} = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2}$ 。

(4) 样本 k 阶矩:

原点 k 阶矩 $A_k = \frac{1}{n} \sum_{i=1}^n X_i^k, k=1,2,\dots$

中心 k 阶矩 $B_k = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^k, k=2,3,\dots$

上述统计量统称为矩统计量, 简称为样本矩, 它们都是样本 $X_1, X_2, \dots, X_n$ 的函数, 因此也是随机变量。

【例 3.8】 从一批袋装糖果中随机抽取 8 袋, 测得其质量 (单位: g) 为 230, 243, 185, 240, 228, 196, 246, 200。

- (1) 写出总体、样本、样本值及样本容量。
- (2) 求样本均值、样本方差及样本二阶原点矩。
- (3) 在 R 中求样本的均值、方差和标准差的 3 种方法。

解: 总体: 一批袋装糖果; 样本: 随机抽取 8 袋, 重量(单位:g) 230, 243, 185, 240, 228, 196, 246, 200; 样本容量 8。

样本均值

```
#install.packages("moments")
> library(moments)
> a<-c(230,243,185,240,228,196,246,200)
> mean(a)
[1] 221
> var(a)
[1] 566
> moment(a,order = 2)
[1] 49336.25
```

3.3.3 参数估计

在实际问题中，当所研究的总体分布类型已知，但分布中含有一个或多个未知参数时，如何根据样本来估计未知参数？这就是参数估计问题。例如，灯泡的寿命 X 是一个总体，根据实际经验可知， X 服从 $N(\mu, \sigma^2)$ ，但参数 μ, σ^2 是未知的，

μ, σ^2 为待估计的参数。此类问题就属于参数估计问题。

参数估计问题分为点估计与区间估计两类。所谓点估计就是构造一个统计量，用该统计量的观察值作为总体未知参数的估计值；区间估计就是对于未知参数给出一个范围，并且在一定的可靠度下使这个范围内包含未知参数。

参数估计问题的一般思路：设有一个总体分布函数 $F(x, \theta)$ ，其中 θ 为未知参数 (θ 也可以是向量)，构造一个适当的统计量 $\hat{\theta} = \hat{\theta}(x_1, x_2, \dots, x_n)$ ，现从该总体中随机抽样，得样本值 $x_1, x_2, \dots, x_n$ ，代入统计量公式中，求出的称为 θ 的估计值。

常用的参数估计方法有点估计和区间估计等，这里不再一一介绍，下面介绍在机器学习领域应用广泛的极大似然估计和贝叶斯估计（最大后验估计）。

8.4 最大似然估计

最大似然估计是在总体的分布类型已知的前提下使用的一种参数估计法。在自然生活中，观察到的某种现象产生的原因可能有很多种，但要判断出到底是哪种原因时，**人们往往选择可能性最大的一种或者说是概率最大的**，这就是最大似然估计的思想。

3.4.1 似然函数

给定联合样本值 x 关于参数 θ 的似然函数如下：

$$L(x; \theta) = f(x | \theta), \text{ 其中 } \theta \text{ 是未知参数。}$$

似然函数 $L(x; \theta)$ 是一个概率(密度)函数 $f(x | \theta)$ ，表示在参数 θ 下样本数据发生的可能性。例如，现在有一批往年下雨的数据样本 X ，是否下雨是由某些气象指标控制，如参数 θ 表示空气的湿度， $L(x; \theta)$ 就表示在湿度参数 θ 下下雨的可能性，参数 θ 可以取值 $\theta_1, \theta_2, \dots, \theta_n$ ，每个参数 θ_i 会得到对应的似然函数值。如果某个 θ_i 似然函数值大，代表该样本在参数 θ_i 下发生的可能性更大些，所以把它称为“似然函数”，用来表示参数 θ 取值和样本数据的关联程度。

8.4.2 最大似然估计

最大似然估计 (Maximum Likelihood Estimation, MLE) 是概率论中一个很常用的估计方法, 对同一个似然函数, 如果存在一个参数值 $\hat{\theta}$, **使得似然函数值达到最大**的话, 那么这个值就最为 “合理”, $\hat{\theta}$ 称为参数 θ 的最大似然估计, 简言之, 概率最大的事件, 最有可能发生。

求未知参数 θ 的最大似然估计问题, 归结为求似然函数 $L(x; \theta)$ 的最大值点的问题。当似然函数关于未知参数可微时, 可利用微分学中求最大值的方法来求解。

求最大似然估计的主要步骤如下。

(1) 写出似然函数 $L(x; \theta) = L(x_1, x_2, \dots, x_n; \theta)$ 。

(2) 对似然函数或对数似然函数求导, 令 $\frac{dL(x; \theta)}{d\theta} = 0$ 或 $\frac{d \ln L(x; \theta)}{d\theta} = 0$, 求出 θ 的最大似然估计。

因函数 $\ln L$ 是 L 的单调递增函数, 且函数 $\ln L(x; \theta)$ 与函数 $L(x; \theta)$ 有相同的极值点, 故转化为求函数 $\ln L(x; \theta)$ 的最大值点较方便。

【例 3.9】 假设 $X_1, X_2, \dots, X_n$ 来自总体正态分布 $N(\mu, \sigma^2)$ 的简单随机样本，其中 $\mu \in R$ ， $\sigma^2 > 0$ 。记 $\theta = (\mu, \sigma^2)$ 。给出 μ 和 σ^2 的极大似然估计量 (MLE) $\hat{\mu}^*$ 和 $\hat{\sigma}_*^2$ ，并讨论 $\hat{\sigma}_*^2$ 的无偏性。如果不满足无偏性，请修正其为一无偏估计。进一步，给出 $g(\theta) = \frac{\mu}{\sigma^2}$ 的 MLE $\hat{g}^*$ 。↵

解：由于 $X_1, X_2, \dots, X_n$ 来自总体正态分布 $N(\mu, \sigma^2)$ 的简单随机样本，其中 $\mu \in R$ ，

$\sigma^2 > 0$ ，故样本 $X = (X_1, X_2, \dots, X_n)$ 的概率密度函数为↵

$$f(x, \theta) = \left(\frac{1}{\sqrt{2\pi\sigma^2}} \right)^n \exp \left\{ -\frac{\sum_{i=1}^n (x_i - \mu)^2}{2\sigma^2} \right\}, \quad \leftarrow$$

解得↵

$$\hat{\mu}^* = \frac{1}{n} \sum_{i=1}^n X_i = \bar{X} \text{ 和 } \hat{\sigma}_*^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2 = S_n^2. \quad \leftarrow$$

其中 $x = (x_1, \dots, x_n)$ 。对数似然函数为↵

由于正态分布是指数族，所以易知 $\hat{\mu}^*$ 和 $\hat{\sigma}_*^2$ 为 μ 和 σ^2 的 MLE。↵

$$l(\theta, x) = \log(f(x, \theta)) = -\frac{n}{2} \log(2\pi) - \frac{n}{2} \log(\sigma^2) - \frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2. \quad \leftarrow$$

另一方面，由于 $E\hat{\sigma}_*^2 = ES_n^2 = \frac{n-1}{n}\sigma^2 \neq \sigma^2$ ，所以 $\hat{\sigma}_*^2$ 是 σ^2 的有偏估计。从而

似然方程组为↵

$\frac{n}{n-1}\hat{\sigma}_*^2$ 为 σ^2 无偏估计。进一步，有 MLE 性质知， $g(\theta) = \frac{\mu}{\sigma^2}$ 的 MLE 为 ↵

$$\begin{cases} \frac{\partial l(\theta, x)}{\partial \mu} = \frac{1}{\sigma^2} \sum_{i=1}^n (x_i - \mu) = 0 \\ \frac{\partial l(\theta, x)}{\partial \sigma^2} = -\frac{n}{2\sigma^2} + \frac{1}{2\sigma^4} \sum_{i=1}^n (x_i - \mu)^2 = 0 \end{cases} \quad \leftarrow$$

$$\hat{g}^* = \frac{\hat{\mu}^*}{\hat{\sigma}_*^2} = \frac{\bar{X}}{S_n^2}. \quad \leftarrow$$

3.5 最大后验估计

最大似然估计中把待估计的参数 θ 看作确定性的量（只是其取值未知），在抽取样本之前，我们对 θ 一无所知，所有的信息全部来自样本，参数估计是使取样本观测值概率最大的值。贝叶斯学派是数理统计学中的一大学派，他们认为在进行试验之前，未知参数 θ 已经有了一定的知识，叫作 θ 的先验知识，这里“先验”表示知识是在试验之前就有了。先验知识可以用参数 θ 的某种概率分布表达，记为 $P(\theta)$ 当试验后得到样本 X ，那么在已知样本 X 的条件下，再推断参数 θ 值的概率分布，称之为后验概率，记为 $P(\theta|X)$ 。

利用贝叶斯公式求解最大后验估计。

【例 3.10】 假设有 5 个袋子，各袋中都有无限量的饼干（樱桃口味或柠檬口味），已知 5 个袋子中两种口味的比例如下：袋子 1：樱桃 100%；袋子 2：樱桃 75% + 柠檬 25%；袋子 3：樱桃 50% + 柠檬 50%；袋子 4：樱桃 25% + 柠檬 75%；袋子 5：柠檬 100%。设拿到袋子 1 或袋子 5 的概率都是 0.1，拿到袋子 2 或袋子 4 的概率都是 0.2，拿到袋子 3 的概率是 0.4。

问从同一个袋子中连续拿到 2 个柠檬饼干，那么这个袋子最有可能是上述 5 个袋子中的哪一个？
解：记 H_i 为第 i 个袋子，其被拿到的先验概率为

$$P(H_1)=0.1, P(H_2)=0.2, P(H_3)=0.4, P(H_4)=0.2, P(H_5)=0.1$$

记 D 为连续拿出 2 个柠檬饼干事件，则

$$P(D | H_1)=0, P(D | H_2)=0.25^2, P(D | H_3)=0.5^2, P(D | H_4)=0.75^2, P(D | H_5)=1$$

利用贝叶斯公式计算后验概率

$$P(H_i|D) = \frac{P(D|H_i)P(H_i)}{\sum_{j=1}^5 P(D|H_j)P(H_j)}$$

则后验概率计算分为为：

$$P(H_1 | D)=0/0.325=0, P(H_2 | D)=0.0125/0.325, P(H_3 | D)=0.1/0.325,$$

$$P(H_4 | D)=0.1125/0.325, P(H_5 | D)=0.1/0.325$$

最大后验概率是 H_4 ，即袋子 4（樱桃 25%，柠檬 75%）

朴素贝叶斯是基于最大后验概率和特征条件独立假设的分类方法，其分类原理是根据某对象的先验概率和类条件概率计算出其后验概率，然后选择具有最大后验概率的类作为该对象所属的类。

朴素贝叶斯分类器的公式如下：

假设某样本 X 有 n 项特征 (Feature)，分别为 $F_1, F_2, \dots, F_n$ ，有 m 个类别 (Category)，分别为 $C_1, C_2, \dots, C_m$ 。贝叶斯分类器就是计算出样本 X 后验概率最大的分类，即求下面这个公式的最大值。

$$P(C_i | F_1 F_2 \dots F_n) = \frac{P(F_1 F_2 \dots F_n | C_i) P(C_i)}{P(F_1 F_2 \dots F_n)}, i = 1, 2, \dots, m$$

【课后练习题】 利用极大似然估计和贝叶斯估计，求解机器学习领域中相关实例分析问题。