

# 统计学概论

杨文志  
安徽大学大数据与统计学院  
wzyang@ahu.edu.cn

## 第5章 随机数与抽样模拟

- 一元随机数产生
- 多元随机数产生
- 随机抽样
- 统计模拟

## 5.1 一元随机数产生

### ● 均匀分布随机数

- 均匀分布 $U(a,b)$  的密度函数为

$$f(x) = \begin{cases} \frac{1}{b-a}, & a < x < b \\ 0, & \text{else} \end{cases}$$

可以直接使用R语言中stats包中的runif()函数生成均匀分布随机数，其句法是：

```
> runif(n, min=0, max=1)
```

- 其中n表示生成的随机数数量，min表示均匀分布下限，max表示均匀分布上限，若省略参数min、max，则默认生成[0,1]上的均匀分布随机数。
- runif()默认每次生成的随机数是不一样的。有时在做模拟时，为比较不同方法的好坏，需要生成的随机数都要一样(即重复生成同样的随机数)，可以使用set.seed()设定随机数种子，其参数为整数。


```
> set.seed(1) #种子取一样，生成的随机数相同
> runif(3)
[1] 0.1297134 0.9822407 0.8267184
```

## 5.1 一元随机数产生

### ● 均匀分布随机数

- 接下来，我们检验一下runif()生成的随机数的性质。通过直方图和散点图以及自相关系数图来检验独立同分布。从下图中可以看出，基本上满足独立同分布性质。

```
> Nsim=10^3
> x=runif(Nsim)
> x1=x[-Nsim] #因为要求自相关系数，去掉最后一个数
> x2=x[-1] #去掉第一个数
> par(mfrow=c(1,3))
> hist(x,prob=T,col="blue",main="uniform on [0,1]") #直方图
> curve(dunif(x,0,1),add=T,col="red") #添加均匀分布密度函数线
> plot(x1,x2,col="red",pch=17)
> acf(x)#画自相关系数图
```



## 5.1 一元随机数产生


### ● 正态分布随机数

➤ 同样，R中也提供了可以直接生成正态分布随机数的函数：rnorm()，其句法是：

```
> rnorm(n, mean=0, sd=1)
```

➤ 其中，n表示生成的随机数数量，mean是正态分布均值，默认为0，sd是正态分布标准差，默认时为1。例如：

```
> rnorm(3,10,5) #产生3个均值为10标准差为5的正态分布随机数
[1] 8.826333 10.861766 9.751118
> rnorm(3) # 默认3个生成标准正态分布随机数
[1] -1.0402282 -0.4409729 0.6897580
x=rnorm(1000)
hist(x,prob=T,main="normal mu=0,sigma=1",col="blue") #作直方图
curve(dnorm(x),add=T,col="red")
#在直方图上添加标准正态分布密度函数线
```



## 5.1 一元随机数产生

### ● 二项分布随机数

➤ 二项分布是指n次独立重复贝努力试验（Bernoulli trials）成功次数的分布，每次贝努力试验的结果只有两个，成功和失败，记成功的概率为p。如果一个变量x服从二项分布，记为 $x \sim B(n,p)$ ，n表示试验次数，p表示成功概率。它的概率密度函数为：

$$P\{X = k\} = C_n^k p^k (1-p)^{n-k}, \quad k = 0, 1, 2, \dots, n$$

➤ R中直接生成二项分布随机数的函数是rbinom()，其句法是：

```
> rbinom(n, size, prob)
```

- 其中n表示生成的随机数数量，size表示进行贝努力试验的次数，prob表示一次贝努力试验成功的概率。
- 首先，我们生成二点分布（一次贝努力试验）的随机数。

```
> size=1; p=0.4
> rbinom(10,size,p)
[1] 0 0 1 0 1 1 0 0 1 0
```

## 5.1 一元随机数产生

### ● 二项分布随机数

- 接下来，我们生成服从 $B(10,0.4)$ 的二项分布随机数。


```
> size=10; p=0.4
> rbinom(5,size,p) # 生成5个服从B(10,0.4)的二项分布随机数
[1] 5 3 4 5 6
```

- 二项分布是离散分布，但随着试验次数 $n$ 的增加，二项分布越来越接近于正态分布。下面将分别产生100个 $n$ 为10, 20, 50, 概率 $p$ 为0.4的二项分布随机数：

```
> par(mfrow=c(1,3))
> p=0.4
> for( n in c(10,20,50)){
  x=rbinom(100,n,p)
  hist(x,prob=T,main=paste("n =",n),col=rainbow(n))
  xvals=0:n
  points(xvals,dbinom(xvals,n,p),type="h",lwd=3)
}
```

## 5.1 一元随机数产生

- 从图中可以看出，随着实验次数 $n$ 的增大，二项分布越来越接近于正态分布。



## 5.1 一元随机数产生

### ● 常见分布函数表

- 除了生成上面介绍的几种分布的随机数，还可以生成poisson分布、t分布、F分布等多种分布的随机数，只要在相应的分布名前加“r”就可以。

| 分布                  | 中文名称    | R中的表达     | 参数              |
|---------------------|---------|-----------|-----------------|
| Beta                | 贝塔分布    | beta()    | shape1, shape2  |
| Binomial            | 二项分布    | binom()   | size, prob      |
| Cauchy              | 柯西分布    | cauchy( ) | location, scale |
| Chi-square          | 卡方分布    | chisq()   | df              |
| Exponential         | 指数分布    | exp()     | rate            |
| F                   | F分布     | f()       | df1, df2        |
| Gamma               | 伽玛分布    | gamma()   | shape, rate     |
| Geometric           | 几何分布    | geom()    | prob            |
| Hypergeometric      | 超几何分布   | hyper()   | m, n, k         |
| Logistic            | 逻辑分布    | logis()   | location, scale |
| Negative binomial   | 负二项分布   | nbinom()  | size, prob      |
| Normal              | 正态分布    | norm()    | mean, sd        |
| Multivariate normal | 多元正态分布  | mvnorm()  | mean, cov       |
| Poisson             | 泊松分布    | pois()    | lambda          |
| T                   | t分布     | t()       | df              |
| Uniform             | 均匀分布    | unif()    | min, max        |
| Weibull             | 威布凡分布   | weibull() | shape, scale    |
| Wilcoxon            | 威尔考可森分布 | wilcox()  | m, n            |

与分布相关的函数及代码

- r- 生成相应分布的随机变量  
d- 生成相应分布的密度函数  
p- 生成相应分布的累积概率密度函数  
q- 生成相应分布的分位数函数

例如

- rnorm 产生正态随机变量  
dnorm 产生正态分布密度函数  
pnorm 产生正态分布累积密度函数  
qnorm 产生正态分布的分位数函数

## 5.2 多元随机数产生

### ● 多元正态分布随机数

- 多元正态分布随机数可以使用MASS包中的mvnorm(), 其使用方法是：

```
> mvnorm(n, mu, Sigma, tol = 1e-6, empirical = FALSE, EISPACK = FALSE)
```

- 其中n是生成的随机数个数，mu是均值向量，Sigma是协方差阵，tol是容忍度，empirical是逻辑参数，取TRUE时，mu和sigma取经验均值和协方差阵。  
➤ 假设要生成一个p维多元正态随机数 $X=(x_1, x_2, \dots, x_p)$ ，它的均值为u，方差为 $\Sigma$ ，可以将X写成如下形式：

$$x_i = a_{i1}Z_1 + \dots + a_{ip}Z_p + \mu_i, i = 1, \dots, p$$


- 其中 $Z=(Z_1 \dots Z_p)$ 服从独立标准正态分布。可以证明： $\Sigma = Cov(x_i, x_j) = \sum_{k=1}^p a_{ik}a_{jk} = AA'$   
➤ 其中A为p×p维矩阵。我们可以使用Cholesky分解等方法对方差 $\Sigma$ 进行分解。对 $Z=(Z_1 \dots Z_p)$ 中 $Z_1 \dots Z_p$ 由iidN(0,1)换成其他分布随机数，用以上方法可以产生p维非正态随机数。

## 5.2 多元随机数产生

### ● 多元正态分布随机数

- 如果需要产生均值都为0，协方差矩阵为 $\begin{pmatrix} 5 & 2 \\ 2 & 1 \end{pmatrix}$ 的二元正态分布随机数。

```
>#install.packages("MASS")
> library(MASS) #载入MASS包
> Sigma <- matrix(c(5,2,2,1),2,2) #生成协方差矩阵
> x=mvrnorm(n=1000, rep(0, 2), Sigma)
> head(x ,n=3L)
      [,1]      [,2]
[1,] -2.936373 -1.6623149
[2,] -1.390695 -0.3952741
[3,]  2.419697  1.8233755
> var(x)
      [,1]      [,2]
[1,]  4.97430  1.995510
[2,]  1.99551  1.011414
>plot(x,col= "red ")
```



## 5.2 多元随机数产生

### ● 多元正态分布密度函数、分位数与累积概率

- 与生成一元随机数类似，pmvnorm()可以计算累积概率（mvtnorm包），其用法是

```
> pmvnorm(lower=-Inf, upper=Inf, mean=rep(0, length(lower)), corr=NULL, sigma=NULL,
algorithm = GenzBretz(), ...)
```

- 其中lower是求累积概率的下限，默认为 $-\infty$ 。upper是求累积概率的上限，默认为 $+\infty$ 。  
mean是多元正态分布的均值向量，corr是多元正态分布的相关系数矩阵，sigma是协方差矩阵，其中相关系数矩阵和协方差阵两者只要知道一个即可。Algorithm是计算累积概率的算法，R提供了 GenzBretz, Miwa 和 TVPACK，默认为 GenzBretz算法。
- 同样道理，求多元正态分布的密度函数可以用dmvnorm()，求其分位数可以用qmvnorm()。

## 5.2 多元随机数产生

### ● 多元正态分布随机数

- 计算均值为0，相关系数矩阵为 $\begin{pmatrix} 1 & 0.5 & 0.5 \\ 0.5 & 1 & 0.5 \\ 0.5 & 0.5 & 1 \end{pmatrix}$ 的3元正态分布随机数。求其下限为(-1,-1,-1)，上限为(1,1,1)的累积概率。

```
> #install.packages("mvtnorm")
> library(mvtnorm)
> mean <- rep(0, 3) #均值向量
> lower <- rep(-1, 3) #下限
> upper <- rep(1, 3) #上限
> corr <- diag(3) #相关系数矩阵
> corr[lower.tri(corr)] <- 0.5 #相关系数矩阵下三角用0.5赋值
> corr[upper.tri(corr)] <- 0.5 #相关系数矩阵上三角用0.5赋值
> pmvnorm(lower, upper, mean, corr)
[1] 0.3756943
attr("error")
[1] 5.435729e-05
attr("msg")
[1] "Normal Completion"
```

## 5.3 随机抽样

### ● 放回与无放回抽样

- R可以进行有放回、无放回抽样。用R语言进行抽样很简单，只要用sample()函数就可以了，其用法是

```
> sample(x, n, replace = F, prob = NULL)
```

其中x表示总体向量，可以是数值、字符、逻辑向量。n表示样本容量，replace = F，表示无放回抽样，replace = T表示有放回抽样，默认是无放回抽样，prob可以设置各个抽样单元不同的入样概率进行抽样。

- 可以用R来模拟重复掷一颗六面的骰子和掷两颗六面的骰子5次的结果。

```
> sample(1:6,5,rep=T) #掷一颗六面的骰子，重复5次
[1] 1 2 4 2 1
> dice=as.vector(outer(1:6,1:6,paste)) #掷两颗六面的骰子所有可能的结果
> sample(dice,5,replace=T) #重复5次
[1] "5 5" "3 5" "2 1" "3 6" "5 3"
```

## 5.3 随机抽样

### ● 分层抽样

- 分层抽样是指先将目标按照某一准则分成若干层，再对每一层进行简单随机抽样。比如：一个班级共有40个人，其中10个女生，30个男生，我们希望从中抽取2个女生和3个男生参加比赛。这种情形下，可以按照性别将学生分为“男”和“女”两层，而后再分别抽取2个女生和3个男生。R中可以使用sampling包中的strata函数进行抽取，语句为：

```
>strata(data, stratanames=NULL, size, method=c("srswor","srswr","poisson","systematic"))
```

其中stratanames是抽样依据的变量，size是每个种类抽样的数目，method是抽样的方法，包括“srswor”（无放回随机抽样）、“srswr”（有放回随机抽样）等。

## 5.3 随机抽样

- chickwts数据集是不同饮食种类对小鸡生长速度的影响，包括小鸡的体重“weight”变量和饮食种类“feed”变量，其中饮食种类包括“horsebean”、“linseed”、“soybean”、“sunflower”、“meatmeal”以及“casein”，共六类。要求从饮食种类中各抽取一个样本。代码如下：

```
>install.packages("sampling")
> library(sampling)
> strata(chickwts,stratanames=("feed"),size=rep(1,6),method="srswor")
  Feed  ID_unit  Prob  Stratum
2 horsebean    2  0.1000000    1
17 linseed   17  0.0833333    2
36 soybean   36  0.0714285    3
39 sunflower  39  0.0833333    4
49 meatmeal  49  0.0909090    5
62 casein    62  0.0833333    6
```



## 5.4 统计模拟

- R具有模拟各种类型随机数的功能，我们将借助随机数的生成，以中心极限定理的验证为例进行说明。中心极限定理是数理统计中非常重要的定理，很多定理和统计推断都建立在中心极限定理的基础上。

### ● 直方图模拟

- 我们以二项分布模拟中心极限定理为例进行说明。对于二项分布，假如 $Z \sim B(n, p)$ ，则其标准化变量为：

$$x = \frac{z - np}{\sqrt{np(1-p)}}$$

- 随着 $n \rightarrow \infty$ ， $X$ 的分布依概率收敛于标准正态分布。该定理也称为德莫弗 - 拉普拉斯定理。至于这个定理是否正确，除了数学上的严格证明外，也可用统计模拟方法检验它。首先介绍如何用R生成二项分布随机数的标准化变量。


```
> n=20;p=0.3
> z=rbinom(1,n,p) #模拟生成一个二项分布随机数
> (z-n*p)/sqrt(n*p*(1-p)) #计算标准化变量
> [1] 1.9518
```

## 5.4 统计模拟

### ● 直方图模拟

- 这只是一个随机数标准化后的结果，我们需要产生很多随机数并观察它们的分布情况，比如需要产生1000个这样的随机数，这在R中是很容易实现的。

```
> m=1000          # m为模拟次数
> n = 20; p = 0.3
> z = rbinom(m,n,p)      # 产生1000个
二项随机数
> x = (z-n*p)/sqrt(n*p*(1-p))  # 对1000
个二项随机数标准化
> hist(x,prob=T,main=paste("n
=",n,"p=",p),col="red")
> curve(dnorm(x),add=T,col="blue") #
添加正态曲线
```




## 5.4 统计模拟

### ● 直方图模拟

- 在上面的模拟例子中，我们指定模拟次数 $m=1000$ ，样本量 $n=20$ ，概率 $p=0.3$ ，如果要改变这些参数来重新进行模拟将会很麻烦，下面将展示形成一个模拟函数再进行模拟。

```
> sim.clt <- function(m,n,p){
  z = rbinom(m,n,p)
  x = (z-n*p)/sqrt(n*p*(1-p))
  hist(x,prob=T,breaks=20,main=paste("n =",n,"p =",p), col="red")
  curve(dnorm(x),add=T,col="blue")
}
> par(mfrow=c(1,2))
> sim.clt(2000,100,0.6) # 取 m=2000, n=100, p=0.6
> sim.clt(1000,30,0.5) # 取 m=1000, n=30, p=0.5
```



## 5.4 统计模拟


### ● 正态概率模拟

- 能比直方图更好判定随机数是否近似服从正态分布的是正态概率图，其基本思想是作样本分位数与理论分位数的散点图，看图像是否近似在一条直线上。分位数比中位数、下四分位数 $Q1$ 和上四分位数 $Q3$ 等更具一般性。 $q$ 分位数就是累积概率小于 $q\%$ 所对应的值，所以25%分位数就是 $Q1$ ，50%分位数就是中位数，75%分位数就是 $Q3$ 。用R来画正态概率图很简单，只要使用函数`qqnorm()`和`qqline()`，其中`qqline`是用来添加参考线（并不是回归线）。
- 下面分别产生1000个均值为0，标准差为1的正态分布随机数以及均值为10的指数分布。重复计算1000次它们的标准化变量。再分别作它们的正态概率图。程序如下：

```
> n=1000;mu=10 #mu为指数分布均值
> par(mfrow=c(1,3))
> x=rnorm(n,0,1);qqnorm(x,main="N(0,1)",col="red");qqline(x,col="blue") #画QQ图并添加qq线
> z=rexp(n,1/mu);qqnorm(z,main="exp(0.1)",col="brown");qqline(z,col="blue")
> y=replicate(1000,(mean(rexp(n,1/mu))-mu)/(mu/sqrt(n)))
> qqnorm(y,main="趋于N(0,1)",col="orange");qqline(y,col="blue")
```

## 5.4 统计模拟

- 最左边和最右边图的散点近似分布在参考线上，所以服从正态分布，而中间一张图的散点严重偏离参考线，可以认为这张图不服从正态分布。因此可以发现当 $n$ 趋于无穷时，指数分布的标准化变量服从正态分布。由于仅仅根据正态概率图无法得知标准化变量是否服从标准正态分布，因此想要更加严谨地对中心极限定理进行验证，需要结合上一小节提到的直方图模拟方法进行判断。



## 5.4 统计模拟

### ● 模拟函数构建方法


- 本节介绍`sim.fun()`函数来解决模拟函数构建问题，只要编写一个用来生成随机数函数，然后剩下的工作就交给`sim.fun`来做。编写泛式：`sim.fun`函数（泛式是指函数是虚构的，这是R语言最强大的地方）

- **1. 二项分布：**用二项分布来检验中心极限定理，首先编写一个二项分布随机数的标准化值的函数。

```
>f<-function(n=100,p=0.5){s=rbinom(1,n,p);(s-n*p)/sqrt(n*p*(1-p))}
```

- 设置参数 $n$ 、 $p$ ， $n$ 是 $f$ 函数的第一个参数，其默认值为100， $p$ 是 $f$ 函数的第二个参数。

```
> x=sim.fun(10000,f)      # 模拟10000个二项随机数
> hist(x,prob=T,col="brown",main="二项分布验证中心极限定理")
> curve(dnorm(x),add=T,col="blue")
```




## 5.4 统计模拟

### ● 模拟函数构建方法

- **2. 均匀分布：**用均匀分布来检验中心极限定理，可直接用均匀分布随机数函数来生成一个均匀随机数的值。

```
> f = function(n=10) (mean(runif(n))-1/2)/(1/sqrt(12*n))
> x=sim.fun(10000,f)      # 模拟10000个均匀随机数
> hist(x,prob=T, col="orange",main="均匀分布验证中心极限定理")
> curve(dnorm(x),add=T,col="blue")
```



## 5.4 统计模拟

### ● 模拟函数构建方法

- **3. 指数分布：**下面举一个偏态分布的数据的例子，检验随着n的增大，其样本均值是否服从中心极限定理，不妨使用指数分布数据来模拟。首先编写函数生成均值和标准差都为10的指数分布数据（指数分布的 $\mu=\delta=1/\gamma$ ），并求样本均值标准化变量。

```
> f <- function(n,mu)(mean(rexp(n,1/mu))-mu)/(mu/sqrt(n))
```

## 5.4 统计模拟

### ● 模拟函数构建方法

- 接下来分别模拟 $n$ 取5, 10, 100情况, 每次生成的随机数都是1000, 并作直方图以及标准正态分布密度线。程序如下:

```
>f <- function(n,mu)(mean(rexp(n,1/mu))-
mu)/(mu/sqrt(n))
>par(mfrow=c(1,3))
> x<- sim.fun(1000,f,5,10)
> hist(x,prob=T,main="n=5",col="red")
> curve(dnorm(x),add=T,col="blue")
> x<- sim.fun(1000,f,10,10)
> hist(x,prob=T,main="n=10",col="brown")
> curve(dnorm(x),add=T,col="blue")
> x<- sim.fun(1000,f,100,10)
> hist(x,prob=T,main="n=100",col="orange")
> curve(dnorm(x),add=T,col="blue")
```

