

统计学概论

杨文志
安徽大学大数据与统计学院
wzyang@ahu.edu.cn

第6章 描述性数据分析

- 单变量数据分析
- 双变量数据分析
- 多变量数据分析

6.1 单变量数据分析


● 分类型数据

- 统计学上把取值范围是有限个值或是一个数列构成的变量称为**离散变量**，其中表示分类情况的离散变量又称为**分类变量**。对于分类数据我们可以用频数表来分析，也可以用条形图和饼图来描述。
- **频数表**(Table)可以描述一个分类变量的数值分布概况。如果x是分类数据，只要在R中用table(x)就可以生成分类频数表。
- **条形图**(Barplot)的高度可以是频数或频率，图的形状看起来是一样，但是刻度不一样。R画条形图的命令是barplot()。在R中，对分类数据作条形图，需先使用table命令对原始数据分组，再对分组后的数据使用barplot()命令，否则作出的不是分类数据的条形图。
- **饼图**(Pie Graph)用于表示各类别某种特征的构成比情况，它以图形的总面积为100%，扇形面积的大小表示事物内部各组成部分所占的百分比构成比。在R中作饼图的命令是pie()，像条形图一样，对原始数据作饼图前要先分组。

6.1 单变量数据分析

- 假如对一组25人饮酒者所饮酒类进行调查，饮酒者按照红酒（1）、白酒（2）、黄酒（3）和啤酒（4）分成4类统计。数据如下：3,4,1,1,3,4,3,3,1,3,2,1,2,1,2,3,2,3,1,1,1,1,4,3,1

```
> drink <- c(3,4,1,1,3,4,3,3,1,3,2,1,2,1,2,3,2,3,1,1,1,1,4,3,1)
> drink.count <- table(drink) # 分组计数
> names(drink.count) <- c("红酒","白酒","黄酒","啤酒")
> drink.count
红酒 白酒 黄酒 啤酒
  10   4   8   3
> barplot(drink.count) # 画条形图
> pie(drink.count) # 画饼图
```



6.1 单变量数据分析

● 数值型数据

➤ 1. 使用统计量描述数据

- 对于数值型数据，主要用均值，中位数来描述集中趋势，用方差、标准差、变异系数描述离散程度。使用R求均值、中位数、方差、标准差的命令分别是mean()、median()、var()、sd()。变异系数，又称离散系数，通过标准差除以平均值得到，是分布离散程度的一个归一化量度。此外，还可以使用summary()求分位数来概括数据，即五数概括。
- 值得注意的是，当数据是长尾或存在异常值时，均值、方差和标准差对于数据的描述会有所偏差，此时更为稳健的方法是使用中位数或截尾均值来描述集中趋势吗，用四分位间距(IQR)和平均差(mad)来描述离散程度。
- datasets包里的数据集Nile记录了从1871年到1970年尼罗河每年的平均流量（立方米）。

```
> mean(Nile) # 求均值
[1] 919.35
> mean(Nile,trim = 0.2) # 截尾均值(截去两端20%后的数据)
[1] 903.2167
> median(Nile) # 求中位数
[1] 893.5
> var(Nile) # 求方差
[1] 28637.95
```

```
> sd(Nile) # 求标准差
[1] 169.2275
> grubbsary(Nile) # 求分位数
  Min. 1st Qu. Median  Mean 3rd Qu.  Max.
456.0  798.5  893.5  919.4 1032.5 1370.0
> IQR(Nile) # 四分位间距
[1] 234
> mad(Nile) # 平均差
[1] 179.3946
```

6.1 单变量数据分析

● 数值型数据

➤ 2. 数据分箱与直方图(Histogram)

- 数据分箱是指将连续变量离散化，即将一组数值数据按大小进行分组。在R中可以使用cut函数并规定切分点来对数值数据进行分箱。
- 直方图用于表示连续性变量的频数分布，实际应用中常用于考察变量的分布是否服从某种分布类型，相当于对分箱后的数据绘制条形图。图形以矩形的面积表示各组段的频数(或频率)，各矩形的面积总和为总频数(或等于1)。R中绘制直方图的函数是hist()，默认绘制频数直方图，若要绘制频率直方图，需将probability参数设置为T。
- 核密度估计是一种对数据分布情况的非参数估计方法，其主要思想是使用落在[x-h,x+h]区间的点的个数占样本总数的比例，来近似作为x处的密度函数，即

$$\hat{f}_h(x) = \frac{1}{nh} \sum_{i=1}^N K_0\left(\frac{x-x_i}{h}\right), K_0(t) = \frac{1}{2} \cdot 1(t < 1)$$


- 其中，h称为带宽， $K_0(t)$ 称为核函数。进一步，也可以使用其他核函数来替代上式。
- 在频率直方图上，可添加使用density函数拟合核密度估计曲线，并使用bw参数和kernel参数调整带宽和核函数。

6.1 单变量数据分析

● 数值型数据

➤ 仍以尼罗河流量数据为例。

```
> Nile.group = cut(Nile, breaks = seq(400,1400,100)) # 数据分箱
> table(Nile.group)
Nile.group
(400,500] (500,600] (600,700] (700,800]
      1         0         5         20
(800,900] (900,1e+03] (1e+03,1.1e+03] (1.1e+03,1.2e+03]
      25        19        12         11
(1.2e+03,1.3e+03] (1.3e+03,1.4e+03]
      6         1
> hist(Nile, breaks = seq(400,1400,100), main = '频数直方图')
> hist(Nile, breaks = seq(400,1400,100), probability = T, main = '频率直方图')
> lines(density(Nile),col='red') # 在频率直方图上添加核密度估计曲线
> legend("topright", legend='密度函数线', lty = 1, col = 'red', cex = 0.7)
```




6.1 单变量数据分析

● 数值型数据

➤ 3. 箱线图(Boxplot Graph)

➤ 箱线图可以用于考察连续变量的总体分布情况，它由一个箱子和两根引线构成，可分为垂直型和水平型，以垂直型为例，数据从小到大排序，下端引线表示数据的最小值，箱子的下端表示下四分位数，箱子中间的线表示中位数，箱子上端表示上四分位数，上端引线表示最大值。直方图侧重于对一个连续变量的分布情况进行详细考察，而箱线图更侧重于勾勒出分位数信息，比直方图更为简洁，并且便于对多个连续变量进行比较。在R里作箱线图的函数是boxplot()。

```
> boxplot(Nile) # 垂直型箱线图
> boxplot(Nile, horizontal=T) # 水平型箱线图
```




6.1 单变量数据分析

- 数值型数据

- 4. 时间序列图

- 特别地，对于时间序列数据，我们可以使用`ts.plot()`函数来绘制时间序列图。时间序列图是以时间轴为横轴，变量为纵轴，将数据点依次相连的折线，其主要目的是观察变量是否随时间变化而呈某种趋势。

```
> ts.plot(Nile)
```



6.1 单变量数据分析

- 离群值探索

- **离群值(outlier)**就是某个或少数几个值明显远离于其他大部分数据。理论上讲，离群值可以出现在各种分布中，但常见的主要出现在具有测量误差(measurement error)的数据或者总体是厚尾(heavy-tailed)分布的数据中。离群值的检验主要有箱线图，Grubb检验，Dixon's Q检验。

- 1.箱线图检验

- 如果观测值距箱式图底线Q1(25%分位数)或顶线Q3(75%分位数)过远，如超出箱体高度(Q3-Q1四分位数间距)的1.5以上，则可视该观测值为离群值。
- 另外，`boxplot.stats()`可以返回箱线图的有关统计量，返回值里，`$stats`是由箱线图的下须线、下四分位数、中位数、上四分位数、箱线图的上须线组成，`$n`返回样本量，`$conf`返回置信区间，默认是95%的置信区间，`$out`返回离群值。

- 2. Grubbs 检验

- **Grubbs 检验**是由Grubbs F.E.提出来用来探索来自于正态总体的单变量数据的离群值。Grubbs 检验是基于正态总体的假设，也就说在做检验前需要先检验数据的正态性。Grubbs 检验每次只能检验一个离群值。

6.1 单变量数据分析

● 离群值探索

➤ R中outliers包是专门用来做离群值检测包，Grubbs 检验函数是grubbs.test()。参数type表示检验类型，10表示检验一个离群值(默认值),11表示检验两个尾部上的两个离群值，20表示在一个尾部检验两个离群值。Opposite表示检验反方向上离群值，Two.sided表示是否进行双边检验。

➤ 3. Dixon's Q 检验

➤ 当样本量在3到30之间时，可以使用Dixon's Q 检验。gap是假设的离群值离它最近值的绝对距离，range是极差（最大值与最小值之间的距离），Q统计量为 $Q = \text{gap} / \text{range}$ ，当Q统计量大于临界值时，拒绝没有离群值的原假设，认为有离群值。

➤ outliers包中，Dixon's Q 检验的函数是dixon.test()。参数type表示检验类型,根据样本量大小选择不同的类型，具体的选择有：10(样本量 3-7)，11（样本量8-10），21（样本量11-13），22（样本量14及以上）。


6.1 单变量数据分析

● 离群值探索

➤ 假设1971年尼罗河年平均流量为1800（立方米），检验增加该数据后的Nile数据集是否存在离群值。

➤ 根据箱线图和箱线图统计量的结果，1800是一个离群值。并且，Grubbs 检验的p值为，Dixon's Q 检验的p值小于，因此对于这两个检验，均拒绝原假设，即认为数据集中存在离群值。

```
> Nile2 <- c(Nile, 1800)
> boxplot(Nile2)
> boxplot.stats(Nile2)
$stats
[1] 456 799 897 1040 1370
$sn
[1] 101
$conf
[1] 859.111 934.889
$out
[1] 1800
#install.packages("outliers")
library("outliers")
grubbs.test(Nile2, type = 10)
Grubbs test for one outlier
data: Nile2
G = 4.59355, U = 0.78688, p-value = 5.955e-05
alternative hypothesis: highest value 1800 is an outlier
```



6.2 双变量数据分析

● 分类数据vs分类数据

➤ 1. 二维列联表

➤ 类似一维分类数据，table()函数也可以把双变量分类数据整理成二维列联表形式。对于二维列联表x，可以使用prop.table(x, margin) 计算某个数据占行、列汇总数的比例或是占总数的比例，也就是边缘概率。当margin=1时，表示各个数据占行汇总数的比例，margin=2表示各个数据占列汇总数的比例，省略时，表示占总数的比例。

➤ 2. 复杂(复式)条形图

➤ 条形图用等宽直条的长短来表示相互独立的各指标数值大小，该指标可以是连续性变量的某汇总指标，也可以是分类变量的频数或构成比。各组间距应相等，其宽度一般与直条的宽度相等或为直条宽度的一半。类似一维情形，数据分组后，使用barplot()作条形图，默认为分段式条形图，并列式条形图需将beside参数设为True。


➤ 实际中经常碰到分成几种类型的数值型数据，类似单变量数据箱线图，可以使用boxplot()对双变量数据作箱线图，来粗略比较属于不同类的两组数据之间的关系。此外，也可以拼接所有类型的数据为y，另设一个虚拟变量x来标记对应的类别，使用boxplot(y~x)绘制箱线图。

6.2 双变量数据分析

● 分类数据vs数值型数据

➤ 对datasets包里中mtcars数据集，使用箱线图比较自动挡和手动档汽车的每加仑汽油行驶英里数(mpg)。


```
> head(mtcars)
> attach(mtcars); options(digits=3)
> table(vs, am) # 二维列联表
> prop.table(table(vs, am), 1) # 占行总数的比例
> prop.table(table(vs, am), 2) # 占列总数的比例
> barplot(table(vs, am), names.arg = c('V型', '直列'), legend.text=c('自动', '手动'))
> # 以变速器类型为横轴、发动机类型为分类变量画条形图
> barplot(table(am, vs), names.arg = c('自动', '手动'), legend.text=c('V型', '直列'))
> # 并列式条形图
> barplot(table(am, vs), beside = T, names.arg = c('自动', '手动'), legend.text=c('V型', '直列'))
```



6.2 双变量数据分析

● 数值型数据vs数值型数据

- 对于两个数值变量，我们可以从分布是否相同、是否存在相关关系和回归关系等多个角度进行比较。例如，使用plot()命令绘制散点图，或使用cor()函数计算相关系数。
- 相关系数用来反映两个数值变量的相关程度。需要注意的是，**非线性相关并不意味着不相关，有相关关系并不意味着一定有因果关系。**



6.2 双变量数据分析

● 数值型数据vs数值型数据

- 我们常用Person相关系数刻画两个变量的线性相关关系，变量X和Y的样本相关系数的定义公式是：

$$r = \frac{\sum (X_i - \bar{X})(Y_i - \bar{Y})}{\sqrt{\sum (X_i - \bar{X})^2 \sum (Y_i - \bar{Y})^2}}$$

- **Person相关系数度量变量之间线性关系**，取值范围是[-1,1]，当 $-1 < r < 0$ ，表示具有负线性相关，越接近-1，负相关性越强。 $0 < r < 1$ ，表示具有正线性相关，越接近1，正相关性越强。 $r = -1$ 表示具有完全负线性相关， $r = 1$ 表示具有完全正线性相关， $r = 0$ 表示两个变量不具有线性相关性。

- 对于非线性相关关系，我们常使用Spearman等级相关系数，此时应将cor()函数中的method参数设置为"spearman"，具体计算公式为


$$r_s = 1 - \frac{6 \sum d_i^2}{n(n^2 - 1)}$$

- 其中 $d_i = (x_i - y_i)$ ， x_i 和 y_i 分别是两个变量样本所对应的序数，n是样本数。类似地，Spearman等级相关系数的取值范围也是[-1,1]， $-1 < r < 0$ 表示具有负等级相关， $0 < r < 1$ 表示具有正等级相关。

6.2 双变量数据分析

➤ 对datasets包里中mtcars数据集的排量(displ)和hp(总马力)的关系。

```
> attach(mtcars); par(mfrow=c(1,2))
> plot(displ, hp, xlab = '排量', ylab = '总马力')
> abline(lm(hp~displ)) # 添加回归趋势线
> cor(displ, hp) # Person相关系数
[1] 0.791
> cor(displ, hp, method="spearman")
# Spearman等级相关系数, 等于cor(rank(displ), rank(hp))
[1] 0.851
```



排量displ和总马力hp之间散点图和趋势线

6.3 多变量数据分析

● 多维分类数据

- 多维数据中，每一维都是分类变量的情形。对多维分类数据使用table()函数生成一系列二维列联表。设数据的维数为s，变量的类别数分别为 $r_1, r_2, \dots, r_s$ 。当维数等于3，就会输出 r_1 个2维列联表；当维数大于3，就会输出 $r_1, r_2, \dots, r_{s-2}$ 个二维列联表。因此，维数较大或个别变量的类别数较多时，我们更常使用ftable()函数生成平面二维列联表(flat contingency table)，相当于从纵横两个方向拼接一系列二维列联表，因此改变变量的顺序会改变平面二维列联表的形状。
- 类似使用复式条形图来展示二维列联表，可以使用马赛克图(Mosaic Plots)来展示多维列联表数据。马赛克图由数个矩形组成，矩形面积正比于单元格频率。马赛克图背后的统计理论是对数线性模型，由于残差反映了拟合的好坏，因此马赛克图用5级颜色来表示每个单元格拟合结果的残差。R中马赛克图的函数为mosaicplot()，参数sort指定展示变量的顺序，参数dir指定马赛克图的拆分方向(横向拆分或纵向拆分)，参数type 给定残差的类型。

6.3 多变量数据分析


- 多维连续变量数据
 - 当多维数据中存在多维连续变量时，可以通过散点图和关系矩阵图等方式展现数据特征。
 - 一个常用的多维数据集为datasets包里的鸢尾花卉数据集(iris)数据集，含有4个连续变量，包括花萼长度、花萼宽度、花瓣长度和花瓣宽度，数据分为Setosa、Versicolour和Virginica三类，每类50个数据，因此共有150个数据样本。对于不含分类变量和含有多个分类变量的情况，分析方法与本节类似，因此不再赘述。

```
> head(iris)
Sepal.Length Sepal.Width Petal.Length Petal.Width Species
1      5.1         3.5         1.4         0.2  setosa
2      4.9         3.0         1.4         0.2  setosa
3      4.7         3.2         1.3         0.2  setosa
4      4.6         3.1         1.5         0.2  setosa
5      5.0         3.6         1.4         0.2  setosa
6      5.4         3.9         1.7         0.4  setosa
```

6.3 多变量数据分析

- 多维连续变量数据
 - 1. 散点图
 - 当我们只需要观察两个变量时，可以使用重叠散点图来更好地比较变量之间的相关关系，通过添加样本序号或类别序号，可以根据重叠散点图观察数据分布与样本顺序或类别的关系。
 - 对iris数据集的花萼长度和花瓣长度绘制重叠散点图。

```
> attach(iris); iris.lab = rep(c("1", "2", "3"), rep(50, 3))
> plot(iris[,1],iris[,3],type="n", xlab = "花萼长度",
ylab = "花瓣长度")
> text(iris[,1],iris[,3],cex=0.6) # 显示样本序号
> plot(iris[,1],iris[,3],type="n", xlab = "花萼长度",
ylab = "花瓣长度")
> text(iris[,1],iris[,3],iris.lab,cex=0.7) # 显示分类序号
```




6.3 多变量数据分析

● 多维连续变量数据

- 当我们需要观察三个变量时，可以使用scatterplot3d包中的scatterplot3d()命令来绘制三维图形，color参数控制点的颜色，angle参数控制前两维坐标轴之间的角度。
- 对iris数据集的花萼长度、花萼宽度和花瓣长度绘制三维散点图。

```
#install.packages("scatterplot3d")
> library(scatterplot3d); attach(iris); par(mfrow=c(1,2))
> scatterplot3d(iris[,1:3],color = as.numeric(Species))
> scatterplot3d(iris[,1:3],color = as.numeric(Species),angle = 10) # 旋转10度
> legend("bottomright",legend = c('setosa','versicolor','virginica'), pch=rep(1,3),col=1:3)
> detach(iris)
```





6.3 多变量数据分析

● 多维连续变量数据

- 当需要同时考察三个或三个以上的数值变量间的相关关系时，更适合使用散点图矩阵，它由将多个散点图合并在一起，**对角线为变量名称**，除对角线外的每个散点图对应其横、纵向变量，展示出变量两两之间的相关关系，这一点在多元线性回归显得尤为重要。散点图矩阵可以用R的pairs()函数绘制，也可以使用car包中的scatterplotMatrix()函数，scatterplotMatrix()函数的diagonal参数默认为TRUE，即在对角线绘制自适应核密度估计曲线并标注样本点的位置，如果存在分组，则为每个组分别绘制

```
> attach(iris)
> pairs(iris,pch=20) # 绘制矩阵散点图
> pairs(iris[1:4],pch=21,bg=Species) # 使用不同颜色来区分种类
> library(car) # 在散点图矩阵的对角线绘制核密度估计曲线
> scatterplotMatrix(~Sepal.Length+Sepal.Width+Petal.Length+Petal.Width|Species, col = 4:6)
```



6.3 多变量数据分析



● 多维连续变量数据

➤ 2. 关系矩阵图

➤ 当我们只需要观察连续变量之间的相关关系时，可以直接使用corrplot包的corrplot()函数，绘制圆点矩阵，来表示变量之间相关关系。其相关关系由相关系数衡量，蓝色代表正相关，红色代表负相关，颜色越深、面积越大代表相关关系越强。通过调整order和addrect参数，可以使关系矩阵图按照相关系数大小排序，并区分正相关与负相关，让图形变得更美观易读。

➤ 对iris数据集的连续变量绘制关系矩阵图。

```
> library(corrplot); attach(iris); par(mfrow=c(1,2))
> corrplot(cor(iris[,1:4]), tl.pos = "d", cl.pos = "n")
> corrplot(cor(iris[,1:4]), order = "h", tl.pos = "d",
  cl.pos = "n", addrect = 2); detach(iris)
```



6.3 多变量数据分析

● 多维连续变量数据

➤ 3. 雷达图(radar charts)

➤ 雷达图又叫蜘蛛网图，是一种表现3维或以上数据的图表。它将多个维度的数据量映射到坐标轴上，这些坐标轴起始于同一个圆心点，通常结束于圆周边缘，将同一组的点使用线连接起来就称为雷达图。雷达图在图形表现上通常以线、面或线面叠加的方式呈现，因此雷达图在样本数较小时更为清晰，并且允许缺失值，在样本的某一项数据缺失时，雷达图会直接将该样本缺失项两侧的点相连。

➤ 在R中，可以使用fmsb包中的radarchart()函数，对数据框绘制雷达图。maxmin函数默认为TRUE，此时数据框中每列的第一行和第二行需为该列的最大值和最小值，实际数据从第3行开始。另外，axistype参数等于0到5中任一整数，代表轴的类型；seg参数表示每个轴的段数；通过修改vlabels参数可以更改轴标签；pty、pcol、plty、pdensity、pangle、pfcpl参数分别控制数据点类型、颜色、线型、多边形填充密度、填充线角度和颜色。


6.3 多变量数据分析

● 多维连续变量数据

下面的R代码来自radarchart()函数文档中的示例。

```
> library(fmsb)
> ?radarchart
> maxmin <- data.frame(total=c(5,1), phys=c(15,3), psycho=c(3,0), social=c(5,1),
+ env=c(5,1))
> RNGkind("Mersenne-Twister");set.seed(123)
> dat <- data.frame(total=runif(5,1,5), phys=rnorm(5,10,2), psycho=c(1,1,0.5,NA,3),
+ social=runif(5,1,5), env=c(5,2,2,2.5,4))
> dat <- rbind(maxmin,dat) # 使得前两行为该列可能的最大值和可能的最小值
> radarchart(dat, axistype=1, seg=5, plty=1,
+ vlabels=c("Total\nQOL", "Physical\naspects", "Psychological\naspects",
+ "Social\naspects", "Environmental\naspects"), title="(axis=1, 5 segments, with
+ specified vlabels)", vlceex=0.5)
> radarchart(dat, axistype=2, pcol=topo.colors(3), plty=1, pdensity=c(5, 10,
+ 30), pangle=c(10, 45, 120), pfccl=topo.colors(3), title="(topo.colors, fill, axis=2)")
```

(axis=1, 5 segments, with specified vlabels)



(topo.colors, fill, axis=2)

