

统计学概论

杨文志
安徽大学大数据与统计学院
wzyang@ahu.edu.cn

第8章 线性回归分析


- 回归问题提出
- 一元线性回归
- 多元线性回归
- 回归R语言实现

8.1 回归问题提出

例8.1 身高与体重的关系

- 医学上认为人的身高和体重是有很大关系的，R的女性（women）数据集记录了不同身高（height，单位：英寸）的美国女性的体重（weight，单位：磅）：

身高	58	59	60	61	62	63	64	65	66	67	68	69	70	71	72
体重	115	117	120	123	126	129	132	135	139	142	146	150	154	159	164



- 首先对数据进行探索性分析，发现身高和体重具有很强的正相关关系，pearson相关系数为0.9954948。通过如下散点图可以看出，两者有着明显的线性关系，但身高是如何确定体重呢？

8.2 一元线性回归

例8.2 每月家庭消费支出与每月家庭可支配收入的关系

- 在一个假想的由100户家庭组成的社区中，我们要研究该社区每月家庭消费支出与每月家庭可支配收入的关系（参见表8-2），例如随着家庭月收入的增加，其平均月消费支出是如何变化的？

表 8-2 某社区家庭月可支配收入和消费支出

	每月家庭可支配收入 X（元）										
	800	1100	1400	1700	2000	2300	2600	2900	3200	3500	
每月家庭消费支出 Y（元）	561	638	869	1023	1254	1408	1650	1969	2090	2299	
	594	748	913	1100	1309	1452	1738	1991	2134	2321	
	627	814	924	1144	1364	1551	1749	2046	2178	2530	
	638	847	979	1155	1397	1595	1804	2068	2266	2629	
		935	1012	1210	1408	1650	1848	2101	2354	2860	
		968	1045	1243	1474	1672	1881	2189	2486	2871	
			1078	1254	1496	1683	1925	2233	2552		
			1122	1298	1496	1716	1969	2244	2585		
			1155	1331	1562	1749	2013	2299	2640		
			1188	1364	1573	1771	2035	2310			
			1210	1408	1606	1804	2101				
				1430	1650	1870	2112				
				1485	1716	1947	2200				
						2002					
	总计	2420	4950	11495	16445	19305	23870	25025	21450	21285	15510

注：数据来自李子奈、潘文卿《计量经济学》（第三版）

8.2 一元线性回归

从表8-2可以看出：

- 可支配收入相同的家庭，其消费支出不一定相同，即收入和消费支出的关系不是完全确定的；
- 由于是假想的总体，给定收入水平 X 的消费支出 Y 的分布是确定的，即在 X 给定下 Y 的条件分布（Conditional distribution）是已知的
- 如 $P(Y = 638|X = 800) = \frac{1}{4}$ 。

表8-2里的数据对应的散点图见图8-2：

- 从图8-2可以发现家庭消费支出的平均值随着收入的增加而增加，且 Y 的条件均值和收入 X 近似落在一条直线上。




图 8-2 某社区消费支出散点图

8.2 一元线性回归

在给定解释变量 X 条件下被解释变量 Y 的期望轨迹称为**总体回归线**

相应的函数称为**总体回归函数**（population regression function, PRF）

$$E(Y | X_i) = f(X_i)$$

- 其中 $f(X_i)$ 可以是线性的也可以是非线性的。

- 例8.2中，将居民消费支出看成是其可支配收入的线性函数时，总体回归函数为 $E(Y | X_i) = \beta_0 + \beta_1 X_i$

- 其中， β_0 、 β_1 是未知参数，也称为回归系数（regression coefficients）。

总体回归函数描述了在给定的收入水平 X 下，家庭的平均消费支出水平。但对某一个别的家庭，其消费支出可能与该平均水平有偏差。记 $\mu_i = Y_i - E(Y | X_i)$

这是一个不可观测的随机变量，称为随机误差项（error term）或随机干扰项（disturbance）。

8.2 一元线性回归

例8.2中，个别家庭的消费支出为： $Y_i = E(Y | X_i) + \mu_i = \beta_0 + \beta_1 X_i + \mu_i$

即给定收入水平 X_i ，个别家庭的消费支出可表示为两部分之和：

- (1)该收入水平下所有家庭的平均消费支出 $E(Y|X_i)$ ，称为系统性(systematic)或确定性(deterministic)部分；
- (2)其他随机或非确定性 (nonsystematic) 部分 μ_i 。

自然的想法是能否画一条直线尽可能好地拟合这些散点，如图 8-2 中的直线，这条直线称为样本回归线(sample regression lines)。 $\hat{Y}_i = f(X_i) = \hat{\beta}_0 + \hat{\beta}_1 X_i$ ，称为样本回归函数(sample regression function, SRF)。样本回归函数也有如下的随机形式： $Y_i = \hat{Y}_i + \hat{\mu}_i = \hat{\beta}_0 + \hat{\beta}_1 X_i + e_i$ 。

其中， e_i 称为残差(residual)，代表了其他影响 Y_i 的随机因素的集合，可以看成是 μ_i 的估计量 $\hat{\mu}_i$ 。




图 8-2 某社区消费支出散点图

8.2 一元线性回归

参数估计

- 回归分析**主要目的**是要通过样本回归函数(模型)SRF尽可能准确地估计总体回归函数(模型)PRF。
- 即根据 $Y_i = \hat{Y}_i + e_i = \hat{\beta}_0 + \hat{\beta}_1 X_i + e_i$ 去估计 $Y_i = E(Y | X_i) + \mu_i = \beta_0 + \beta_1 X_i + \mu_i$ ，其中 $e_i = Y_i - \hat{Y}_i = Y_i - \hat{\beta}_0 - \hat{\beta}_1 X_i$ 。
- 或者说利用 $\hat{\beta}_j (j=1, 2)$ 去估计 $\beta_j (j=1, 2)$ 。
- 参数估计方法有多种，其中使用最广泛的是**普通最小二乘估计法**(ordinary least squares, OLS)和**极大似然估计法**(Maximum Likelihood Estimation, MLE)。

为保证参数估计量具有良好的性质，通常要求模型满足若干基本假设：

- **假设1** 自变量X是确定的，不是随机变量；
- **假设2** 随机误差项具有零均值、同方差和无序列相关性，即：

$$\begin{aligned} E(\mu_i) &= 0 \quad i = 1, 2, \dots, n & Var(\mu_i) &= \sigma_\mu^2 \quad i = 1, 2, \dots, n \\ Cov(\mu_i, \mu_j) &= 0 \quad i \neq j \quad i = 1, 2, \dots, n \end{aligned}$$

8.2 一元线性回归

为保证参数估计量具有良好的性质，通常要求模型满足若干基本假设：

- **假设3** 随机误差项与自变量之间不相关，即：

$$\text{Cov}(X_i, \mu_i) = 0 \quad i = 1, 2, \dots, n$$

- **假设4** 服从正态分布，即：

$$\mu_i \sim N(0, \sigma^2) \quad i = 1, 2, \dots, n$$

- 以上假设也称为线性回归模型的**经典假设**或**高斯（Gauss）假设**，满足该假设的线性回归模型，也称为**经典线性回归模型**（Classical Linear Regression Model, CLRM）。

8.2 一元线性回归

1. 普通最小二乘估计（OLS）

普通最小二乘法（Ordinary least squares, OLS）是求解参数 $\hat{\beta}_j (j=1,2)$ ，使得样本观测值和拟合值之差的平方和最小，即：

$$\min : Q = \sum_{i=1}^n (Y_i - \hat{Y})^2 = \sum_{i=1}^n (Y_i - (\hat{\beta}_0 + \hat{\beta}_1 X_i))^2$$

- 由一阶条件可得：
- $$\begin{cases} \frac{\partial Q}{\partial \hat{\beta}_0} = 0 \\ \frac{\partial Q}{\partial \hat{\beta}_1} = 0 \end{cases} \Rightarrow \begin{cases} 2 \sum (Y_i - \hat{\beta}_0 + \hat{\beta}_1 X_i)(-1) = 0 \\ 2 \sum (Y_i - \hat{\beta}_0 + \hat{\beta}_1 X_i)(-1)X_i = 0 \end{cases} \Rightarrow \begin{cases} \sum (\hat{\beta}_0 + \hat{\beta}_1 X_i - Y_i) = 0 \\ \sum (\hat{\beta}_0 + \hat{\beta}_1 X_i - Y_i)X_i = 0 \end{cases}$$

- 解正规方程组可得：
- $$\begin{cases} \hat{\beta}_1 = \frac{\sum (X_i - \bar{X})(Y_i - \bar{Y})}{\sum (X_i - \bar{X})^2} := \frac{S_{xy}}{S_{xx}} \\ \hat{\beta}_0 = \bar{Y} - \hat{\beta}_1 \bar{X} \end{cases}$$

8.2 一元线性回归

参数估计量的统计性质：

- (1)线性性，即它是否是另一随机变量的线性函数；
- (2)无偏性，即它的期望值是否等于总体的真实值；
- (3)有效性，即它是否在所有线性无偏估计量中具有最小方差。

这三个准则也称作估计量的小样本性质。拥有以上性质的估计量称为**最佳线性无偏估计量**（best linear unbiased estimator, BLUE）。

可以证明最小二乘法估计量具有高斯——马尔可夫定理（Gauss-Markov theorem）：在给定经典线性回归的假定下，**最小二乘估计量是具有最小方差的线性无偏估计量**（best linear unbiased estimator, BLUE）。

8.2 一元线性回归

2. 参数估计量的概率分布及随机干扰项方差的估计：

参数估计量 $\hat{\beta}_0$ 与 $\hat{\beta}_1$ 的概率分布

- 普通最小二乘估计量 $\hat{\beta}_0$ 、 $\hat{\beta}_1$ 分别是 Y_i 的线性组合，所以 $\hat{\beta}_0$ 与 $\hat{\beta}_1$ 的分布取决于 Y 的分布。在 μ 是正态分布的假设下， Y 也是正态分布，则 $\hat{\beta}_0$ 、 $\hat{\beta}_1$ 也服从正态分布，分别为

$$\hat{\beta}_1 \sim N\left(\beta_1, \frac{\sigma^2}{S_{XX}}\right) = N\left(\beta_1, \frac{\sigma^2}{\sum (X_i - \bar{X})^2}\right)$$

$$\hat{\beta}_0 \sim N\left(\beta_0, \sigma^2 \left(\frac{1}{n} + \frac{(\bar{X})^2}{S_{XX}}\right)\right) = N\left(\beta_0, \sigma^2 \frac{\sum X_i^2}{n \sum (X_i - \bar{X})^2}\right)$$

注意： $\bar{Y}$ 、 $\hat{\beta}_1$ 相互独立。

8.2 一元线性回归

2. 参数估计量的概率分布及随机干扰项方差的估计：

随机误差项 μ 的方差 σ^2 的估计。

- 在 $\hat{\beta}_0$ 、 $\hat{\beta}_1$ 的方差中，都含有随机误差项 μ 的方差 σ^2 。由于 σ^2 实际上是未知的，因此 $\hat{\beta}_0$ 与 $\hat{\beta}_1$ 的方差实际上无法计算，这就需要对其进行估计。由于随机项 μ_i 不可观测，只能从 μ_i 的估计(残差 e_i)出发，对 σ^2 估计，其中 $e_i = Y_i - \hat{Y}_i = Y_i - \hat{\beta}_0 - \hat{\beta}_1 X_i$ 。因此，参数 $\hat{\beta}_0$ 与 $\hat{\beta}_1$ 的方差和标准差的估计量分别是：

- σ^2 的最小二乘估计量为 $\hat{\sigma}^2 = \frac{\sum e_i^2}{n-2}$ ，
可以证明 $\hat{\sigma}^2$ 是 σ^2 的无偏估计量。

$$\hat{\beta}_1 \text{ 的样本方差: } S_{\hat{\beta}_1}^2 = \hat{\sigma}^2 / \sum (X_i - \bar{X})^2 ;$$

$$\hat{\beta}_1 \text{ 的样本标准差: } S_{\hat{\beta}_1} = \hat{\sigma} / \sqrt{\sum (X_i - \bar{X})^2}$$

$$\hat{\beta}_0 \text{ 的样本方差: } S_{\hat{\beta}_0}^2 = \hat{\sigma}^2 \sum X_i^2 / n \sum (X_i - \bar{X})^2 ;$$

$$\hat{\beta}_0 \text{ 的样本标准差: } S_{\hat{\beta}_0} = \hat{\sigma} \sqrt{\sum X_i^2 / n \sum (X_i - \bar{X})^2}$$

8.2 一元线性回归

尽管从统计性质上可以保证如果有足够多的重复抽样，参数的估计值的期望（均值）就等于其总体的参数真值，即具有**无偏性**。但在一次抽样中，估计值不一定就等于该真值。那么，在一次抽样中，参数的估计值与真值的差异有多大、是否显著，这就需要进一步进行统计检验，主要有**拟合优度检验**、**变量的显著性检验**。

1. 拟合优度检验

拟合优度检验是对回归拟合值与观测值之间拟合程度的一种检验，指标主要是**判定系数(决定系数) R^2** 。

$$TSS = \sum_{i=1}^n (Y_i - \bar{Y})^2 \quad \text{为总体平方和(Total Sum of Squares)}$$

$$ESS = \sum_{i=1}^n (\hat{Y}_i - \bar{Y})^2 \quad \text{为回归平方和(Explained Sum of Squares)}$$

$$RSS = \sum_{i=1}^n (Y_i - \hat{Y}_i)^2 = \sum_{i=1}^n e_i^2 \quad \text{为残差平方和(Residual Sum of Squares)}$$

$$TSS = ESS + RSS \quad \text{总平方和=回归平方和+残差平方和}$$

$$\text{记 } R^2 = \frac{ESS}{TSS} = 1 - \frac{RSS}{TSS},$$

称 R^2 为可决系数(coefficient of determination)。 R^2 的取值范围为[0, 1]， R^2 越接近1，说明实际观测点离样本线越近，拟合优度越高。

8.2 一元线性回归

2. 变量显著性检验

回归分析的目的之一是要判断是否是一个显著影响因素，需要进行变量显著性检验。

$$\hat{\beta}_1 \sim N(\beta_1, \frac{\sigma^2}{\sum (X_i - \bar{X})^2}) \quad \hat{\sigma}^2 = \frac{\sum e_i^2}{n-2}$$

可构造检验统计量进行检验

$$t = \frac{\hat{\beta}_1 - \beta_1}{\sqrt{\hat{\sigma}^2 / \sum (X_i - \bar{X})^2}} = \frac{\hat{\beta}_1 - \beta_1}{S_{\hat{\beta}_1}} \sim t(n-2)$$

具体检验步骤为：

(1)对总体参数提出假设 $H_0: \beta_1 = 0$ $H_1: \beta_1 \neq 0$

(2)在原假设 H_0 成立下，构造 t 统计量 $t = \frac{\hat{\beta}_1}{S_{\hat{\beta}_1}}$

(3)给定显著性水平 α ，查 t 分布表，得临界值 $t_{1-\alpha/2}(n-2)$

(4)比较，判断：

若 $|t| > t_{1-\alpha/2}(n-2)$ ，则拒绝 H_0 ，接受 H_1 ；

若 $|t| \leq t_{1-\alpha/2}(n-2)$ ，则不拒绝 H_0

(5)对于一元线性回归方程中的截距项 $\hat{\beta}_0$ ，具体检验步骤类似。

8.2 一元线性回归

1. 点预测

对于拟合得到一元线性回归模型 $\hat{Y}_i = \hat{\beta}_0 + \hat{\beta}_1 X_i$ ，给定样本以外的自变量观测值 X_0 ，可以得到因变量的预测值 $\hat{Y}_0$ ，并以此作为其条件均值 $E(Y|X = X_0)$ 或个别值 Y_0 的一个近似估计，我们称之为**点预测**。给定显著性水平下，可以求出 Y_0 的**预测区间**，我们称之为**区间预测**。

对总体回归函数 $E(Y|X) = \beta_0 + \beta_1 X$ ，当 $X = X_0$ 时， $E(Y|X = X_0) = \beta_0 + \beta_1 X_0$ 通过样本回归函数 $\hat{Y} = \hat{\beta}_0 + \hat{\beta}_1 X$ ，求得拟合值为 $\hat{Y}_0 = \hat{\beta}_0 + \hat{\beta}_1 X_0$ ，于是两边取期望可得， $E(\hat{Y}_0) = E(\hat{\beta}_0 + \hat{\beta}_1 X_0) = E(\hat{\beta}_0) + X_0 E(\hat{\beta}_1) = \beta_0 + \beta_1 X_0 = E(Y|X = X_0)$ 可见， $\hat{Y}_0$ 是 $E(Y|X = X_0)$ 的无偏估计。

对总体回归函数 $Y = \beta_0 + \beta_1 X + \mu$ 当 $X = X_0$ 时， $Y_0 = \beta_0 + \beta_1 X_0 + \mu$ ，两边取期望可得，

$$E(Y_0) = E(\beta_0 + \beta_1 X_0 + \mu) = \beta_0 + \beta_1 X_0 + E(\mu) = \beta_0 + \beta_1 X_0$$

而通过样本回归函数 $\hat{Y} = \hat{\beta}_0 + \hat{\beta}_1 X$ ，求得拟合值 $\hat{Y}_0 = \hat{\beta}_0 + \hat{\beta}_1 X_0$ 的期望为，

$$E(\hat{Y}_0) = E(\hat{\beta}_0 + \hat{\beta}_1 X_0) = E(\hat{\beta}_0) + X_0 E(\hat{\beta}_1) = \beta_0 + \beta_1 X_0 \neq Y_0$$

可见 $\hat{Y}_0$ 不是个值 Y_0 的无偏估计。

8.2 一元线性回归

2. 区间预测

根据 $\hat{Y}_0 = \hat{\beta}_0 + \hat{\beta}_1 X_0$ $\hat{\beta}_1 \sim N(\beta_1, \frac{\sigma^2}{\sum (X_i - \bar{X})^2})$ $\hat{\beta}_0 \sim N(\beta_0, \frac{\sum X_i^2}{n \sum (X_i - \bar{X})^2} \sigma^2)$

可构造t统计量

$$t = \frac{\hat{Y}_0 - (\beta_0 + \beta_1 X_0)}{S_{\hat{Y}_0}} = \frac{\hat{Y}_0 - (\beta_0 + \beta_1 X_0)}{\sqrt{\hat{\sigma}^2 \left(\frac{1}{n} + \frac{(X_0 - \bar{X})^2}{\sum_{i=1}^n (X_i - \bar{X})^2} \right)}} \sim t(n-2)$$

于是，在给定显著性水平 α 下，总体均值的置信区间为：

$$\hat{Y}_0 - t_{1-\frac{\alpha}{2}} \times S_{\hat{Y}_0} < E(Y_0 | X_0) < \hat{Y}_0 + t_{1-\frac{\alpha}{2}} \times S_{\hat{Y}_0}$$

这也称为 $E(Y_0 | X_0)$ 的区间预测。

8.3 多元线性回归

多元线性回归——模型及假定

多元线性模型一般形式

$$Y_i = \beta_0 + \beta_1 X_{1i} + \beta_2 X_{2i} + \beta_3 X_{3i} + \cdots + \beta_k X_{ki} + \varepsilon_i \quad i = 1, 2, \dots, n$$

上述模型用矩阵形式记为 $\mathbf{Y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}$

则样本回归模型为 $\mathbf{Y} = \mathbf{X}\hat{\boldsymbol{\beta}} + \mathbf{e}$

样本回归方程为 $\hat{\mathbf{Y}} = \mathbf{X}\hat{\boldsymbol{\beta}}$

这里 $\hat{\mathbf{Y}}$ 表示 Y 的样本估计值向量； $\hat{\boldsymbol{\beta}}$ 表示回归系数 β 估计值向量； $\mathbf{e} = \mathbf{Y} - \hat{\mathbf{Y}} = \mathbf{Y} - \mathbf{X}\hat{\boldsymbol{\beta}}$ 表示残差向量。

8.3 多元线性回归

经典线性回归模型满足的假定条件有：

➤ **假设1** 零均值。假定随机干扰项的期望向量或均值向量为零，即 $E(\boldsymbol{\varepsilon}) = E \begin{pmatrix} \varepsilon_1 \\ \varepsilon_2 \\ \vdots \\ \varepsilon_n \end{pmatrix} = \begin{pmatrix} E\varepsilon_1 \\ E\varepsilon_2 \\ \vdots \\ E\varepsilon_n \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \\ \vdots \\ 0 \end{pmatrix} = \mathbf{0}$

➤ **假设2** 同方差和无序列相关。假定随机干扰项不存在序列相关且方差相同，即

$$\text{Var}(\boldsymbol{\varepsilon}) = E[(\boldsymbol{\varepsilon} - E\boldsymbol{\varepsilon})(\boldsymbol{\varepsilon} - E\boldsymbol{\varepsilon})'] = E(\boldsymbol{\varepsilon}\boldsymbol{\varepsilon}') = \sigma^2 \mathbf{I}_n$$

➤ **假设3** 随机干扰项与自变量相互独立，即 $E(\mathbf{X}'\boldsymbol{\varepsilon}) = 0$

➤ **假设4** 无多重共线性。假定数据矩阵X列满秩，即 $\text{Rank}(\mathbf{X}) = k + 1$

➤ **假设5** 正态性。假定 $\boldsymbol{\varepsilon} \sim N(\mathbf{0}, \sigma^2 \mathbf{I}_n)$

8.3 多元线性回归

多元线性回归——参数估计

对于总体回归模型 $\mathbf{Y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}$ ，求参数的方法是最小二乘 (OLS) 法，

即求 $\hat{\boldsymbol{\beta}}$ 使得残差平方和 $\sum e_i^2 = \mathbf{e}'\mathbf{e}$ 达到最小：

$$\begin{aligned} Q(\hat{\boldsymbol{\beta}}) &= \mathbf{e}'\mathbf{e} \\ &= (\mathbf{Y} - \mathbf{X}\hat{\boldsymbol{\beta}})'(\mathbf{Y} - \mathbf{X}\hat{\boldsymbol{\beta}}) \\ &= \mathbf{Y}'\mathbf{Y} - \hat{\boldsymbol{\beta}}'\mathbf{X}'\mathbf{Y} - \mathbf{Y}'\mathbf{X}\hat{\boldsymbol{\beta}} + \hat{\boldsymbol{\beta}}'\mathbf{X}'\mathbf{X}\hat{\boldsymbol{\beta}} \\ &= \mathbf{Y}'\mathbf{Y} - 2\hat{\boldsymbol{\beta}}'\mathbf{X}'\mathbf{Y} + \hat{\boldsymbol{\beta}}'\mathbf{X}'\mathbf{X}\hat{\boldsymbol{\beta}} \end{aligned}$$

一阶条件为

$$\frac{\partial Q(\hat{\boldsymbol{\beta}})}{\partial \hat{\boldsymbol{\beta}}} = -2\mathbf{X}'\mathbf{Y} + 2\mathbf{X}'\mathbf{X}\hat{\boldsymbol{\beta}} = 0$$

我们有 $\hat{\boldsymbol{\beta}} = (\mathbf{X}'\mathbf{X})^{-1} \mathbf{X}'\mathbf{Y}$ ，为线性回归模型参数最小二乘估计量，在误差正态情形下有 $\hat{\boldsymbol{\beta}} \sim N(\boldsymbol{\beta}, \sigma^2 (\mathbf{X}'\mathbf{X})^{-1})$

另外方差 σ^2 估计用 $S^2 = \mathbf{e}'\mathbf{e} / (n - k - 1)$ 估计，为无偏估计。

8.3 多元线性回归

1. 拟合优度检验

拟合优度检验是对回归拟合值与观测值之间拟合程度的一种检验，度量指标主要是判定系数(决定系数) R^2 。

$$TSS = (\mathbf{Y} - \bar{\mathbf{Y}})'(\mathbf{Y} - \bar{\mathbf{Y}}) = \mathbf{Y}'\mathbf{Y} - n(\bar{\mathbf{Y}})^2$$

为总体平方和(Total Sum of Squares)

$$ESS = (\hat{\mathbf{Y}} - \bar{\mathbf{Y}})'(\hat{\mathbf{Y}} - \bar{\mathbf{Y}}) = \hat{\mathbf{Y}}'\hat{\mathbf{Y}} - n(\bar{\mathbf{Y}})^2$$

为回归平方和(Explained Sum of Squares)

$$RSS = (\mathbf{Y} - \hat{\mathbf{Y}})'(\mathbf{Y} - \hat{\mathbf{Y}}) = \mathbf{e}'\mathbf{e}$$

为残差平方和(Residual Sum of Squares)

$$TSS = ESS + RSS$$

总平方和=回归平方和+残差平方和

$$\text{可决系数: } R^2 = \frac{ESS}{TSS} = 1 - \frac{RSS}{TSS}$$

注意到，可决系数 R^2 有一个问题：如果观测值 Y_i 不变，可决系数将随着自变量数目的增加而增大。如果用 R^2 去选择模型，会选取自变量数目最多的模型，这与实际不符合。

为解决这一问题，定义修正可决系数为

$$\bar{R}^2 = 1 - \frac{\text{残差平方和/自由度}}{\text{总平方和/自由度}} = 1 - \frac{RSS / (n - k - 1)}{TSS / (n - 1)}$$

8.3 多元线性回归

2. 方程整体显著性检验

方程的整体显著性检验，旨在对模型中因变量与自变量之间线性关系在总体上是否显著成立做出推断。

检验模型，

$$Y_i = \beta_0 + \beta_1 X_{1i} + \beta_2 X_{2i} + \beta_3 X_{3i} + \cdots + \beta_k X_{ki} + \varepsilon_i$$

可提出如下假设：

$$H_0 : \beta_1 = \beta_2 = \cdots = \beta_k = 0$$

$$H_1 : \beta_j \text{不全为0}$$

根据数理统计学中的知识，在原假设 H_0 成立的条件下，统计量

$$F = \frac{\text{回归平方和/自由度}}{\text{残差平方和/自由度}} = \frac{ESS / k}{RSS / (n - k - 1)} \sim F(k, n - k - 1)$$

中所有参数 β_j 都等于0。

给定显著性水平 α ，可得到临界值 $F_{\alpha}(k, n - k - 1)$ 。

如果 $F < F_{\alpha}(k, n - k - 1)$ ，则接受原假设，即该模型的所有回归系数都等于0，该模型是没有意义的；

如果 $F > F_{1-\alpha}(k, n - k - 1)$ ，则拒绝原假设，即认为模型是有意义的，但无法确认所有的回归系数是否都显著，这需要做进一步的检验，即需要对单个变量进行显著性检验。

8.3 多元线性回归

3. 单个变量显著性检验

单个变量的显著性检验一般利用t检验。可提出如下假设：

$$H_0 : \beta_j = 0 \quad j = 1, 2, \dots, k \quad H_1 : \beta_j \neq 0$$

根据数理统计学中的知识，在原假设 H_0 成立的条件下，统计量

$$t = \frac{\hat{\beta}_j - \beta_j}{S_{\hat{\beta}_j}} \sim t(n - k - 1) \quad \begin{aligned} S_{\hat{\beta}}^2 &= S^2 (\mathbf{X}'\mathbf{X})^{-1}, S^2 = \mathbf{e}'\mathbf{e} / (n - k - 1) \\ S_{\hat{\beta}_j}^2 &= S^2 (\mathbf{X}'\mathbf{X})_{jj}^{-1} \end{aligned}$$

$(\mathbf{X}'\mathbf{X})_{jj}^{-1}$ 为 $(\mathbf{X}'\mathbf{X})$ 第j个对角元素

给定显著性水平 α ，可得到临界值 $t_{1-\alpha/2}(n - k - 1)$ 。

如果 $|t| < t_{1-\alpha/2}(n - k - 1)$ ，则接受原假设，即该模型的 $\beta_j = 0$

说明自变量 X_j 对因变量是没有影响的。

8.3 多元线性回归

1. 单值预测

针对线性回归模型 $\mathbf{Y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}$ ，与一元线性回归模型类似，给定 $\mathbf{X}_0 = (1, X_{10}, X_{20}, \dots, X_{k0})_{1 \times (k+1)}$

$\hat{Y}_0 = \mathbf{X}_0 \hat{\boldsymbol{\beta}}$ 是 $E(Y_0)$ 的点估计值，也是 Y_0 的点估计值。

此外， $\hat{Y}_0$ 是 $E(Y_0)$ 的无偏估计，因为

$$E(\hat{Y}_0) = E(\mathbf{X}_0 \hat{\boldsymbol{\beta}}) = \mathbf{X}_0 E(\hat{\boldsymbol{\beta}}) = \mathbf{X}_0 \boldsymbol{\beta} = E(Y_0)$$

但是 $\hat{Y}_0$ 不是 Y_0 的无偏估计，因为

$$E(\hat{Y}_0) = E(\mathbf{X}_0 \hat{\boldsymbol{\beta}}) = \mathbf{X}_0 E(\hat{\boldsymbol{\beta}}) = \mathbf{X}_0 \boldsymbol{\beta} = Y_0 - \varepsilon_0$$

8.3 多元线性回归

2. $E(Y_0)$ 和 Y_0 区间预测

为了得到 $E(Y_0)$ 的置信区间，首先要得到 $\hat{Y}_0$ 的方差

$$\begin{aligned}\text{var}(\hat{Y}_0) &= E((\hat{Y}_0 - E(\hat{Y}_0))^2) \\ &= E((\mathbf{X}_0 \hat{\beta} - E(\mathbf{X}_0 \hat{\beta}))^2) \\ &= E((\mathbf{X}_0 \hat{\beta} - \mathbf{X}_0 \beta)^2) \\ &= \mathbf{X}_0 E((\hat{\beta} - \beta)(\hat{\beta} - \beta)') \mathbf{X}_0' \\ &= \mathbf{X}_0 \text{cov}(\hat{\beta}) \mathbf{X}_0' \\ &= \sigma_\varepsilon^2 \mathbf{X}_0 (\mathbf{X}'\mathbf{X})^{-1} \mathbf{X}_0'\end{aligned}$$

实际中 σ_ε^2 是未知的，所以用样本估计量 s^2 代替 σ_ε^2 于是得到

$$\hat{\text{var}}(\hat{Y}_0) = s^2 \mathbf{X}_0 (\mathbf{X}'\mathbf{X})^{-1} \mathbf{X}_0'$$

由于 $\hat{Y}_0 \sim N(\mathbf{X}_0 \beta, \sigma_\varepsilon^2 \mathbf{X}_0 (\mathbf{X}'\mathbf{X})^{-1} \mathbf{X}_0')$ ，所以

$$\frac{\hat{Y}_0 - E(Y_0)}{s \sqrt{\mathbf{X}_0 (\mathbf{X}'\mathbf{X})^{-1} \mathbf{X}_0'}} \sim t(n-k-1)$$

在给定显著性水平 α 下， $E(Y_0)$ 的 $(1-\alpha)$ 置信区间为

$$\hat{Y}_0 \pm t_{\alpha/2}(n-k-1) s \sqrt{\mathbf{X}_0 (\mathbf{X}'\mathbf{X})^{-1} \mathbf{X}_0'}$$

由于 $(Y_0 - \hat{Y}_0) \sim N(0, \sigma_\varepsilon^2 (1 + \mathbf{X}_0 (\mathbf{X}'\mathbf{X})^{-1} \mathbf{X}_0'))$ ，所以

$$\frac{Y_0 - \hat{Y}_0}{s \sqrt{1 + \mathbf{X}_0 (\mathbf{X}'\mathbf{X})^{-1} \mathbf{X}_0'}} \sim t(n-k-1)$$

在给定显著性水平 α 下， Y_0 的 $(1-\alpha)$ 置信区间为

$$\hat{Y}_0 \pm t_{\alpha/2}(n-k-1) s \sqrt{1 + \mathbf{X}_0 (\mathbf{X}'\mathbf{X})^{-1} \mathbf{X}_0'}$$

8.4 回归R语言实现

1. 一元线性回归

R里OLS的估计可用lm()函数。lm()的用法是

`lm ( formula , data , subset , weights , na.action , method = "qr" , ...)`

其中formula表示回归里的表达式，一般是 $y \sim X$ ，“ $\sim$ ”左边是因变量，“ $\sim$ ”右边是自变量，默认是包含截距项，如果不需要截距项的可以在自变量前面加“-1”，即 $y \sim -1 + X$ 。

比如，例8.1的OLS估计结果为：

```
> lm1 <- lm(weight ~ height, data = women) # 将回归结果保存在lm1对象里
> coef(lm1) # 提取估计系数
(Intercept) height
-87.51667 3.45000
> coef(lm(weight ~ -1 + height, data = women)) # 不加截距项
height
2.109512
```

例8.1的 $\hat{\beta}_0$ 和 $\hat{\beta}_1$ 的OLS估计结果分别是-87.52和3.45。如果去掉截距项后，回归系数为2.11。

8.4 回归R语言实现

1. 一元线性回归

R里求OLS的方差估计量 $\hat{\sigma}^2$ ，需要用summary()函数先将lm()的结果保存在slm对象里，然后提取sigma成分，即为 $\hat{\sigma}$ 。若要计算参数 $\hat{\beta}_0$ 与 $\hat{\beta}_1$ 的标准差，先提取出coef矩阵，然后再提取矩阵的第二列即为参数 $\hat{\beta}_0$ 与 $\hat{\beta}_1$ 的标准差。

例8.1的估计结果为：

```
> slm <- summary(lm1)
> slm $ sigma # 得到总体方差的OLS估计量
[1] 1.525005
> slm $ coef # 得到系数有关的矩阵
      Estimate Std. Error t value Pr(>|t|)
(Intercept) -87.51667  5.9369440 -14.74103 1.711082e-09
height       3.45000  0.0911365  37.85531 1.090973e-14
> slm $ coef[, 2] # 矩阵第二列，即系数标准差
(Intercept) height
5.9369440  0.0911365
```

例8.1中 $\hat{\sigma}$ 为1.525005, $\hat{\beta}_0$ 与 $\hat{\beta}_1$ 的样本标准差分别为5.9369和0.0911。

```
> summary(lm1)
Call:
lm(formula = weight ~ height, data = women)

Residuals:
    Min       1Q   Median       3Q      Max
-1.7333 -1.1333 -0.3833  0.7417  3.1167

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept) -87.51667   5.93694  -14.74 1.71e-09 ***
height       3.45000   0.09114   37.85 1.09e-14 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 1.525 on 13 degrees of freedom
Multiple R-squared:  0.991,    Adjusted R-squared:  0.9903
F-statistic: 1433 on 1 and 13 DF, p-value: 1.091e-14
```

8.4 回归R语言实现

1. 一元线性回归

也可以基于回归结果lm1，利用predict()函数进行预测。

```
> predict ( lm1 , newdata = data.frame(height = 64.5),
+          interval = "confidence", level = 0.95) # 均值预测区间, level为置信度
      fit   lwr   upr
1 135.0083 134.152 135.8647
> predict ( lm1 , newdata = data.frame (height = 64.5) ,
+          interval = "prediction", level = 0.95 ) # 个值预测区间
      fit   lwr   upr
1 135.0083 131.6043 138.4124
```

在R里可以用predict()函数求均值预测区间，但要在interval参数设为confidence，如果求个值的预测区间也可以用predict()函数，但要在interval参数设为prediction。

8.4 回归R语言实现

2. 多元线性回归

与一元线性回归类似，R使用lm()函数求多元线性回归的最小二乘估计。

例8.3 R中swiss记录了47个法语城市标准化的生育率指标和社会经济指标。为研究影响生育率的主要原因，对生育率进行有效调整，需建立回归模型。#影响生育因素很多，主要有从事农业男性百分比Agriculture、小学以上上学率百分比Education、天主教徒百分比Catholic、寿命小于1年婴儿死亡率Infant.Mortality。

估计结果为：

```
> lm2 <- lm(Fertility ~ Agriculture+Education+Catholic+Infant.Mortality, data = swiss) #多个自变量用+链接
> # lm2 <- lm(Fertility ~ ., data = swiss) # 使用其余全部自变量时可用"."代替
> coef(lm2)
      (Intercept)  Agriculture      Education      Catholic
      62.1013116   -0.1546175   -0.9802638    0.1246664
      Infant.Mortality
      1.0784422
```

模型估计结果说明，在假定其他变量不变的情况下，从事农业的男性百分比每增加1，生育率指标平均减少0.15；在假定其他变量不变的情况下，小学以上学历百分比每增加1，生育率指标平均减少0.98；在假定其他变量不变的情况下，天主教徒百分比每增加1，生育率指标平均增加0.12；在假定其他变量不变的情况下，寿命小于一年的婴儿死亡率每增加1，生育率指标平均增加1.08。

8.4 回归R语言实现

2. 多元线性回归

可以用summary()函数返回估计结果。

```
> summary(lm2) #返回估计结果
Call:
lm(formula = Fertility ~ Agriculture + Education + Catholic +
    Infant.Mortality, data = swiss)
Residuals:
    Min       1Q   Median       3Q      Max
-14.6765  -6.0522   0.7514   3.1664  16.1422
Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept)   62.10131    9.60489   6.466 8.49e-08 ***
Agriculture   -0.15462    0.06819  -2.267 0.02857 *
Education     -0.98026    0.14814  -6.617 5.14e-08 ***
Catholic       0.12467    0.02889   4.315 9.50e-05 ***
Infant.Mortality 1.07844    0.38187   2.824 0.00722 **
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
Residual standard error: 7.168 on 42 degrees of freedom
Multiple R-squared:  0.6993,    Adjusted R-squared:  0.6707
F-statistic: 24.42 on 4 and 42 DF, p-value: 1.717e-10
```

其中F检验统计量为24.4，两个自由度为分别4和42，对应的检验p-value小于0.05，说明是模型整体是显著的。单个变量显著性检验，截距项和所有自变量的p-value都小于0.05，说明它们都是显著的。