

统计学概论

杨文志
安徽大学大数据与统计学院
wzyang@ahu.edu.cn

第9章 线性分类模型

- 分类回归问题提出
- Probit与Logistic模型
- 判别分析法
- 分类问题评价准则
- R语言实现

9.1 分类问题提出

例9.1 医学诊断模型

- 医学诊断往往需要医生通过经验判断，而针对医学数据建立诊断模型，有利于提高诊断效率，降低误诊可能性。R的MASS包中的皮马印第安女性糖尿病数据集（Pima.tr、Pima.tr2、Pima.te）记录了居住在亚利桑那州凤凰城附近的21岁以上皮马印第安女性的糖尿病检查数据，除去含缺失值的样本外，共有532个样本。数据包括怀孕次数、血糖浓度、血压、皮肤厚度、体重指数、糖尿病谱系功能、年龄以及诊断结果。如下表所示。请问上述因素如何影响诊断结果？如何建立诊断模型进行分析？根据模型如何进行预测诊断结果？

编号	怀孕次数	血糖浓度	血压	皮肤厚度	体重指数	糖尿病谱系功能	年龄	诊断结果
obs	npreg	glu	bp	skin	bmi	ped	age	y
1	5	86	68	28	30.2	0.364	24	0
2	7	195	70	33	25.1	0.163	55	1
..	...	...	...	...	...	...	...	...

9.2 Probit与Logistic模型

X_i 是包含常数项的k元设计矩阵, Y_i 是二元取值的因变量, 考虑二元选择模型:

$$Y_i = X_i' \beta + \varepsilon_i \quad i = 1, 2, \dots, N$$

$$Y_i = \begin{cases} 1 & \text{某一事件发生} \\ 0 & \text{某一事件不发生} \end{cases}$$

若假定 $E(\varepsilon_i | X_i) = 0$, 则**总体回归方程**为: $E(Y_i | X_i) = X_i' \beta$

进一步地, 假设在给定 X_i 的时候, 某一事件发生的概率 p , 不发生的概率为 $(1-p)$, 即
 $Prob(Y_i = 1 | X_i) = p$, $Prob(Y_i = 0 | X_i) = 1 - p$, 则因为 Y_i 只取1和0两个值, 所以其条件期望为:

$$\begin{aligned} E(Y_i | X_i) &= 1 \cdot Prob(Y_i = 1 | X_i) + 0 \cdot Prob(Y_i = 0 | X_i) \\ &= 1 \cdot p + 0 \cdot (1 - p) = p \end{aligned}$$

综上, 可以得到: $E(Y_i | X_i) = X_i' \beta = Prob(Y_i = 1 | X_i) = p$

因此将该二元选择模型称为**线性概率模型**(Linear Probability Model, **LPM**)。这实际上就是用普通的线性回归方法对二元取值的因变量直接建模。

9.2 Probit与Logistic模型

对于线性概率模型，可以采用普通最小二乘法进行估计，但是会存在如下一些问题：

- (1)对模型进行拟合，实际上是对某一事件发生的平均概率的预测。但是，这里预测值并不能保证在0和1之间，完全有可能出现大于1和小于0的情形。
- (2)由于Y是二元变量，因此扰动项也应该是二元变量，它应该服从二项分布，而不是通常假定的正态分布。但是，当样本足够多时，二项分布收敛于正态分布。
- (3)在LPM中，扰动项是异方差的。

9.2 Probit与Logistic模型

在LPM中通过适当的假设可使得概率是线性关系，即： $p(X_i) = \text{Prob}(Y_i = 1 | X_i) = F(X_i' \beta) = X_i' \beta$ 但是存在问题： $X_i' \beta$ 并不能保证概率的取值在0和1之间。故为保证估计的概率取值在[0, 1]区间上，一个直接想法就是在外套上分布函数 $F(\cdot)$ 。如果分布函数 $F(X_i' \beta)$ 用标准正态分布函数 $\Phi(\cdot)$ ，即：

$$p(X_i) = \text{Prob}(Y_i = 1 | X_i) = \Phi(X_i' \beta) = \int_{-\infty}^{X_i' \beta} \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{z^2}{2}\right) dz$$

其中 $\Phi(X_i' \beta)$ 是正态分布的分布函数，取值范围是[0, 1]。这时的概率模型我们就称为Probit模型。

如果分布函数 $F(X_i' \beta)$ 取Logistic分布函数 $\Lambda(\cdot)$ ，则产生的概率模型为Logit模型：

$$p(X_i) = \text{Prob}(Y_i = 1 | X_i) = \Lambda(X_i' \beta) = \frac{\exp(X_i' \beta)}{1 + \exp(X_i' \beta)}$$

这里， $\Lambda(\cdot)$ 的取值也在0和1之间。或者变换成

$$\log\left(\frac{p(X_i)}{1-p(X_i)}\right) = X_i' \beta = \beta_0 + \beta_1 X_{i1} + \cdots + \beta_p X_{ip}$$

其中 $\log\left(\frac{p(X_i)}{1-p(X_i)}\right)$ 称为链接函数(link function)， $\frac{p(X_i)}{1-p(X_i)}$ 称之为机会比(odds ratio)，即取1的概率与取0的概率比值。

9.2 Probit与Logistic模型

基于潜变量模型的理解 二元选择模型也可以从潜变量回归模型去解释，首先考察以下模型：

$$Y_i^* = \mathbf{X}_i' \boldsymbol{\beta} + \varepsilon_i \quad i = 1, 2, \dots, T \quad Y_i = \begin{cases} 1 & \text{if } Y_i^* > 0 \\ 0 & \text{if } Y_i^* \leq 0 \end{cases}$$

其中， Y_i^* 是**潜变量或隐变量**(Latent Variable)，它无法获得实际观测值，但是却可以观测到 $Y_i^* > 0$ 还是 $Y_i^* \leq 0$ 。因此，我们实际上观测到的变量是 Y_i 而不是 Y_i^* 。该式称为**潜变量响应函数**(Latent Response Function)或**指示函数**(Index Function)。

如果我们假设：

- 假设1 $E(\varepsilon_i | X_i) = 0$
- 假设2 ε_i 是i.i.d.的正态分布
- 假设3 $\text{rank}(X_i) = k$

则当 $f(\varepsilon_i)$ 为 $N(0,1)$ 概率密度函数 $\phi(\varepsilon_i) = \frac{1}{\sqrt{2\pi}} \exp(-\frac{\varepsilon_i^2}{2})$

$$\text{Prob}(Y_i = 1 | \mathbf{X}_i) = 1 - \int_{-\infty}^{-\mathbf{X}_i' \boldsymbol{\beta}} \phi(\varepsilon_i) d\varepsilon_i$$

在这些假定之下考察 Y_i 的概率特征如下

$$= 1 - \Phi(-\mathbf{X}_i' \boldsymbol{\beta})$$

$$\text{Prob}(Y_i = 1 | \mathbf{X}_i) = \text{Prob}(Y_i^* > 0 | \mathbf{X}_i) = \text{Prob}(\mathbf{X}_i' \boldsymbol{\beta} + \varepsilon_i > 0 | \mathbf{X}_i)$$

$$= \Phi(\mathbf{X}_i' \boldsymbol{\beta})$$

$$= \text{Prob}(\varepsilon_i > -\mathbf{X}_i' \boldsymbol{\beta} | \mathbf{X}_i) = \int_{-\mathbf{X}_i' \boldsymbol{\beta}}^{\infty} f(\varepsilon_i) d\varepsilon_i$$

上式正是**Probit模型**。

9.2 Probit与Logistic模型

如果我们假设：

- 假设1 $E(\varepsilon_i | X_i) = 0$
- 假设2 ε_i 是i.i.d.的Logistic分布
- 假设3 $\text{rank}(X_i) = k$

在上述假定之下，考察 Y_i 的概率特征：

$$\text{Prob}(Y_i = 1 | \mathbf{X}_i) = \text{Prob}(Y_i^* > 0 | \mathbf{X}_i)$$

$$= \text{Prob}(\mathbf{X}_i' \boldsymbol{\beta} + \varepsilon_i > 0 | \mathbf{X}_i)$$

$$= \text{Prob}(\varepsilon_i > -\mathbf{X}_i' \boldsymbol{\beta} | \mathbf{X}_i)$$

$$= 1 - \int_{-\infty}^{-\mathbf{X}_i' \boldsymbol{\beta}} f(\varepsilon_i) d\varepsilon_i$$

$$= 1 - \frac{\exp(-\mathbf{X}_i' \boldsymbol{\beta})}{1 + \exp(-\mathbf{X}_i' \boldsymbol{\beta})}$$

$$= \frac{\exp(\mathbf{X}_i' \boldsymbol{\beta})}{1 + \exp(\mathbf{X}_i' \boldsymbol{\beta})} = \Lambda(\mathbf{X}_i' \boldsymbol{\beta})$$

上式正是**Logit模型**。

9.2 Probit与Logistic模型

Probit和Logit模型的参数估计常用**最大似然法**。对于Probit或Logit模型来说，

$$\text{Prob}(Y_i = 0 | \mathbf{X}_i) = 1 - F(\mathbf{X}_i' \boldsymbol{\beta})$$

所以似然函数为：

$$L = \prod_{i=1}^N F(\mathbf{X}_i' \boldsymbol{\beta})^{Y_i} (1 - F(\mathbf{X}_i' \boldsymbol{\beta}))^{1-Y_i}$$

对数似然函数为：

$$\log L = \sum_{i=1}^N \left\{ Y_i \cdot \log F(\mathbf{X}_i' \boldsymbol{\beta}) + (1 - Y_i) \cdot \log [1 - F(\mathbf{X}_i' \boldsymbol{\beta})] \right\}$$

最大化logL的一阶条件为：

$$\begin{aligned} \frac{\partial \log L}{\partial \boldsymbol{\beta}} &= \sum_{i=1}^N \left\{ Y_i \cdot \mathbf{X}_i \frac{f(\mathbf{X}_i' \boldsymbol{\beta})}{F(\mathbf{X}_i' \boldsymbol{\beta})} + (1 - Y_i) \cdot \mathbf{X}_i \frac{-f(\mathbf{X}_i' \boldsymbol{\beta})}{1 - F(\mathbf{X}_i' \boldsymbol{\beta})} \right\} \\ &= \sum_{i=1}^N \left\{ \mathbf{X}_i f(\mathbf{X}_i' \boldsymbol{\beta}) \frac{Y_i - F(\mathbf{X}_i' \boldsymbol{\beta})}{F(\mathbf{X}_i' \boldsymbol{\beta}) (1 - F(\mathbf{X}_i' \boldsymbol{\beta}))} \right\} = 0 \end{aligned}$$

其中 $f(\mathbf{X}_i' \boldsymbol{\beta}) = F'(\mathbf{X}_i' \boldsymbol{\beta})$ 上式求解需要用非线性方程迭代法求解。

9.2 Probit与Logistic模型

对于Probit模型来说，其边际效应为：

$$\frac{\partial \text{Prob}(Y_i = 1 | \mathbf{X}_i)}{\partial \mathbf{X}_i} = \Phi'(\mathbf{X}_i' \boldsymbol{\beta}) \boldsymbol{\beta} = \phi(\mathbf{X}_i' \boldsymbol{\beta}) \boldsymbol{\beta}$$

对于Logit模型，其边际效应为：

$$\frac{\partial \text{Prob}(Y_i = 1 | \mathbf{X}_i)}{\partial \mathbf{X}_i} = \Lambda'(\mathbf{X}_i' \boldsymbol{\beta}) \boldsymbol{\beta} = \Lambda(\mathbf{X}_i' \boldsymbol{\beta}) (1 - \Lambda(\mathbf{X}_i' \boldsymbol{\beta})) \boldsymbol{\beta}$$

其中 $\Lambda'(\cdot) = \Lambda(\cdot)(1 - \Lambda(\cdot))$

从上式可以看出，在Probit和Logit模型中，自变量对 Y_i 取值为1的概率的边际影响并不是常数，**它会随着自变量取值的变化而变化**。所以对于Probit和Logit模型来说，其回归系数的解释就没有线性回归那么直接了，相应的，它们的边际影响也不能像线性回归模型那样，直接等于其系数。

似然比检验类似于检验模型整体显著性的F检验，原假设为全部自变量的系数都为0，检验的统计量LR为：

$$LR = 2(\ln L - \ln L_0)$$

其中 $\ln L$ 为对概率模型进行MLE估计的对数似然函数值， $\ln L_0$ 为只有截距项的模型的对数似然函数值，往往也称为**空模型**，即模型中不包含任何自变量。当原假设成立时，LR的渐近分布是自由度为**k-1**(即除截距项外的自变量的个数)的 **χ^2 分布**。

9.2 Probit与Logistic模型

如果我们得到了系数的估计值 $\hat{\beta}$ ，那么我们就可以预测出在给定 X_0 下， $p(X_0) = \text{Prob}(Y_i = 1|X_0)$ 的概率预测值，即

对于Probit模型 $\hat{p}(X_0) = \hat{\text{Prob}}(Y_i = 1|X_0) = \Phi(X_0' \hat{\beta}) = \int_{-\infty}^{X_0' \hat{\beta}} \frac{1}{\sqrt{2\pi}} \exp(-\frac{z^2}{2}) dz$

对于logistic模型 $\hat{p}(X_0) = \hat{\text{Prob}}(Y_i = 1|X_0) = \Lambda(X_0' \hat{\beta}) = \frac{\exp(X_0' \hat{\beta})}{1 + \exp(X_0' \hat{\beta})}$

当然，对于logistic模型，我们也可以直接预测得到模型的链接(link)值

$$\hat{\text{Link}} = \log\left(\frac{\hat{p}(X_0)}{1 - \hat{p}(X_0)}\right) = X_0' \hat{\beta} = \beta_0 + \hat{\beta}_1 X_{10} + \dots + \hat{\beta}_p X_{p0}$$

9.2 Probit与Logistic模型

多分类Logistic模型

当因变量 Y_i 为分类变量，有K种取值时，我们也可以使用Probit与Logistic模型，但需要对其进行一定的修改，同时保证后验概率的和为1且每一个都落在[0,1]内。令前K-1类的链接函数为

$$\log \frac{\text{Prob}(Y_i = 1|X_0)}{\text{Prob}(Y_i = K|X_0)} = \beta_{10} + \beta_1^T X_0$$

$$\log \frac{\text{Prob}(Y_i = 2|X_0)}{\text{Prob}(Y_i = K|X_0)} = \beta_{20} + \beta_2^T X_0$$

...

$$\log \frac{\text{Prob}(Y_i = K-1|X_0)}{\text{Prob}(Y_i = K|X_0)} = \beta_{(K-1)0} + \beta_{K-1}^T X_0$$

即模型由K-1个logit变换来确定，通常使用最后一类或第一类作为机会比的分子。此处可简单计算得到属于每一类的概率为

$$\text{Prob}(Y_i = k|X_0) = \frac{\exp(\beta_{k0} + \beta_k^T X_0)}{1 + \sum_{l=1}^{K-1} \exp(\beta_{l0} + \beta_l^T X_0)}, k = 1, 2, \dots, K-1$$

$$\text{Prob}(Y_i = K|X_0) = \frac{1}{1 + \sum_{l=1}^{K-1} \exp(\beta_{l0} + \beta_l^T X_0)}$$

显然它们相加等于1。类似可推得多分类Probit模型。

9.3 判别分析法

对于二元因变量，Logistic模型采取的方法是直接对 $Pr(Y = k|X = x)$ 进行建模，用统计术语说，就是在给定自变量 X 下，建立因变量 Y 的条件分布模型。

在这小节将介绍另一种间接估计这些概率的方法——**判别分析**。判别分析是先对每一个给定的 Y 建立自变量 X 的分布，然后使用**贝叶斯定理**反过来再去估计 $Pr(Y = k|X = x)$ 。

那么在什么情况下我们会考虑使用判别分析呢？

一方面，当类别的区分度较高的时候，或者当样本量 n 较小且自变量 X 近似服从正态分布时，Logistic模型的参数估计会相对不够稳定，而判别分析就不存在这样的问题；

另一方面，在现实生活中，有很多因变量取值超过两类的情形，虽然我们可以把二元Logistic模型推广到多元的情况，但这在实际应用中并不常用。

实际上，对于因变量取多类别的问题，我们更常使用的是**判别分析法**。

9.3 判别分析法——朴素贝叶斯判别分析

1. **贝叶斯分类器** 一个非常简单的分类器是将每个观测值分到它最大可能所在的类别中，即给定 $X = x_0$ 的情况下，将它分到条件概率最大的 j 类中是比较合理的：

$$\max_j \Pr(Y = j | X = x_0)$$

这类方法称为**贝叶斯分类器**，这种分类器将产生最低的测试错误率，称为**贝叶斯错误率**，在 $X = x_0$ 这一点的错误率为 $1 - \max_j \Pr(Y = j | X = x_0)$ ，整个分类器的贝叶斯错误率为： $1 - E\left(\max_j \Pr(Y = j | X)\right)$

2. **贝叶斯定理** 假设观测分成 K 类，即因变量 Y 的取值为 $\{1, 2, \dots, K, K \geq 2\}$ ，取值顺序对结果并无影响。设 π_k 为一个随机选择的观测属于因变量 Y 的第 k 类的概率，即先验概率； $f_k(X) = \Pr(X = x | Y = k)$ 表示第 k 类观测的 X 的密度函数。则根据**贝叶斯定理**，可得观测 $X = x$ 属于第 k 类的后验概率为

$$\Pr(Y = k | X = x) = \frac{\pi_k f_k(x)}{\sum_{i=1}^K \pi_i f_i(x)}$$

我们知道，贝叶斯分类器是将一个观测分到 $p_k(x)$ 最大的类中，它在所有分类器中测试错误率是最小的(注意：只有当各项假设正确，该结论才是对的)。如果我们找到合适的方法估计 $f_k(X)$ ，便可构造一个与贝叶斯分类器类似的分类方法。

9.3 判别分析法——线性判别分析

1. 一元线性判别分析

我们在进行分类时，首先要获取 $f_k(X)$ 的估计，然后估计 $p_k(x)$ ，并根据 $p_k(x)$ 的值，将观测分到值最大的一类中。为获取 $f_k(X)$ 的估计，要先对其做一些假设。

通常假设 $f_k(X)$ 的分布是正态的，当 $p = 1$ ，密度函数为一维正态密度函数：

$$f_k(x) = \frac{1}{\sqrt{2\pi}\sigma_k} \exp\left(-\frac{1}{2\sigma_k^2}(x - \mu_k)^2\right)$$

其中 μ_k 和 σ_k^2 分别为第 k 类的均值和方差。再假设 $\sigma_1^2 = \dots = \sigma_K^2 = \sigma^2$ ，即所有 K 个类别方差相同，均为 σ^2 。带入可得 $p_k(x)$ ：

$$p_k(x) = \frac{\pi_k \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{1}{2\sigma^2}(x - \mu_k)^2\right)}{\sum_{i=1}^K \pi_i \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{1}{2\sigma^2}(x - \mu_i)^2\right)}$$

9.3 判别分析法

1. 一元线性判别分析

贝叶斯分类器是将观测值分到 $p_k(x)$ 最大的一类。我们对刚才求出的 $p_k(x)$ 取对数，并将对 $p_k(x)$ 大小无影响的项去掉，整理式子，不难看出贝叶斯分类器也将观测分到最大的一类。

$$\delta_k(x) = x \cdot \frac{\mu_k}{\sigma^2} - \frac{\mu_k^2}{2\sigma^2} + \log \pi_k$$

例如， $K = 2$ ，且 $\pi_1 = \pi_2$ ，当 $2x(\mu_1 - \mu_2) > \mu_1^2 - \mu_2^2$ 时，贝叶斯分类器把观测分到第一类，反之分到第二类。此时贝叶斯决策边界对应的点为

$$x = \frac{\mu_1^2 - \mu_2^2}{2(\mu_1 - \mu_2)} = \frac{\mu_1 + \mu_2}{2}$$

在实际中，即使确定 X 服从正态分布，但总体参数 $\mu_1, \dots, \mu_K, \pi_1, \dots, \pi_K, \sigma^2$ 我们仍然不知道，需要进行估计。线性判别分析方法与贝叶斯分类器类似，常用的参数估计如下：

$$\begin{aligned} \hat{\mu}_k &= \frac{1}{n_k} \sum_{i: y_i = k} x_i \\ \hat{\sigma}^2 &= \frac{1}{n - K} \sum_{k=1}^K \sum_{i: y_i = k} (x_i - \hat{\mu}_k)^2 \\ &= \sum_{k=1}^K \frac{n_k - 1}{n - K} \hat{\sigma}_k^2 \end{aligned}$$

其中， n 为随机抽取的样本数， n_k 为属于第 k 类的样本数， μ_k 的估计值为第 k 类观测的均值； $\hat{\sigma}_k^2 = \frac{1}{n_k - 1} \sum_{i: y_i = k} (x_i - \hat{\mu}_k)^2$ 为第 k 类观测的样本方差， $\hat{\sigma}^2$ 的估计值可以看作 K 类样本方差的加权平均。

9.3 判别分析法

1. 一元线性判别分析

实际中，有时我们可以掌握每一类的先验概率 $\pi_1, \dots, \pi_k$ ，但当信息不全时需要用样本进行估计，LDA是用属于第k类的观测的比例作为 π_k 的估计，即

$$\hat{\pi}_k = \frac{n_k}{n} \quad \hat{\delta}_k = x \cdot \frac{\hat{\mu}_k}{\hat{\sigma}^2} - \frac{\hat{\mu}_k^2}{2\hat{\sigma}^2} + \log \hat{\pi}_k$$

LDA分类器将观测 $X = x$ 分入值 $\hat{\delta}_k$ 最大的一类中。由于判别函数中 $\hat{\delta}_k$ 是关于 x 的线性函数，所以称该方法为**线性判别分析**。

与贝叶斯分类器比较，LDA分类器是建立在观测都来自于**均值不同、方差相同的正态分布假设**上的，将均值、方差和先验概率的**参数估计**代入贝叶斯分类器便可得到LDA分类器。

9.3 判别分析法

2. 多元线性判别分析

若自变量维度 $p > 1$ ，假设 $X = (X_1, \dots, X_p)$ 服从一个**均值不同、协方差矩阵相同**的多元正态分布，即假设第k类观测服从一个多元正态分布 $N(\mu_k, \Sigma)$ ，其中 μ_k 是一个均值向量， Σ 为所有K类共同的协方差矩阵，其密度函数形式为

$$f_k(x) = \frac{1}{(2\pi)^{p/2} |\Sigma|^{1/2}} \exp\left(-\frac{1}{2}(x - \mu_k)^T \Sigma^{-1}(x - \mu_k)\right)$$

通过类似于一维自变量的方法，我们可以知道贝叶斯分类器将 $X = x$ 分入最大的一类。

$$\delta_k(x) = x^T \Sigma^{-1} \mu_k - \frac{1}{2} \mu_k^T \Sigma^{-1} \mu_k + \log \pi_k$$

3. 二次判别分析

LDA假设每一类观测服从协方差矩阵相同的多元正态分布，但现实中可能很难满足这样的假设。**二次判别分析**放松了这一假设，虽然QDA分类器也假设每一类观测服从一个正态分布，并把参数估计代入贝叶斯定理进行预测，但QDA假设每一类观测有自己的协方差矩阵，即假设第k类观测服从的分布为 $X \sim N(\mu_k, \Sigma_k)$ ，其中 Σ_k 是第k类观测的协方差矩阵。此时，**二次判别函数**为

$$\begin{aligned} \delta_k(x) &= -\frac{1}{2}(x - \mu_k)^T \Sigma_k^{-1}(x - \mu_k) + \log \pi_k \\ &= -\frac{1}{2} x^T \Sigma_k^{-1} x + x^T \Sigma_k^{-1} \mu_k - \frac{1}{2} \mu_k^T \Sigma_k^{-1} \mu_k + \log \pi_k \end{aligned}$$

QDA分类器把 μ_k 、 Σ_k 、 π_k 的估计值代入上式，然后将观测分入使 $\hat{\delta}_k(x)$ 值最大的一类。

9.3 判别分析法

面对一个分类问题时，该如何在线性判别分析(LDA)和二次判别分析(QDA)中做出选择呢？

- 不妨假设有 p 个自变量，并且因变量包含 K 个不同类别
- 首先，假设 p 个自变量的协方差矩阵不同，由于预测一个协方差矩阵就需要 $p(p + 1)/2$ 个参数，而QDA需要对每一类分别估计协方差矩阵，因而共需要 $Kp(p + 1)/2$ 个参数；
- 另一方面，若假设 K 类的协方差矩阵相同，那么LDA模型对 x 来说是线性的，这时候就只需要估计 Kp 个线性系数。
- 因此，需要在方差与偏差之间进行一个权衡。一般而言，如果训练数据相对较少，那么降低模型的方差就显得很有必要，这个时候LDA是一个比QDA更好的选择。反之，如果训练集非常大，则会更倾向于使用QDA，因为这时候类的协方差矩阵相同的假设是站不住脚的。

9.4 分类问题评价标准

分类问题中需要基于一定准则对分类器进行评价

以二分类问题为例，设 $Y \in \{+, -\}$ ，例如在信用卡用户的违约问题中，我们可以将“+”理解为“违约”，将“-”理解为“未违约”。如果与经典的假设检验进行结合，那么就可以将“-”看作原(零)假设，而将“+”看作备择(非零)假设。

		预测分类		
		- 或零	+ 或非零	总计
真实分类	- 或零	真阴性值 (TN)	假阳性值 (FP)	N
	+ 或非零	假阴性值 (FN)	真阳性值 (TP)	P
	总计	N*	P*	

混淆矩阵

模型整体的正确率可表示为: $accuracy = (TN + TP)/(N + P)$

相应的，整体错误率即为 $1 - accuracy$ 。

9.4 分类问题评价标准

很多时候更关心模型在每个类别上的预测能力

在不平衡分类(imbalance classification)问题下，模型对不同类别点的预测能力可能差异很大。如果只关注整体预测的准确性，模型很有可能将所有数据都预测为最多类别的那一类，而这样的模型是没有意义的。

名称	定义	相同含义名称
假阳性率	FP/N	第I类错误，特异度 (specificity)
真阳性率	TP/P	第II类错误，灵敏度 (sensitivity)，召回率 (recall)
预测阳性率	TP/P*	精确率 (precision)
预测阴性率	TN/N*	
F1值	$\frac{2Precision \times Recall}{Precision + Recall}$	

9.4 分类问题评价标准

- 对于二分类模型，很多时候并不是直接给出每个样本的类别预测，而是给出其中一类的预测概率，因此需选取一个**阈值**(比如0.5)，当预测概率大于阈值时，将观测预测为这一类，否则预测为另一类。
- 对于不平衡数据，可以通过**ROC曲线**来比较模型优劣。
- ROC曲线是一类可以同时展示出所有可能阈值对应的两类错误的图像，它是通过将阈值从0到1移动，获得多对FPR(specificity)和TPR(sensitivity)，以**FPR为横轴**，**TPR为纵轴**，将各点连接起来而得到的一条曲线。
- ROC曲线越接近左上角，说明该分类器的性能越好。

如何绘制出ROC曲线？

当获得所有样本的概率输出(即属于正样本的概率)，将它们从小到大排列，并从**最小的概率值**开始，依次将概率值作为阈值。如果样本的输出概率大于等于这个值时，将其判定为正样本；反之判定为负样本。于是，每次都可以得到一对FPR和TPR，即ROC曲线上的一点，最终可以得到与样本个数相同的FPR和TPR的对数。

- 将阈值设置为1和0时，就可以分别得到ROC曲线上的(0,0)和(1,1)这两个点，将这两个点与之前得到的这些 (FPR, TPR) 对连接起来，就得到了ROC曲线。
- 选取的阈值个数**越多**，ROC曲线就**越平滑**。
- 很多时候由ROC曲线并不能清晰地看出哪个分类器的效果更好，所以可以采用**ROC曲线下方的面积** (area under the ROC curve, AUC) 来代表分类器的性能，AUC值越大，分类器的效果就越好。

9.5 R语言实现

现在对例9.1的数据进行分析。在建模之前，需先把诊断结果转换为0-1变量y，y = 1为患有糖尿病，y = 0为不患有糖尿病，求出数据的基本描述统计量，R程序如下。

```
> library(MASS)
> Pima = rbind(Pima.tr,Pima.te)[,1:7]
> head(Pima)
  npreg glu bp skin  bmi  ped age
1    5  86 68  28 30.2 0.364  24
2    7 195 70  33 25.1 0.163  55
3    5  77 82  41 35.8 0.156  35
4    0 165 76  43 47.9 0.259  26
5    0 107 60  25 26.4 0.133  23
6    5  97 76  27 35.6 0.378  52
> y<- as.numeric(rbind(Pima.tr,Pima.te)$type)-1
> Pima = data.frame(Pima,y)

> attach(Pima)
> summarys <- function(x) {data.frame(mean=mean(x),
max=max(x),min=min(x), sd=sd(x))} # 自编一个求基本描述统计
量简单函数
> summarys(npreg); summarys(glu); summarys(bp); summarys(skin)
  mean max min  sd
1 3.516917 17  0 3.312036
  mean max min  sd
1 121.0301 199  56 30.99923
  mean max min  sd
1 71.50564 110  24 12.31025
  mean max min  sd
1 29.18233  99  7 10.52388
> summarys(bmi); summarys(ped); summarys(age); summarys(y)
  mean max min  sd
1 32.89023 67.1 18.2 6.881109
  mean max min  sd
1 0.5029662 2.42 0.085 0.3445463
  mean max min  sd
1 31.61466  81  21 10.76158
  mean max min  sd
1 0.3327068  1  0 0.471626
```

9.5 R语言实现

R中可以用glm()函数拟合广义线性模型，包含Logistic回归中的probit模型和logit模型。glm()的形式与lm()类似，只是多了一些参数。函数的基本形式为：

glm (formula , family = family (link = function) , data =)

其中，formula是模型表达式，与lm()的表达式一致。family参数用于设置模型的连接函数对应的分布族，比如gaussian分布，Poisson分布等，详见下表。

分布族 (family)	连接函数
binomial	(link = "logit" 或 "probit" 或 "cauchit")
gaussian	(link = "identity")
gamma	(link = "inverse" 或 "identity" 或 "log")
inverse.gaussian	(link = "1/mu^2")
poisson	(link = "log" 或 "identity" 或 "sqrt")
quasi	(link = "identity" , variance = "constant")
quasibinomial	(link = "logit")
quasipoisson	(link = "log")

9.5 R语言实现

我们将从两个方面，即模型的错分率和ROC曲线来分别对前面介绍的四种模型（Logit、LDA、QDA、朴素 Bayes）的分类效果进行比较。

```
> library(MASS)
> Pima = rbind(Pima.tr,Pima.te)[,1:7]
> head(Pima)
  npreg glu bp skin bmi ped age
1    5  86 68  28 30.2 0.364 24
2    7 195 70  33 25.1 0.163 55
3    5  77 82  41 35.8 0.156 35
4    0 165 76  43 47.9 0.259 26
5    0 107 60  25 26.4 0.133 23
6    5  97 76  27 35.6 0.378 52
> y<-
as.numeric(rbind(Pima.tr,Pima.te)$type
)-1
> Pima = data.frame(Pima,y)
> attach(Pima)

> summarys <- function(x) {data.frame(mean=mean(x),
max=max(x),min=min(x), sd=sd(x))} # 自编一个求基本描述统计量简单函数
> summarys(npreg); summarys(glu); summarys(bp); summarys(skin)
  mean max min sd
1 3.516917 17 0 3.312036
  mean max min sd
1 121.0301 199 56 30.99923
  mean max min sd
1 71.50564 110 24 12.31025
  mean max min sd
1 29.18233 99 7 10.52388
> summarys(bmi); summarys(ped); summarys(age); summarys(y)
  mean max min sd
1 32.89023 67.1 18.2 6.881109
  mean max min sd
1 0.5029662 2.42 0.085 0.3445463
  mean max min sd
1 31.61466 81 21 10.76158
  mean max min sd
1 0.3327068 1 0 0.471626
```

```
> #OLS估计
> lpm <- lm (y ~ npreg+glu+bp+skin+bmi+ped+age, data = Pima)
> summary(lpm)

Call:
lm(formula = y ~ npreg + glu + bp + skin + bmi + ped + age, data =
Pima)

Residuals:
    Min       1Q   Median       3Q      Max
-1.17935 -0.26403 -0.06998  0.27128  1.00835

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept) -1.0372591  0.1189123  -8.723  < 2e-16 ***
npreg      0.0201144  0.0065716   3.061  0.002321 **
glu       0.0060256  0.0005831  10.334  < 2e-16 ***
bp      -0.0009059  0.0015195  -0.596  0.551318
skin     0.0006001  0.0021024   0.285  0.775433
bmi      0.0118797  0.0033199   3.578  0.000378 ***
ped      0.1803291  0.0494867   3.644  0.000295 ***
age      0.0042948  0.0021671   1.982  0.048021 *
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.3834 on 524 degrees of freedom
Multiple R-squared:  0.348,    Adjusted R-squared:  0.3392
F-statistic: 39.95 on 7 and 524 DF, p-value: < 2.2e-16
```

```
> #Logit模型估计
> logit_m <- glm (y ~ npreg+glu+bp+skin+bmi+ped+age,
+               family = binomial ( link = "logit" ), data = Pima) # 注意link设为logit
> summary(logit_m)

Call:
glm(formula = y ~ npreg + glu + bp + skin + bmi + ped + age,
    family = binomial(link = "logit"), data = Pima)

Coefficients:
            Estimate Std. Error z value Pr(>|z|)
(Intercept) -9.554651  0.994217  -9.610  < 2e-16 ***
npreg      0.122517  0.043743   2.801  0.005097 **
glu       0.035321  0.004244   8.322  < 2e-16 ***
bp      -0.007695  0.010314  -0.746  0.455602
skin     0.006774  0.014759   0.459  0.646242
bmi      0.082678  0.023334   3.543  0.000395 ***
ped      1.308708  0.364040   3.595  0.000324 ***
age      0.026375  0.014000   1.884  0.059581 .
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for binomial family taken to be 1)

Null deviance: 676.79  on 531  degrees of freedom
Residual deviance: 466.32  on 524  degrees of freedom
AIC: 482.32

Number of Fisher Scoring iterations: 5
```

```

#install.packages("zoo")
#install.packages("lme4")
> library(zoo)
> library(lme4)
> lrtest(logit_m) # LR检验
Likelihood ratio test

Model 1: y ~ npreg + glu + bp + skin + bmi + ped + age
Model 2: y ~ 1
#Df LogLik Df Chisq Pr(>Chisq)
1 8 -233.16
2 1 -338.39 -7 210.47 < 2.2e-16 ***
---
Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
> coe.l <- coef(logit_m) # 提取logit模型系数
> logit <- dlogis(coe.l[1] + coe.l[2]*mean(npreg) + coe.l[3]*mean(glu) +
coe.l[4]*mean(bp) + coe.l[5]*mean(skin) + coe.l[6]*mean(bmi) + coe.l[7]*mean(ped)
+ coe.l[8]*mean(age))
> coe.l*logit # 求logit模型平均边际影响
(Intercept) npreg glu bp skin bmi
-1.887194050 0.024198955 0.006976470 -0.001519891 0.001338055 0.016330245
ped age
0.258490512 0.005209430

```

```

> #LDA模型
> lda.fit <- lda(y ~ npreg+glu+bp+skin+bmi+ped+age, data=Pima)
> lda.fit
Call:
lda(y ~ npreg + glu + bp + skin + bmi + ped + age, data = Pima)

Prior probabilities of groups:
  0  1
0.6672932 0.3327068

Group means:
  npreg  glu  bp  skin  bmi  ped  age
0 2.926761 110.0169 69.91268 27.29014 31.42958 0.4463155
29.22254
1 4.700565 143.1186 74.70056 32.97740 35.81977 0.6165876
36.41243

Coefficients of linear discriminants:
LD1
npreg 0.089453937
glu 0.026797651
bp -0.004028686
skin 0.002668636
bmi 0.052832219
ped 0.801972183
age 0.019100341

> #对LDA模型的训练误差进行估计
> lda.pred <- predict(lda.fit, Pima)
> names(lda.pred)
[1] "class" "posterior" "x"
> lda.class <- lda.pred$class
> table(lda.class, Pima$y, dnn = c("Prediction", "Actual"))
      Actual
Prediction 0 1
0 317 75
1 38 102
> mean(lda.class != Pima$y)
[1] 0.212406

```

```

> #二次判别分析
> qda.fit <- qda (y ~ npreg+glu+bp+skin+bmi+ped+age, data =
Pima)
> qda.fit
Call:
qda(y ~ npreg + glu + bp + skin + bmi + ped + age, data = Pima)

Prior probabilities of groups:
      0      1
0.6672932 0.3327068

Group means:
      npreg      glu      bp      skin      bmi      ped      age
0 2.926761 110.0169 69.91268 27.29014 31.42958 0.4463155
29.22254
1 4.700565 143.1186 74.70056 32.97740 35.81977 0.6165876
36.41243

> qda.pred <- predict ( qda.fit , Pima) #预测
> names ( qda.pred )
[1] "class"  "posterior"
> qda.class <- qda.pred$class
> table(qda.class, Pima$y, dnn = c ( "Prediction" , "Actual" ) )
      Actual
Prediction 0  1
0      305   69
1       50  108


> mean(qda.class != Pima$y) #QDA模型训练误差
[1] 0.2236842

```

```

#模型比较
> #计算错分率
> logit.pred <- predict ( logit_m , Pima , type = "response" )
> logit.class <- rep ( 0 , nrow (Pima) )
> logit.class [ logit.pred > 0.5 ] <- 1 #阈值设为0.5
> table ( logit.class , Pima$y , dnn = c ( "Prediction" ,
"Actual" ) )
      Actual
Prediction 0  1
0      317   75
1       38  102
> mean ( logit.class != Pima$y)
[1] 0.212406

```



```
> #install.packages("pROC")
> library(pROC)
> logit.pred2 <- predict ( logit_m , Pima , type =
"response" )
> lda.pred2 <- predict ( lda.fit , Pima ) $ posterior [ , 2 ]
> qda.pred2 <- predict ( qda.fit , Pima ) $ posterior [ , 2 ]
> par ( mfrow = c ( 2 , 2 ) )
> roc(y, logit.pred2, plot=TRUE, main = "Logit")
Setting levels: control = 0, case = 1
Setting direction: controls < cases
```

Call:
roc.default(response = y, predictor = logit.pred2, plot = TRUE, main = "Logit")

Data: logit.pred2 in 355 controls (y 0) < 177 cases (y 1).
Area under the curve: 0.8597

```
> roc(y, lda.pred2 , plot=TRUE, main = "LDA")
Setting levels: control = 0, case = 1
Setting direction: controls < cases
```

Call:
roc.default(response = y, predictor = lda.pred2, plot = TRUE, main = "LDA")

Data: lda.pred2 in 355 controls (y 0) < 177 cases (y 1).
Area under the curve: 0.8595

```
> roc(y, qda.pred2 , plot=TRUE, main = "QDA")
Setting levels: control = 0, case = 1
Setting direction: controls < cases
```

Call:
roc.default(response = y, predictor = qda.pred2, plot = TRUE, main = "QDA")

Data: qda.pred2 in 355 controls (y 0) < 177 cases (y 1).
Area under the curve: 0.8497

9.5 R语言实现

